Міністерство освіти і науки України
Харківський національний університет радіоелектроніки

Кафедра штучного інтелекту

Дисципліна «Аналітика великих даних»

Практичне заняття №1

«Обробка великих даних у середовищі Hadoop (HDFS, MapReduce, Hive).»

Виконав:
ст. гр. ДМм-26-1
Зелінський В.С.

Прийняв:
Золотухін О.В.

Харків – 2026

Обробка великих даних у середовищі Hadoop (HDFS, MapReduce, Hive).

Мета роботи

Мета роботи: ознайомитися з архітектурою та принципами роботи платформи Apache Hadoop; навчитися працювати з розподіленою файловою системою HDFS; засвоїти базові прийоми обробки даних моделлю MapReduce; ознайомитися з використанням Hive для SQL-запитів до великих обсягів даних на прикладі повного набору хвилинних свічок BTC/USD (Bitcoin Historical Data, 7 816 537 рядків, 396,8 МБ) з порівнянням результатів, швидкодії і зручності роботи з Pandas та Spark.

Короткі теоретичні відомості

HDFS ділить файл на блоки (типово 128 МБ) і зберігає їх на DataNode в кількох репліках; NameNode тримає лише метадані. YARN виділяє контейнери (пам'ять і vCPU): ResourceManager приймає задачі, NodeManager запускає контейнери, ApplicationMaster керує однією задачею, JobHistoryServer зберігає лічильники.

У MapReduce map обробляє один split (зазвичай блок HDFS) і видає пари «ключ – значення», фреймворк сортує і групує їх за ключем (shuffle), а reduce отримує всі значення одного ключа. Combiner частково агрегує дані на боці map і коректний лише для асоціативних і комутативних операцій з однаковим форматом входу і виходу. Hadoop Streaming дозволяє писати map і reduce на Python через stdin/stdout. Для BTC/USD річні агрегати – суми за ключем часу, а добові Open і Close залежать від порядку свічок за Timestamp, тому combiner для них непридатний.

Hive зберігає схему в метасховищі (тут Derby), дані – файлами в HDFS, і компілює запит у задачі MapReduce. DROP TABLE зовнішньої таблиці видаляє лише метадані, керованої – і дані.

Результати виконання практичного заняття

1 Архітектура Hadoop та принципи роботи HDFS

Кластер розгорнуто на одній віртуальній машині (4 vCPU, 15 GiB RAM, Intel Xeon 2,10 ГГц): Hadoop 3.3.6, Hive 3.1.3, Java 1.8.0_472, Python 3.13.18, pandas 3.0.5, PySpark 4.3.0. `jps` показує п'ять демонів: NameNode, DataNode, ResourceManager, NodeManager і JobHistoryServer. `hdfs dfsadmin -report` підтверджує одну живу DataNode місткістю 270 553 174 016 байт, `hdfs getconf` – адресу `hdfs://localhost:9000`, реплікацію 1 і блок 134 217 728 байт.

2 Встановлення Hadoop у pseudo-distributed mode

Hadoop і Hive встановлено з архівів Apache скриптом `run_pz1.py`; демони запущено командами `hdfs --daemon start` і `yarn --daemon start` (як у `start-dfs.sh` і `start-yarn.sh`, але без ssh). Hive 3.1.3 працює лише з JDK 8, тому стек переведено на JDK 8, а guava 19 з Hive замінено новішою версією з Hadoop. Перевірку віртуальної пам'яті YARN вимкнено: інакше вона знищувала б контейнери Streaming, хоча фізичний пік map становив лише 605 048 832 байти. Ключові параметри подано в таблиці 1.

Таблиця 1 – Ключові параметри pseudo-distributed конфігурації

Параметр	Значення	Обґрунтування
fs.defaultFS	hdfs://localhost:9000	усе на одному вузлі
dfs.replication	1	одна DataNode
dfs.blocksize	134 217 728 (128 МБ)	CSV – 3 блоки
mapreduce.framework.name	yarn	UI і лічильники
nodemanager memory-mb / vcores	5120 / 4	решта RAM – демонам
map.memory.mb / java.opts	1024 / -Xmx768m	AM і 3 map у 5120 МБ
reduce.memory.mb / java.opts	1536 / -Xmx1024m	буфер злиття shuffle у купі JVM
mapreduce.job.reduces	1	один впорядкований файл
vmem-check-enabled	false	вірт. пік map 2 487 697 408 байт
maximum-am-resource-percent	0,8	при 0,1 AM не вміщується
map/reduce.speculative	true (типово)	див. підрозділ 4.2
hive.execution.engine	mr	Tez не встановлено

3 Завантаження набору даних у HDFS

Файл `btcusd_1-min_data.csv` (7 816 537 рядків даних і заголовок) завантажено в каталог `/user/root/btc/raw` і перевірено (рисунок 1):

```
hdfs dfs -mkdir -p /user/root/btc/raw && hdfs dfs -put -f btcusd_1-
   min_data.csv /user/root/btc/raw/
hdfs dfs -stat "%b %r %o" /user/root/btc/raw/btcusd_1-min_data.csv
hdfs dfs -ls -R -h /user/root/btc/raw /user/root/btc/wc_in
hdfs dfs -cat /user/root/btc/raw/btcusd_1-min_data.csv | head -n 5
hdfs fsck /user/root/btc/raw -files -blocks -locations
```

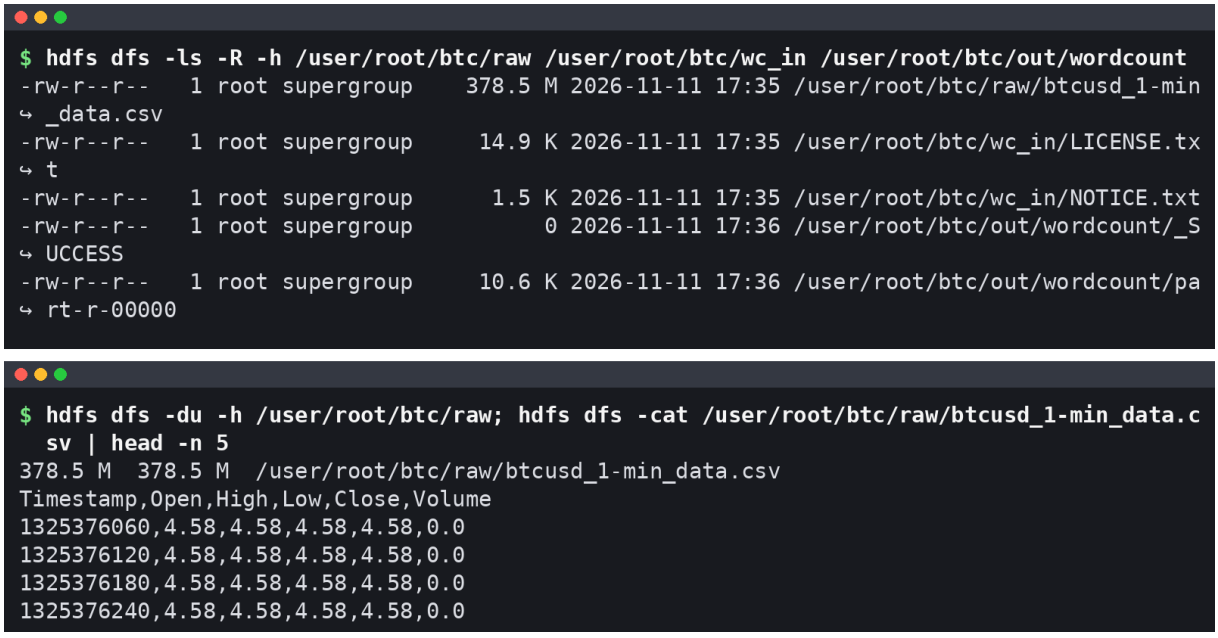


Рисунок 1 – Перевірка вмісту HDFS: ls -R, du і перші рядки CSV

Перші свічки 01.01.2012 мають ціну 4,58 і нульовий обсяг. Блоки за `hdfs fsck` зведено в таблицю 2.

Таблиця 2 – Блоки файлу btcusd_1-min_data.csv у HDFS

Блок	Ідентифікатор	Довжина, байт	Реплік
0	blk_1073742503	134 217 728	1
1	blk_1073742504	134 217 728	1
2	blk_1073742505	128 414 038	1
Разом	–	396 849 494	–

Сума довжин дорівнює розміру файлу, статус fsck – HEALTHY (зведення NameNode – рисунок 2).

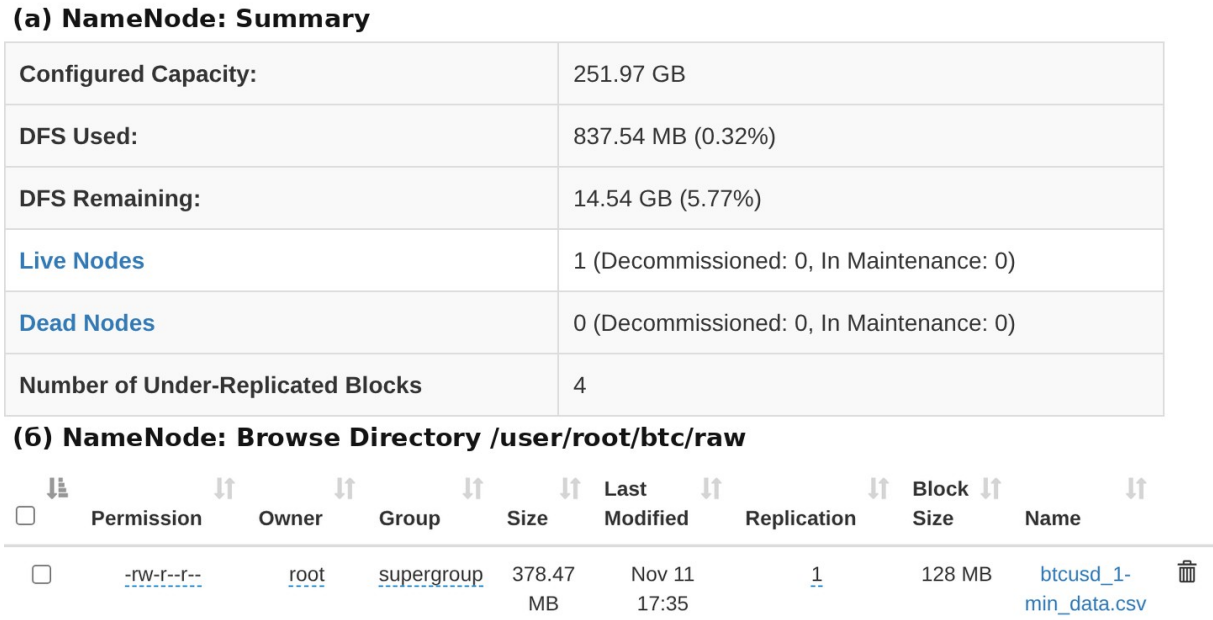


Рисунок 2 – Веб-інтерфейс NameNode (:9870): зведення і каталог /user/root/btc/raw

Розмір 378,47 МБ – це 396 849 494 байти в MiB; DFS Used 837,54 МБ включає ще копію файлу для керованої таблиці Hive і результати задач. Under-Replicated Blocks = 4 стосується не CSV (fsck каталогу raw – 0), а файлів задач MapReduce і Hive, записаних з реплікацією понад 1, якої одна DataNode забезпечити не може; до запуску задач `dfsadmin -report` показував 0.

4 Задачі MapReduce

4.1 WordCount як перевірка кластера

Приклад `wordcount` над `LICENSE.txt` і `NOTICE.txt` прочитав 304 рядки, combiner скоротив 1 879 пар до 798, на виході 748 різних слів («the» – 107, «of» – 68), рисунок 3.

```
$ hdfs dfs -cat /user/root/btc/out/wordcount/part-r-00000 | head -n 15
"AS             2
"Contribution"  1
"Contributor"   1
"Derivative     1
"Legal          1
"License"       1
"License");     1
"Licensor"      1
"NOTICE"        1
"Not            1
"Object"        1
"Source"        1
"Work"          1
"You"           1
"Your")         1
```

Рисунок 3 – Результат WordCount у HDFS (part-r-00000)

4.2 Кількість свічок і обсяг торгів за роками

Mapper `mapper_year.py` відкидає заголовок і неповні рядки і видає `рік \t 1 \t Volume` (рік UTC); reducer `reducer_year.py` сумує кількість і обсяг і через однаковий формат входу і виходу є й combiner:

```
hadoop jar hadoop-streaming-3.3.6.jar -D mapreduce.job.reduces=1 \
  -files mapper_year.py,reducer_year.py -mapper 'python3 mapper_year.py' \
  -combiner 'python3 reducer_year.py' -reducer 'python3 reducer_year.py' \
  -input /user/root/btc/raw -output /user/root/btc/out/mr_yearly
```

Hadoop створив 3 splits і прочитав 396 857 686 байт – більше за розмір файлу, бо reader дочитує рядок за межею split. Результат – 15 рядків, по одному на рік (рисунок 4).

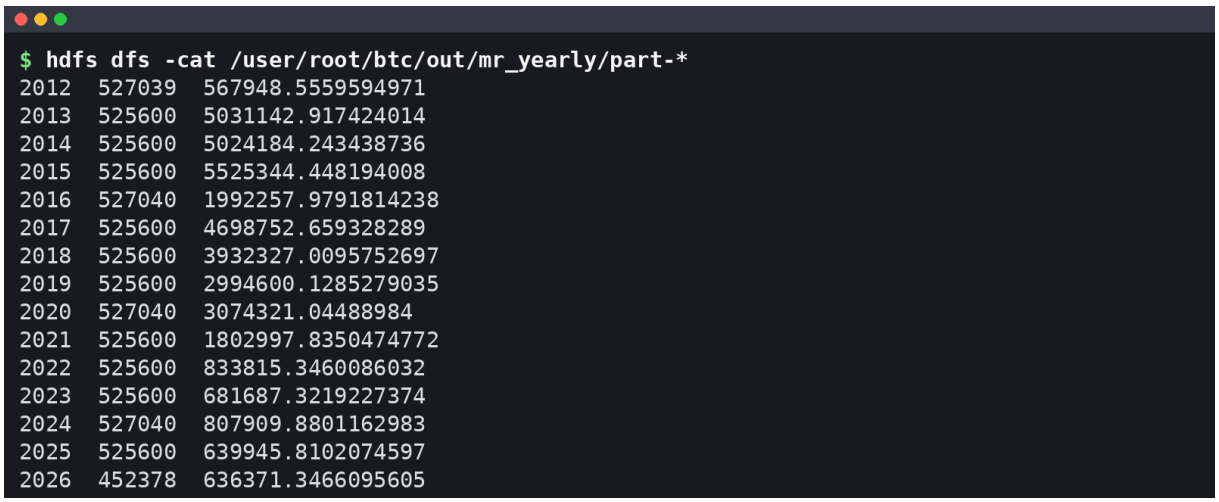


Рисунок 4 – Результат задачі mr_yearly у HDFS: рік, кількість свічок, обсяг

Launched map tasks = 4 при Killed map tasks = 1 – це спекулятивна копія повільної map-задачі; на одному вузлі вона конкурує з оригіналом за ті самі 4 ядра і лише додає розкиду часу.

4.3 Добові OHLC

Добові свічки будуються за правилом Open = first, High = max, Low = min, Close = last, Volume = sum, де first і last визначаються за Timestamp. Замість combiner у `mapper_ohlc.py` застосовано in-mapper combining: для кожної доби свого split mapper тримає найранішу і найпізнішу свічку, максимум, мінімум і суму обсягу та видає один запис на добу з мітками часу. Межа блоку може розрізати добу, а порядок записів усередині ключа не гарантовано, тому `reducer_ohlc.py` явно обирає запис із найменшим і найбільшим часом:

```
for day, grp in groupby(parse(sys.stdin), key=itemgetter(0)):
    parts = list(grp)
    first = sorted(parts, key=itemgetter(1))[0]   # найраніша свічка доби
    last = sorted(parts, key=itemgetter(7))[-1]   # найпізніша свічка доби
    hi = max(parts, key=itemgetter(3))
    lo = min(parts, key=itemgetter(5))
```

Пару mapper – reducer попередньо перевірено конвеєром `cat | mapper | sort | reducer` на 200 000 рядках. Отримано 5 429 діб;

неповні лише перша (1 439 свічок) і остання (218 свічок). Для обвалу 19.05.2021: Open 42 900,85, High 43 601,63, Low 30 066,00, Close 36 780,43.

4.4 Лічильники задач

Лічильники обох задач з журналів зведено в таблицю 3.

Таблиця 3 – Лічильники Streaming-задач над повним CSV

Лічильник	mr_yearly	mr_daily_ohlc
Map input records	7 816 538	7 816 538
Map output records	7 816 537	5 431
Map output bytes	127 655 772	490 246
Combine input / output records	7 816 537 / 17	0 / 0
Reduce shuffle bytes	567	501 126
Reduce input records	17	5 431
Reduce output records	15	5 429

Map input records містить ще заголовок. Combiner стиснув 127 655 772 байти виходу map до 567 байт shuffle, а in-mapper combining скоротив вихід map з 7,8 млн до 5 431 запису. Значення 17 і 5 431 замість 15 і 5 429 означають, що межі блоків розрізали по одному року і одній добі, а reducer злив ці часткові записи.

У JobHistory для добової задачі Shuffled Maps = 3 і Data-local map tasks = 3 (рисунок 5).

Name	Map	Reduce	Total
Data-local map tasks	0	0	3
Name	**Map**	**Reduce**	**Total**
Map input records	7,816,538	0	7,816,538
Reduce input groups	0	5,429	5,429
Shuffled Maps	0	3	3
Spilled Records	5,431	5,431	10,862

Рисунок 5 – Лічильники задачі mr_daily_ohlc у веб-інтерфейсі JobHistory (:19888)

Кожна з трьох map-задач читала свій блок локально (у річній задачі – 4 разом зі спекулятивною копією).

5 Таблиця Hive над даними в HDFS

5.1 Зовнішня таблиця

Hive підключено до Hadoop через `HADOOP_HOME`, метасховище створено командою `schematool -dbType derby -initSchema`. Зовнішню таблицю `btc.candles` над каталогом із CSV створено скриптом `hive_01_create_table.hql` з властивістю `"skip.header.line.count"="1"`; усі HQL-скрипти виконано командою `hive -S -f`. Опис таблиці наведено на рисунку 6.

```
$ hive -S -f hive_01b_describe.hql | sed '/^# Storage Information/,$d' | grep -vE '^(Owner
  Type|Owner|CreateTime|LastAccessTime|Retention):|bucketing|transient'
# фрагмент виводу: DESCRIBE FORMATTED candles (без Storage Information)
# col_name                  data_type                                   comment
ts                          double
open                        double
high                        double
low                         double
close                       double
volume                      double

# Detailed Table Information
Database:                   btc
Location:                   hdfs://localhost:9000/user/root/btc/raw
Table Type:                 EXTERNAL_TABLE
Table Parameters:
                            EXTERNAL                                    TRUE
                            numFiles                                    1
                            skip.header.line.count                      1
                            totalSize                                   396849494
```

Рисунок 6 – Опис зовнішньої таблиці candles (DESCRIBE FORMATTED)

Тип таблиці – EXTERNAL_TABLE, totalSize дорівнює розміру файлу. Подання `candles_v` обчислює дату UTC як `date_add('1970-01-01', floor(ts / 86400))` і відкидає неповні рядки (рисунок 7).

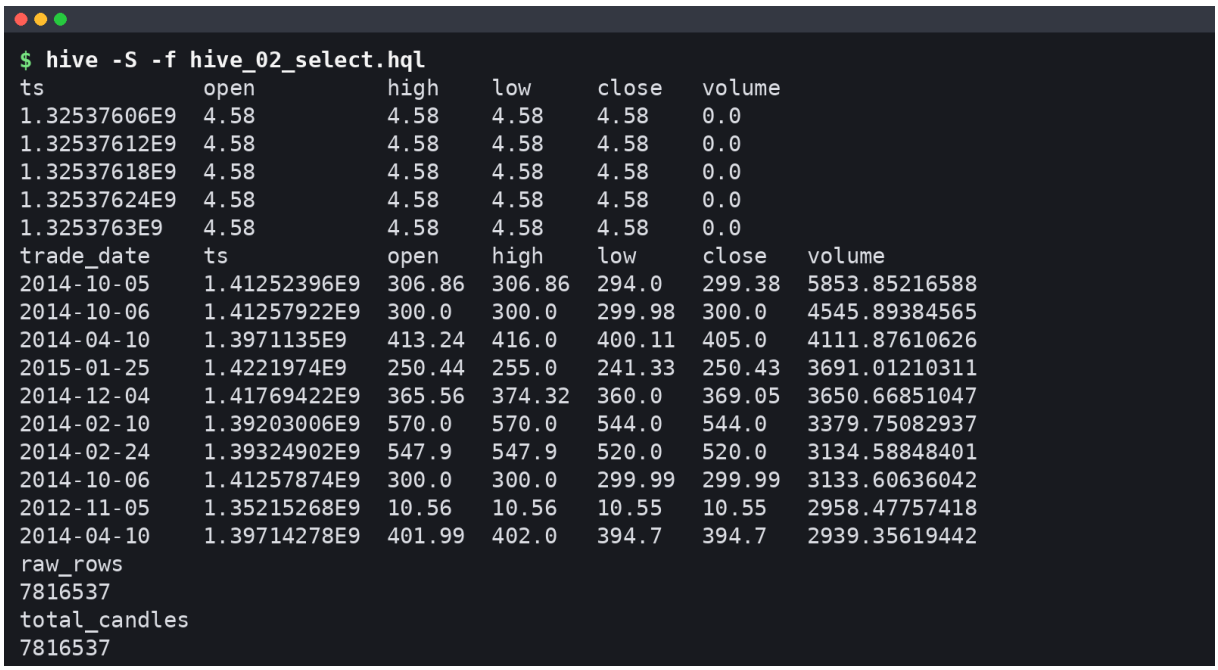


Рисунок 7 – Вибірка з таблиці candles, найбільші хвилинні свічки та COUNT(*)

`SELECT * FROM candles LIMIT 5` починається зі свічки 01.01.2012 00:01 UTC, рядка NULL немає. `COUNT(*)` по таблиці і по поданню однаково дорівнює 7 816 537: заголовок пропускає таблиця, а неповних рядків у файлі немає.

У першій версії DDL властивість мала хибну назву `skip.header.line.number`; Hive мовчки ігнорував її, і заголовок читався як рядок із NULL. Після виправлення результати запитів побайтно збіглися з попередніми, бо подання `candles_v` відкидало цей рядок і раніше.

5.2 Завантаження даних у керовану таблицю

Копію CSV з `/user/root/btc/load_src` (створено командою `hdfs dfs -cp`) завантажено в керовану таблицю `candles_managed` командою `LOAD DATA INPATH` (скрипт `hive_07_load_data.hql`, рисунок 8).

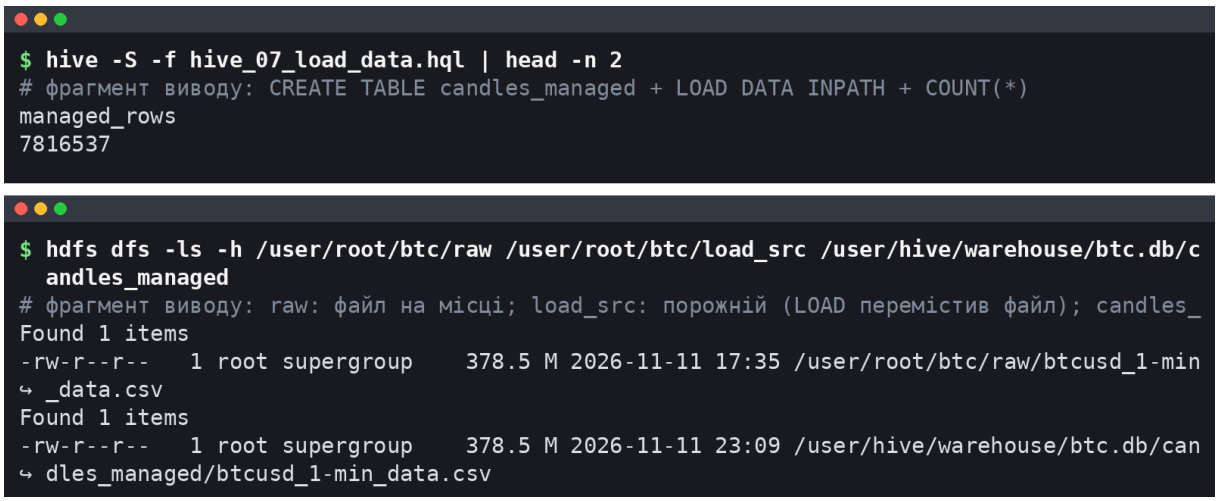


Рисунок 8 – LOAD DATA INPATH у керовану таблицю і стан HDFS після завантаження

Таблиця містить 7 816 537 рядків, каталог `load_src` порожній, а файл опинився у `/user/hive/warehouse/btc.db/candles_managed`: LOAD DATA INPATH переміщує файл у межах HDFS, не копіюючи його. Основні запити виконано над зовнішньою таблицею, бо `DROP TABLE` керованої видалив би й дані.

6 SQL-запити в Hive

6.1 Групування за роками і місяцями

Запит `hive_03a_yearly.hql` групує подання за `year(trade_date)` і рахує кількість свічок, суму обсягу, середню ціну закриття, максимум High і мінімум Low (таблиця 4).

Таблиця 4 – Річні агрегати Hive (обсяг округлено до 0,01 BTC, ціни – до 0,01 USD)

Рік	Свічок	Обсяг, BTC	Сер. Close	Max High	Min Low
2012	527 039	567 948,56	8,23	16,41	3,80
2013	525 600	5 031 142,92	187,43	1 163,00	12,77
2014	525 600	5 024 184,24	525,57	995,00	275,00
2015	525 600	5 525 344,45	272,25	502,00	152,40
2016	527 040	1 992 257,98	565,83	980,74	352,00
2017	525 600	4 698 752,66	3 948,33	19 666,00	751,34
2018	525 600	3 932 327,01	7 524,76	17 234,99	3 122,28
2019	525 600	2 994 600,13	7 352,19	13 880,00	3 322,19

Рік	Свічок	Обсяг, BTC	Сер. Close	Max High	Min Low
2020	527 040	3 074 321,04	11 074,63	29 300,00	3 850,00
2021	525 600	1 802 997,84	47 386,18	69 000,00	27 734,00
2022	525 600	833 815,35	28 228,66	48 234,00	15 479,00
2023	525 600	681 687,32	28 811,76	44 729,00	16 496,00
2024	527 040	807 909,88	65 895,12	108 364,00	38 505,00
2025	525 600	639 945,81	101 639,98	126 272,00	74 434,00
2026	452 378	636 371,35	74 103,97	97 939,00	57 734,63

Кількість свічок збігається з MapReduce до одиниці, обсяги – до останніх знаків (2014 рік: 5 024 184,243438596 у Hive проти 5 024 184,243438736 у MapReduce) через порядок підсумовування. Обсяг максимальний у 2015 році; у 2012 році свічок 527 039, бо перша має час 00:01. Повні роки мають 525 600 або 527 040 хвилин (високосні 2016, 2020, 2024): сітка повна, але 1 312 419 свічок (16,79 %) мають нульовий обсяг. Це заповнені пропуски з ціною попереднього закриття; їх збережено, тому вони входять у кількість свічок і середню ціну закриття. Місячний розріз (179 груп) має пік у листопаді 2013 року (965 986,91 BTC).

6.2 Добова таблиця і топ-10 діб

Добову таблицю `daily_ohlc` створено запитом CTAS без віконних функцій: Hive порівнює структури лексикографічно з першого поля, а `ts` унікальний у межах доби, тому мінімум структури `(ts, open)` дає Open найранішої свічки:

```
SELECT trade_date,
       min(struct(ts, open)).col2  AS open,
       max(high) AS high, min(low) AS low,
       max(struct(ts, close)).col2 AS close,
       sum(volume) AS volume, count(*) AS candles
FROM candles_v GROUP BY trade_date;
```

Таблиця має 5 429 рядків, як і результат MapReduce. Топ-10 діб за сумарним обсягом і за амплітудою High − Low (подання `daily_range_v`) подано в таблиці 5.

Таблиця 5 – Топ-10 діб за обсягом торгів і за амплітудою High − Low (Hive)

№	Доба (обсяг)	Обсяг, BTC	Доба (амплітуда)	High − Low, USD
1	2013-12-18	137 070,18	2021-05-19	13 535,63
2	2015-01-14	124 188,89	2025-10-10	12 899,00
3	2014-02-25	115 761,99	2021-12-04	11 910,27
4	2015-11-04	105 959,26	2026-02-06	11 743,00
5	2015-01-15	83 488,42	2024-12-05	11 555,00
6	2013-12-07	79 852,42	2025-02-03	11 039,00
7	2015-11-03	77 212,78	2026-02-05	10 975,00
8	2014-02-10	71 860,54	2021-02-22	10 164,19
9	2013-11-19	71 560,95	2025-03-02	10 123,00
10	2018-02-06	70 961,37	2021-09-07	10 056,46

Рейтинги не перетинаються. Дев'ять діб з найбільшим обсягом припадають на 2013–2015 роки, коли BTC коштував сотні доларів (18.12.2013 ціна впала з 675,00 до 382,21). Абсолютна амплітуда зростає з ціною, тому її топ-10 належить 2021–2026 рокам на чолі з обвалом 19.05.2021; для порівняння років її треба нормувати на ціну відкриття.

Кожен запит з обчисленнями Hive виконав окремим застосунком YARN; у веб-інтерфейсі ResourceManager (:8088) усі 12 застосунків завершилися зі статусом SUCCEEDED. Запити за роками і за місяцями мають по дві стадії (Stage-1 – GROUP BY, Stage-2 – ORDER BY), а `SELECT * FROM candles LIMIT 5` у списку відсутній: Hive виконав його читанням файлу без MapReduce.

7 Зручність та ефективність: порівняння з Pandas і Spark

7.1 Звірка результатів

Дві агрегації (T1 – кількість і обсяг за роками, T2 – добові OHLC) повторено в Pandas (`groupby` після сортування за Timestamp) і в PySpark local[*]. Підсумки звірки наведено в таблиці 6.

Таблиця 6 – Звірка результатів MapReduce, Hive, Pandas і Spark

Порівняння	Рядків	Збіг	Примітка
Hive – MapReduce, роки	15 / 15	так	обсяг з допуском 10^{-9}
Hive – MapReduce, доби	5 429 / 5 429	так	OHLC з допуском 10^{-12}
MapReduce – Pandas, роки	15 / 15	так	відн. різниця $1{,}00 \cdot 10^{-13}$
MapReduce – Pandas, доби	5 429 / 5 429	так	OHLC без розбіжностей
Hive – Pandas, роки	15 / 15	так	–
Hive – Pandas, топ-10 за обсягом	10 / 10	так	ті самі 10 дат у тому ж порядку
Hive – Pandas, топ-10 за High − Low	10 / 10	так	ті самі 10 дат у тому ж порядку
Spark – Pandas, роки і доби	15 і 5 429	так	–

7.2 Методика вимірювання часу

Скрипт `bench_all.py` вимірював повний настінний час від запуску нового процесу до записаного результату, включно зі стартом JVM, CLI Hive, інтерпретатора Python або SparkSession (local[*], драйвер 3 ГБ, 8 shuffle-розділів). Hadoop і Hive працюють з HDFS, Pandas і Spark – з локальним диском, на якому розміщено й HDFS. Старт кожного рушія виміряно окремо (імпорт pandas, створення SparkSession, `hive -S -e "select 1"`, порожня map-only задача Streaming); «обробка» – медіана загального часу мінус медіана старту.

Вимірювання почалися після трьох поспіль значень loadavg (1 хв) < 1,5. Після відкинутого прогрівального кола виконано 5 кіл (8 пар «рушій – задача» і 4 вимірювання старту) з циклічним зсувом початку, щоб дрейф навантаження і кеш ОС діяли на рушії однаково; усі 46 інших запусків T1/T2 збіглися з еталоном Pandas. Loadavg перед запусками – 1,44–3,22, вільна пам'ять – 10,5–11,1 ГБ.

7.3 Результати вимірювання

Медіани з мінімумом і максимумом 5 запусків показано на рисунку 9, медіани і IQR – у таблиці 7.

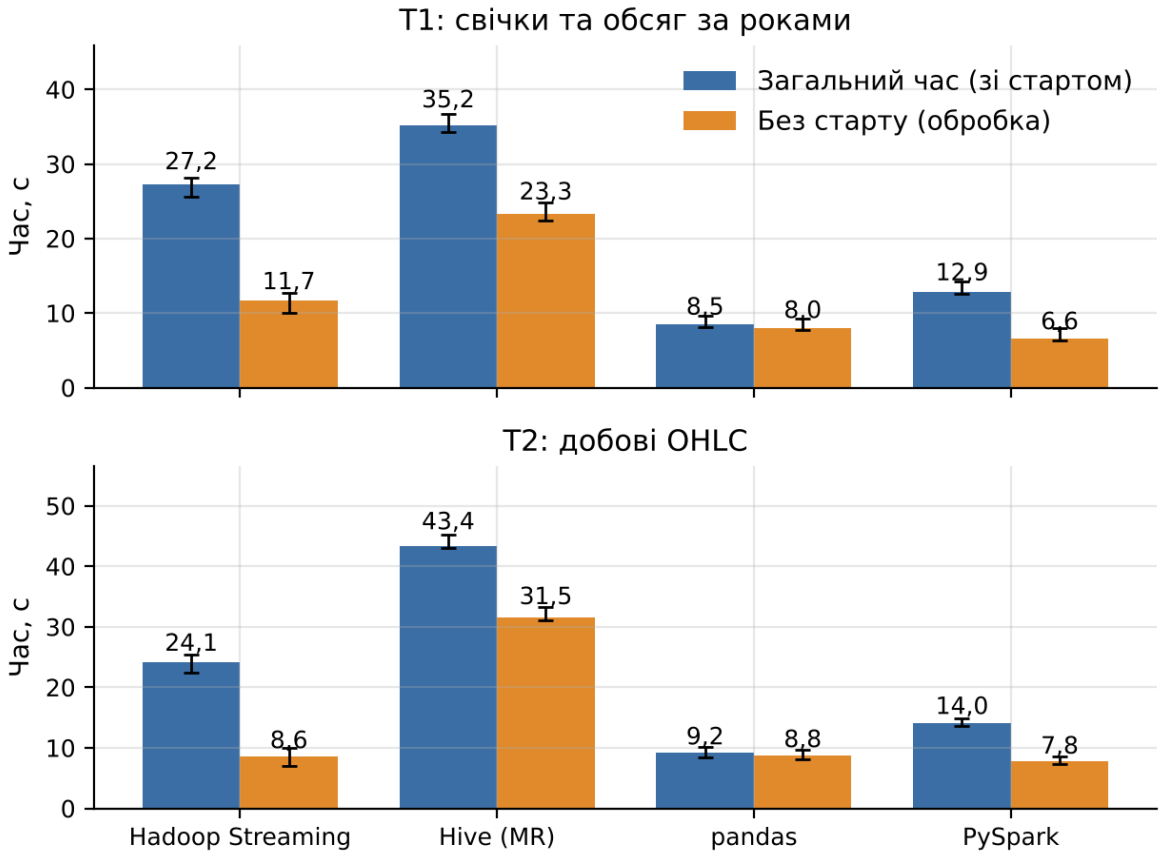


Рисунок 9 – Загальний час і час обробки T1 і T2 (медіана; відрізки – мінімум і максимум 5 запусків)

Таблиця 7 – Час виконання T1 і T2 на 7 816 537 рядках, с (медіана з 5 запусків, 4 vCPU, 15 ГБ)

Рушій	Задача	Загальний час	IQR	Старт	Обробка
Hadoop Streaming	T1	27,20	0,97	15,47	11,73
Hadoop Streaming	T2	24,08	1,74	15,47	8,62
Hive (рушій MR)	T1	35,19	0,83	11,88	23,31
Hive (рушій MR)	T2	43,38	0,38	11,88	31,49
Pandas	T1	8,46	0,21	0,43	8,03
Pandas	T2	9,21	1,37	0,43	8,78
PySpark local[*]	T1	12,88	0,44	6,29	6,58
PySpark local[*]	T2	14,04	0,88	6,29	7,75

IQR не перевищує 1,74 с, тому порядок рушіїв стійкий. Spark найшвидший за чистою обробкою (6,58 і 7,75 с), бо читає файл на 4 ядрах, але 6,29 с на створення сесії роблять його повільнішим за Pandas. Обробка T2 у Streaming (8,62 с) завдяки in-mapper combining швидша за T1 (11,73 с), де mapper видає запис на кожну свічку. Hive найповільніший: до старту CLI додаються компіляція плану і запуск задачі MapReduce.

7.4 Зручність розробки

Добові OHLC у Streaming потребували mapper і reducer на 43 і 26 рядків Python з ручною обробкою меж блоків і порядку записів; у Hive – один запит CTAS на 13 рядків HiveQL; у Pandas і Spark – один вираз `groupby`/`groupBy`.

Висновки

Порівняння з Pandas і Spark. Чотири рушії дали ідентичні результати. За медіаною з 5 запусків Pandas виконав задачі за 8,46 і 9,21 с, Spark – за 12,88 і 14,04 с, Hadoop Streaming – за 27,20 і 24,08 с, Hive – за 35,19 і 43,38 с. Різницю визначає старт: 15,47 с у Hadoop і 11,88 с у Hive проти 0,43 с у Pandas.

Переваги Hadoop. HDFS розбила файл на 3 блоки і контролює їх цілісність, а MapReduce автоматично розпаралелив обробку за блоками (3 data-local map-задачі) і коректно злив записи, розрізані межами блоків. На справжньому кластері реплікація і спекулятивне виконання компенсують збої та повільні вузли, але на одному вузлі лише споживають ресурси.

Обмеження. Налаштування вимагало узгодити версії (JDK 8 для Hive, конфлікт guava) і підібрати пам'ять контейнерів YARN. MapReduce вимагає ручної обробки порядку і меж блоків для Open і Close. Hive мовчки ігнорує невідомі властивості таблиці, як сталося з хибною назвою властивості пропуску заголовка.

Доцільність. Для 7,8 млн рядків на машині з 15 GiB RAM Hadoop не виправданий: дані вміщуються в пам'ять Pandas, а один вузол не дає ні масштабування, ні відмовостійкості. Він доцільний для пакетної обробки даних, що перевищують ресурси однієї машини і вже зберігаються в HDFS.