Міністерство освіти і науки України
Харківський національний університет радіоелектроніки

Кафедра штучного інтелекту

Дисципліна «Аналітика великих даних»

Практичне заняття №1

«Обробка великих даних у середовищі Hadoop (HDFS, MapReduce, Hive).»

Виконав:
ст. гр. ДМм-26-1
Зелінський В.С.

Прийняв:
Золотухін О.В.

Харків – 2026

Обробка великих даних у середовищі Hadoop (HDFS, MapReduce, Hive).

Мета роботи

Мета роботи: ознайомитися з архітектурою та принципами роботи платформи Apache Hadoop; навчитися працювати з розподіленою файловою системою HDFS; засвоїти базові прийоми обробки даних моделлю MapReduce; ознайомитися з використанням Hive для SQL-запитів до великих обсягів даних на прикладі повного набору хвилинних свічок BTC/USD (Bitcoin Historical Data, 7 816 537 рядків, 396,8 МБ) з порівнянням результатів, швидкодії і зручності роботи з Pandas та Spark.

Короткі теоретичні відомості

HDFS ділить файл на блоки фіксованого розміру (типово 128 МБ) і зберігає кожен блок на DataNode в кількох репліках. NameNode тримає в пам'яті лише метадані (дерево каталогів і розміщення блоків), а дані клієнт читає безпосередньо з DataNode.

YARN розподіляє ресурси: ResourceManager приймає задачі й виділяє контейнери (пам'ять і vCPU), NodeManager запускає їх на вузлі, а для кожної задачі стартує власний ApplicationMaster. JobHistoryServer зберігає лічильники завершених задач.

MapReduce описує обчислення двома функціями. Map обробляє один вхідний фрагмент (split, зазвичай один блок HDFS) і видає пари «ключ – значення». Фреймворк сортує і групує ці пари за ключем (shuffle), після чого reduce отримує всі значення одного ключа. Необов'язковий combiner виконує часткову агрегацію на боці map і зменшує обсяг shuffle; він коректний лише для асоціативних і комутативних операцій (сума, кількість, максимум), у яких формат входу збігається з форматом виходу. Проміжні результати пишуться на диск. Hadoop Streaming дозволяє писати map і reduce будь-якою мовою через stdin/stdout.

Hive зберігає схему таблиць у метасховищі (тут Derby), а дані – файлами в HDFS. Зовнішня таблиця (EXTERNAL TABLE) лише описує схему над каталогом, і DROP TABLE видаляє тільки метадані; керована таблиця володіє своїм каталогом у сховищі Hive, і її видалення знищує дані. Запит компілюється в одну чи кілька задач MapReduce.

Для набору BTC/USD агрегати зводяться до групування за ключем часу, але добові Open і Close залежать від порядку свічок за Timestamp.

Результати виконання практичного заняття

1 Архітектура Hadoop та принципи роботи HDFS

Кластер розгорнуто на одній віртуальній машині (4 vCPU, 15 GiB RAM, Intel Xeon 2,10 ГГц): Hadoop 3.3.6, Hive 3.1.3, Java 1.8.0_472, Python 3.13.18, pandas 3.0.5, PySpark 4.3.0. На одному вузлі працюють NameNode і DataNode (HDFS), ResourceManager і NodeManager (YARN) та JobHistoryServer. Команда `jps` показує всі п'ять демонів, звіт `hdfs dfsadmin -report` підтверджує одну живу DataNode і місткість 270 553 174 016 байт, а `hdfs getconf` – адресу `hdfs://localhost:9000`, реплікацію 1 і розмір блоку 134 217 728 байт.

2 Встановлення Hadoop у pseudo-distributed mode

Hadoop і Hive встановлено з архівів Apache скриптом `run_pz1.py` (додаток А.15). Демони запущено командами `hdfs --daemon start` і `yarn --daemon start` (як у `start-dfs.sh` і `start-yarn.sh`, але без ssh). Hive 3.1.3 працює лише з JDK 8, тому стек переведено на JDK 8, а guava 19 з Hive замінено новішою версією з Hadoop. Без вимкнення перевірки віртуальної пам'яті YARN знищував би контейнери Streaming, хоча фізичний пік map становив лише 605 048 832 байти. Ключові параметри подано в таблиці 1.

Таблиця 1 – Ключові параметри pseudo-distributed конфігурації

Параметр	Значення	Обґрунтування
fs.defaultFS	hdfs://localhost:9000	усе на одному вузлі
dfs.replication	1	одна DataNode
dfs.blocksize	134 217 728 (128 МБ)	CSV – 3 блоки
mapreduce.framework.name	yarn	UI і лічильники
nodemanager memory-mb / vcores	5120 / 4	решта RAM – демонам
map.memory.mb / java.opts	1024 / -Xmx768m	AM і 3 map у 5120 МБ
reduce.memory.mb / java.opts	1536 / -Xmx1024m	буфер злиття shuffle у купі JVM
mapreduce.job.reduces	1	один впорядкований файл
vmem-check-enabled	false	вірт. пік map 2 487 697 408 байт
maximum-am-resource-percent	0,8	при 0,1 AM не вміщується
map/reduce.speculative	true (типово)	див. підрозділ 4.2
hive.execution.engine	mr	Tez не встановлено

3 Завантаження набору даних у HDFS

Файл `btcusd_1-min_data.csv` (7 816 537 рядків даних і заголовок) завантажено в каталог `/user/root/btc/raw`. Робочі команди мають такий вигляд:

```
hdfs dfs -mkdir -p /user/root/btc/raw && hdfs dfs -put -f btcusd_1-
   min_data.csv /user/root/btc/raw/
hdfs dfs -stat "%b %r %o" /user/root/btc/raw/btcusd_1-min_data.csv
hdfs dfs -ls -R -h /user/root/btc/raw /user/root/btc/wc_in
hdfs dfs -cat /user/root/btc/raw/btcusd_1-min_data.csv | head -n 5
hdfs fsck /user/root/btc/raw -files -blocks -locations
```

Перевірку вмісту каталогів показано на рисунку 1.

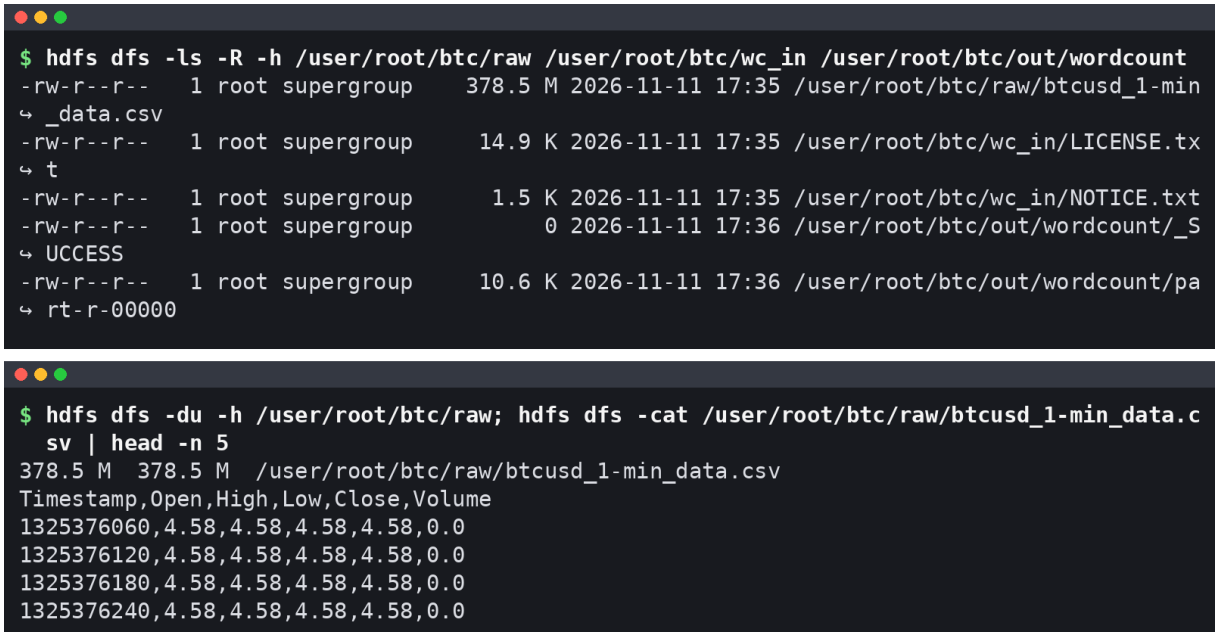


Рисунок 1 – Перевірка вмісту HDFS: ls -R, du і перші рядки CSV

Перші свічки 01.01.2012 мають ціну 4,58 і нульовий обсяг. Блоки за `hdfs fsck` зведено в таблицю 2.

Таблиця 2 – Блоки файлу btcusd_1-min_data.csv у HDFS

Блок	Ідентифікатор	Довжина, байт	Реплік
0	blk_1073742503	134 217 728	1
1	blk_1073742504	134 217 728	1
2	blk_1073742505	128 414 038	1
Разом	–	396 849 494	–

Сума довжин дорівнює розміру файлу, fsck дає статус HEALTHY без недореплікованих і пошкоджених блоків. Той самий стан видно у веб-інтерфейсі NameNode (рисунок 2).

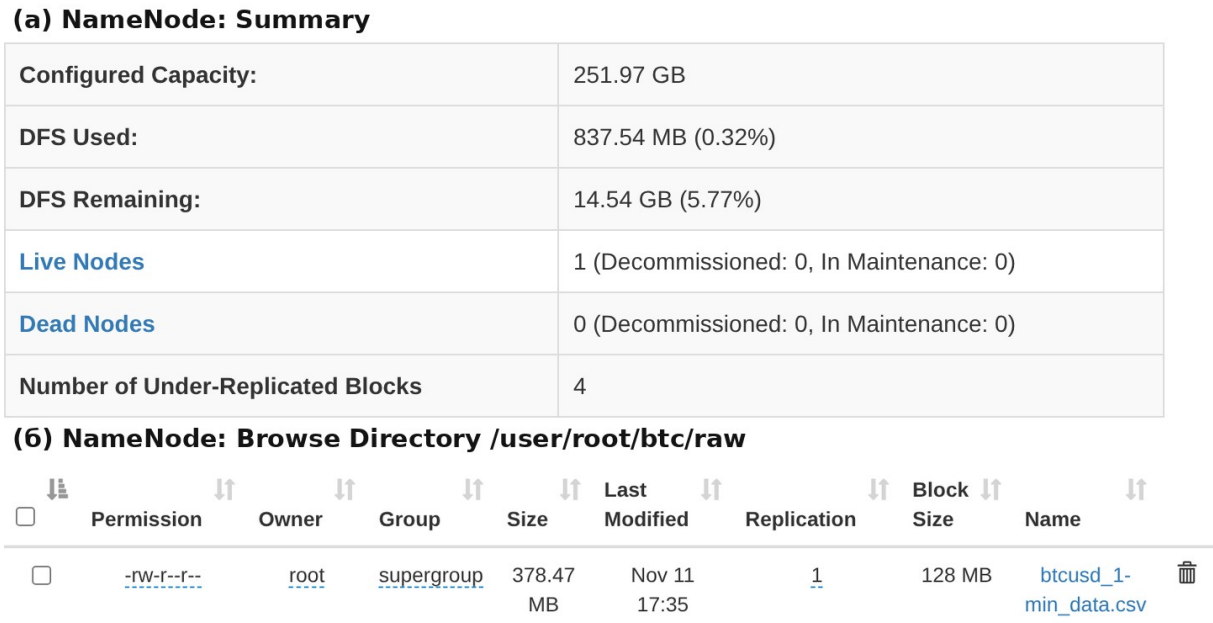


Рисунок 2 – Веб-інтерфейс NameNode (:9870): зведення і каталог /user/root/btc/raw

Розмір 378.47 MB – це 396 849 494 байти в MiB; DFS Used 837,54 MB включає ще копію файлу для керованої таблиці Hive і результати задач.

4 Задачі MapReduce

4.1 WordCount як перевірка кластера

Стандартний приклад `wordcount` запущено над файлами `LICENSE.txt` і `NOTICE.txt` для перевірки кластера. Задача прочитала 304 рядки, combiner скоротив 1 879 пар до 798, на виході 748 різних слів («the» – 107, «of» – 68). Початок файлу результату в HDFS наведено на рисунку 3.

```
$ hdfs dfs -cat /user/root/btc/out/wordcount/part-r-00000 | head -n 15
"AS            2
"Contribution"  1
"Contributor"   1
"Derivative     1
"Legal          1
"License"       1
"License");     1
"Licensor"      1
"NOTICE"        1
"Not            1
"Object"        1
"Source"        1
"Work"          1
"You"           1
"Your")         1
```

Рисунок 3 – Результат WordCount у HDFS (part-r-00000)

Слова розділено лише пробілами, тож «"License"» і «"License");» – різні ключі; ланцюжок HDFS – YARN – MapReduce працює.

4.2 Кількість свічок і обсяг торгів за роками

Перша задача Hadoop Streaming рахує для кожного року UTC кількість свічок і сумарний обсяг. Mapper `mapper_year.py` (додаток А.1) відкидає заголовок і неповні рядки і видає `рік \t 1 \t Volume`, обчислюючи рік UTC через `time.gmtime`. Reducer `reducer_year.py` (додаток А.2) сумує кількість і обсяг; його вхід і вихід мають однаковий формат, тому той самий скрипт використано як combiner:

```
hadoop jar hadoop-streaming-3.3.6.jar -D mapreduce.job.reduces=1 \
  -files mapper_year.py,reducer_year.py -mapper 'python3 mapper_year.py' \
  -combiner 'python3 reducer_year.py' -reducer 'python3 reducer_year.py' \
  -input /user/root/btc/raw -output /user/root/btc/out/mr_yearly
```

Результат задачі в HDFS показано на рисунку 4.

```
$ hdfs dfs -cat /user/root/btc/out/mr_yearly/part-*
2012  527039  567948.5559594971
2013  525600  5031142.917424014
2014  525600  5024184.243438736
2015  525600  5525344.448194008
2016  527040  1992257.9791814238
2017  525600  4698752.659328289
2018  525600  3932327.0095752697
2019  525600  2994600.1285279035
2020  527040  3074321.04488984
2021  525600  1802997.8350474772
2022  525600  833815.3460086032
2023  525600  681687.3219227374
2024  527040  807909.8801162983
2025  525600  639945.8102074597
2026  452378  636371.3466095605
```

Рисунок 4 – Результат задачі mr_yearly у HDFS: рік, кількість свічок, обсяг

Рядків 15, по одному на рік. Hadoop створив 3 splits і прочитав 396 857 686 байт, трохи більше за розмір файлу, бо reader дочитує рядок за межею split. Launched map tasks = 4 при Killed map tasks = 1 означає спекулятивну копію повільної map-задачі. На одному вузлі вона лише конкурує з оригіналом за ті самі 4 ядра, тому типово ввімкнене спекулятивне виконання тут додає розкиду часу.

4.3 Добові OHLC

Друга задача будує добові свічки за правилом Open = first, High = max, Low = min, Close = last, Volume = sum, де first і last визначаються за Timestamp. Combiner тут не підходить, бо Open і Close залежать від порядку, тому в `mapper_ohlc.py` (додаток А.3) застосовано in-mapper combining: mapper тримає для кожної доби свого split найранішу і найпізнішу свічку, максимум, мінімум і суму обсягу та видає один запис на добу з мітками часу.

Межа блоку може розрізати добу, а порядок записів усередині ключа не гарантовано, тому `reducer_ohlc.py` (додаток А.4) явно обирає запис із найменшим і найбільшим часом:

```
for day, grp in groupby(parse(sys.stdin), key=itemgetter(0)):
    parts = list(grp)
    first = sorted(parts, key=itemgetter(1))[0]   # найраніша свічка доби
    last = sorted(parts, key=itemgetter(7))[-1]   # найпізніша свічка доби
    hi = max(parts, key=itemgetter(3))
    lo = min(parts, key=itemgetter(5))
```

Пари mapper – reducer попередньо перевірено конвеєром `cat | mapper | sort | reducer` на 200 000 рядках. Отримано 5 429 діб; неповні лише перша (1 439 свічок) і остання (218 свічок). Для обвалу 19.05.2021 результат містить Open 42 900,85, High 43 601,63, Low 30 066,00, Close 36 780,43.

4.4 Лічильники задач

Лічильники обох задач зведено в таблицю 3 (джерело – `mr_counters_extended.csv`, виділений з журналів задач).

Таблиця 3 – Лічильники Streaming-задач над повним CSV

Лічильник	mr_yearly	mr_daily_ohlc
Map input records	7 816 538	7 816 538
Map output records	7 816 537	5 431
Map output bytes	127 655 772	490 246
Combine input / output records	7 816 537 / 17	0 / 0
Reduce shuffle bytes	567	501 126
Reduce input records	17	5 431
Reduce output records	15	5 429

Map input records містить ще заголовок. Combiner стиснув 127 655 772 байти виходу map до 567 байт shuffle, а in-mapper combining скоротив вихід map з 7,8 млн до 5 431 запису. Значення 17 і 5 431 замість 15 і 5 429 означають, що межі блоків розрізали по одному року і одній добі, а reducer злив ці часткові записи. Лічильники добової задачі в JobHistory наведено на рисунку 5.

	Name	Map	Reduce	Total
Job Counters	Data-local map tasks	0	0	3
	Launched map tasks	0	0	3
	Name	**Map**	**Reduce**	**Total**
Map-Reduce Framework	Map input records	7,816,538	0	7,816,538
	Map output records	5,431	0	5,431
	Reduce input groups	0	5,429	5,429
	Shuffled Maps	0	3	3
	Spilled Records	5,431	5,431	10,862

Рисунок 5 – Лічильники задачі mr_daily_ohlc у веб-інтерфейсі JobHistory (:19888)

Shuffled Maps = 3 і Data-local map tasks = 3 підтверджують, що reducer отримав дані від трьох map-задач, і кожна читала свій блок локально (у річній задачі цей лічильник дорівнює 4 разом зі спекулятивною копією).

5 Таблиця Hive над даними в HDFS

5.1 Зовнішня таблиця

Hive підключено до Hadoop через `HADOOP_HOME`, метасховище Derby створено командою `schematool -dbType derby -initSchema`. Таблицю `btc.candles` створено як зовнішню над каталогом із CSV (додаток А.5) з властивістю `"skip.header.line.count"="1"`, яка пропускає рядок

заголовка. Опис таблиці наведено на рисунку 6; усі HQL-скрипти виконано командою `hive -S -f`.

```
$ hive -S -f hive_01b_describe.hql | sed '/^# Storage Information/,$d' | grep -vE '^(Owner
  Type|Owner|CreateTime|LastAccessTime|Retention):|bucketing|transient'
# фрагмент виводу: DESCRIBE FORMATTED candles (без Storage Information)
# col_name                      data_type                                   comment
ts                              double
open                            double
high                            double
low                             double
close                           double
volume                          double

# Detailed Table Information
Database:                       btc
Location:                       hdfs://localhost:9000/user/root/btc/raw
Table Type:                     EXTERNAL_TABLE
Table Parameters:
                                EXTERNAL                                    TRUE
                                numFiles                                    1
                                skip.header.line.count                      1
                                totalSize                                   396849494
```

Рисунок 6 – Опис зовнішньої таблиці candles (DESCRIBE FORMATTED)

Тип таблиці – EXTERNAL_TABLE, totalSize дорівнює розміру файлу. Подання обчислює дату UTC як `date_add('1970-01-01', floor(ts / 86400))` і відкидає неповні рядки (рисунок 7).

```
$ hive -S -f hive_02_select.hql
ts            open          high    low     close   volume
1.32537606E9  4.58          4.58    4.58    4.58    0.0
1.32537612E9  4.58          4.58    4.58    4.58    0.0
1.32537618E9  4.58          4.58    4.58    4.58    0.0
1.32537624E9  4.58          4.58    4.58    4.58    0.0
1.3253763E9   4.58          4.58    4.58    4.58    0.0
trade_date    ts            open    high    low     close   volume
2014-10-05    1.41252396E9  306.86  306.86  294.0   299.38  5853.85216588
2014-10-06    1.41257922E9  300.0   300.0   299.98  300.0   4545.89384565
2014-04-10    1.3971135E9   413.24  416.0   400.11  405.0   4111.87610626
2015-01-25    1.4221974E9   250.44  255.0   241.33  250.43  3691.01210311
2014-12-04    1.41769422E9  365.56  374.32  360.0   369.05  3650.66851047
2014-02-10    1.39203006E9  570.0   570.0   544.0   544.0   3379.75082937
2014-02-24    1.39324902E9  547.9   547.9   520.0   520.0   3134.58848401
2014-10-06    1.41257874E9  300.0   300.0   299.99  299.99  3133.60636042
2012-11-05    1.35215268E9  10.56   10.56   10.55   10.55   2958.47757418
2014-04-10    1.39714278E9  401.99  402.0   394.7   394.7   2939.35619442
raw_rows
7816537
total_candles
7816537
```

Рисунок 7 – Вибірка з таблиці candles, найбільші хвилинні свічки та COUNT(*)

`SELECT * FROM candles LIMIT 5` починається з першої свічки 01.01.2012 00:01 UTC, рядка NULL немає. `COUNT(*)` по таблиці (`raw_rows`) і по поданню (`total_candles`) однаково дорівнюють 7 816 537: заголовок

пропускає сама таблиця, а неповних рядків у файлі немає. Для `ts` тип BIGINT дав би читабельніший вивід, ніж `1.32537606E9`.

У першій версії DDL властивість мала хибну назву `skip.header.line.number`; Hive мовчки ігнорував її, і заголовок CSV читався як рядок із NULL. Після виправлення запити Hive перезапущено; результати побайтно збіглися з попередніми, бо подання `candles_v` відкидало цей рядок і раніше; рядок NULL був видимий лише у простій вибірці без подання, а агрегати від нього не залежали.

5.2 Завантаження даних у керовану таблицю

Для кроку «Завантажити дані в таблицю» копію CSV з `/user/root/btc/load_src` завантажено в керовану таблицю `candles_managed` командою `LOAD DATA INPATH` (додаток А.14, рисунок 8).

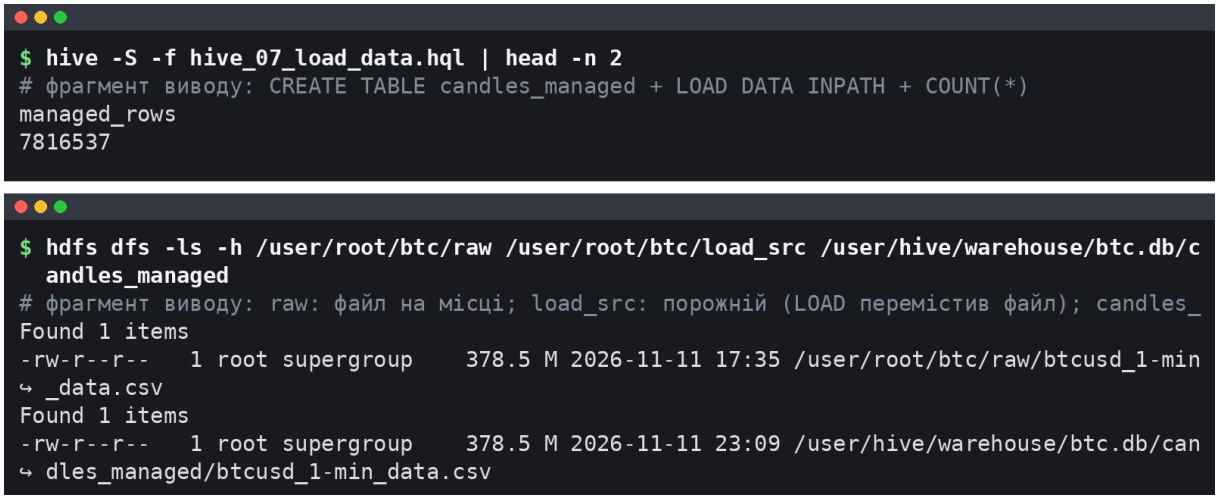


Рисунок 8 – LOAD DATA INPATH у керовану таблицю і стан HDFS після завантаження

Таблиця містить 7 816 537 рядків, каталог `load_src` порожній, а файл опинився у `/user/hive/warehouse/btc.db/candles_managed`: LOAD DATA INPATH переміщує файл у межах HDFS, не копіюючи його. Основні запити виконано над зовнішньою таблицею, бо `DROP TABLE` керованої таблиці видалив би й дані.

6 SQL-запити в Hive

6.1 Групування за роками і місяцями

Запит `hive_03a_yearly.hql` (додаток А.8) групує подання за `year(trade_date)` і рахує кількість свічок, суму обсягу, середню ціну закриття, максимум High і мінімум Low. Результат Hive подано в таблиці 4.

Таблиця 4 – Річні агрегати Hive (обсяг округлено до 0,01 BTC, ціни – до 0,01 USD)

Рік	Свічок	Обсяг, BTC	Сер. Close	Max High	Min Low
2012	527 039	567 948,56	8,23	16,41	3,80
2013	525 600	5 031 142,92	187,43	1 163,00	12,77
2014	525 600	5 024 184,24	525,57	995,00	275,00
2015	525 600	5 525 344,45	272,25	502,00	152,40
2016	527 040	1 992 257,98	565,83	980,74	352,00
2017	525 600	4 698 752,66	3 948,33	19 666,00	751,34
2018	525 600	3 932 327,01	7 524,76	17 234,99	3 122,28
2019	525 600	2 994 600,13	7 352,19	13 880,00	3 322,19
2020	527 040	3 074 321,04	11 074,63	29 300,00	3 850,00
2021	525 600	1 802 997,84	47 386,18	69 000,00	27 734,00
2022	525 600	833 815,35	28 228,66	48 234,00	15 479,00
2023	525 600	681 687,32	28 811,76	44 729,00	16 496,00
2024	527 040	807 909,88	65 895,12	108 364,00	38 505,00
2025	525 600	639 945,81	101 639,98	126 272,00	74 434,00
2026	452 378	636 371,35	74 103,97	97 939,00	57 734,63

Кількість свічок за всі 15 років збігається з результатом MapReduce до одиниці, а обсяги відрізняються лише в останніх знаках (2014 рік: 5 024 184,243438596 у Hive проти 5 024 184,243438736 у MapReduce) через порядок підсумовування. Обсяг максимальний у 2015 році; у 2012 році свічок 527 039, бо перша має час 00:01. Повні роки мають 525 600 або 527 040 хвилин (високосні 2016, 2020, 2024), тобто хвилинна сітка повна, але торгівля не безперервна: 1 312 419 свічок (16,79 %) мають нульовий обсяг. Це заповнені пропуски з ціною попереднього закриття (перші рядки на рисунку 1); їх збережено, тому вони входять у кількість свічок і середню ціну закриття. Місячний розріз (`GROUP BY year, month`, 179 груп) має пік у листопаді 2013 року (965 986,91 BTC).

6.2 Добова таблиця і топ-10 діб

Добову таблицю `daily_ohlc` створено запитом CTAS (додаток А.10). Open і Close обчислено без віконних функцій: Hive порівнює

структури лексикографічно, починаючи з першого поля, а `ts` унікальний у межах доби, тому мінімум структури `(ts, open)` дає Open найранішої свічки:

```
SELECT trade_date,
       min(struct(ts, open)).col2  AS open,
       max(high) AS high, min(low) AS low,
       max(struct(ts, close)).col2 AS close,
       sum(volume) AS volume, count(*) AS candles
FROM candles_v GROUP BY trade_date;
```

Таблиця має 5 429 рядків, як і результат MapReduce. На її основі виконано два запити топ-10: за сумарним обсягом (додаток А.11) і за амплітудою High − Low через подання `daily_range_v` (додаток А.12). Результати подано в таблиці 5.

Таблиця 5 – Топ-10 діб за обсягом торгів і за амплітудою High − Low (Hive)

№	Доба (обсяг)	Обсяг, BTC	Доба (амплітуда)	High − Low, USD
1	2013-12-18	137 070,18	2021-05-19	13 535,63
2	2015-01-14	124 188,89	2025-10-10	12 899,00
3	2014-02-25	115 761,99	2021-12-04	11 910,27
4	2015-11-04	105 959,26	2026-02-06	11 743,00
5	2015-01-15	83 488,42	2024-12-05	11 555,00
6	2013-12-07	79 852,42	2025-02-03	11 039,00
7	2015-11-03	77 212,78	2026-02-05	10 975,00
8	2014-02-10	71 860,54	2021-02-22	10 164,19
9	2013-11-19	71 560,95	2025-03-02	10 123,00
10	2018-02-06	70 961,37	2021-09-07	10 056,46

Рейтинги не перетинаються. Дев'ять діб з найбільшим обсягом припадають на 2013–2015 роки, коли BTC коштував сотні доларів (18.12.2013 ціна впала з 675,00 до 382,21). Абсолютна амплітуда зростає з ціною, тому її топ-10 належить 2021–2026 рокам на чолі з обвалом 19.05.2021; для порівняння різних років її треба нормувати на ціну відкриття.

Під час розбору виводу виявилося, що при `hive.cli.print.header=true` інструкція `CREATE VIEW` друкує назви стовпців подання ще до заголовка результату `SELECT`. Кожен запит, що потребує обчислень, Hive виконав окремим застосунком YARN (рисунок 9).

Name	Application Type	State	FinalStatus
SELECT COUNT(*) AS managed...candles_m…	MAPREDUCE	FINISHED	SUCCEEDED
SELECT trade_date, high, low, price_ran...10 …	MAPREDUCE	FINISHED	SUCCEEDED
SELECT trade_date, open, high, low, clo...10 …	MAPREDUCE	FINISHED	SUCCEEDED
SELECT * FROM daily_ohlc ORDER BY trad…	MAPREDUCE	FINISHED	SUCCEEDED
CREATE TABLE daily_ohlc STORED ...trade_…	MAPREDUCE	FINISHED	SUCCEEDED
SELECT year(trade_date) AS yr, ...mn (Stage-2)	MAPREDUCE	FINISHED	SUCCEEDED
SELECT year(trade_date) AS yr, ...mn (Stage-1)	MAPREDUCE	FINISHED	SUCCEEDED
SELECT year(trade_date) AS yr, ...yr (Stage-2)	MAPREDUCE	FINISHED	SUCCEEDED
SELECT year(trade_date) AS yr, ...yr (Stage-1)	MAPREDUCE	FINISHED	SUCCEEDED
SELECT COUNT(*) AS total_candles...candle…	MAPREDUCE	FINISHED	SUCCEEDED
SELECT COUNT(*) AS raw_rows FROM can…	MAPREDUCE	FINISHED	SUCCEEDED
SELECT trade_date, ts, open, high, low,...10 (…	MAPREDUCE	FINISHED	SUCCEEDED

Рисунок 9 – Застосунки Hive у веб-інтерфейсі YARN ResourceManager (:8088)

Усі 12 застосунків завершилися зі статусом SUCCEEDED. Запити за роками і за місяцями мають по дві стадії (Stage-1 – GROUP BY, Stage-2 – ORDER BY), а `SELECT * FROM candles LIMIT 5` у списку відсутній: Hive виконав його простим читанням файлу без MapReduce.

7 Зручність та ефективність: порівняння з Pandas і Spark

7.1 Звірка результатів

Ті самі дві агрегації (T1 – кількість і обсяг за роками, T2 – добові OHLC) повторено в Pandas (`groupby` після сортування за Timestamp, додатки А.16 і А.17) і в PySpark local[*]. Підсумки звірки наведено в таблиці 6.

Таблиця 6 – Звірка результатів MapReduce, Hive, Pandas і Spark

Порівняння	Рядків	Збіг	Примітка
Hive – MapReduce, роки	15 / 15	так	обсяг з допуском 10^{-9}
Hive – MapReduce, доби	5 429 / 5 429	так	OHLC з допуском 10^{-12}
MapReduce – Pandas, роки	15 / 15	так	відн. різниця $1{,}00 \cdot 10^{-13}$
MapReduce – Pandas, доби	5 429 / 5 429	так	OHLC без розбіжностей
Hive – Pandas, роки	15 / 15	так	–
Hive – Pandas, топ-10 за обсягом	10 / 10	так	ті самі доби
Hive – Pandas, топ-10 за High − Low	10 / 10	так	ті самі доби
Spark – Pandas, роки і доби	15 і 5 429	так	–

Збіг Hive – Pandas і Spark – MapReduce по добах випливає транзитивно з прямих звірок. Усі рушії обчислюють те саме, тож порівняння часу коректне.

7.2 Методика вимірювання часу

Вимірювання виконано скриптом `bench_all.py` з HiveQL-файлами `bench_yearly.hql` і `bench_daily.hql` (додатки А.17–А.19). Вимірювався повний настінний час від запуску нового процесу до записаного результату, включно зі стартом JVM, CLI Hive, інтерпретатора Python або SparkSession (local[*], драйвер 3 ГБ, 8 shuffle-розділів). Hadoop і Hive читають і пишуть HDFS (Hive для T1 без ORDER BY, як і Streaming), Pandas і Spark – локальний диск; ця асиметрія збережена свідомо, бо HDFS тут працює на тому самому диску.

Старт кожного рушія виміряно окремо: `python3 -c "import pandas"`, створення й зупинка SparkSession, `hive -S -e "select 1"` і порожня map-only задача Streaming на файлі з одного рядка. «Обробка» – медіана загального часу мінус медіана старту; старт Hive не містить запуску задачі MapReduce.

Вимірювання почалися після очікування тиші: щохвилинне опитування до трьох поспіль значень loadavg (1 хв) < 1,5 без сторонніх java- і spark-процесів; умову виконано на опитуванні 52 при loadavg 1,28. Далі виконано одне прогрівальне коло, яке відкинуто, і 5 вимірюваних кіл. У кожному колі запускалися всі 8 пар «рушій – задача» і 4 вимірювання старту з циклічним зсувом початку, щоб дрейф навантаження і кеш ОС діяли на рушії однаково. Усі 48 результатів T1/T2 поза часом звірено з Pandas. Loadavg перед запусками – 1,44–3,22 (медіана 2,43), вільна пам'ять – 10,5–11,1 ГБ.

7.3 Результати вимірювання

Медіани з 5 вимірювань разом із мінімумом і максимумом показано на рисунку 10, а медіани і міжквартильний розмах (IQR) загального часу – в таблиці 7.

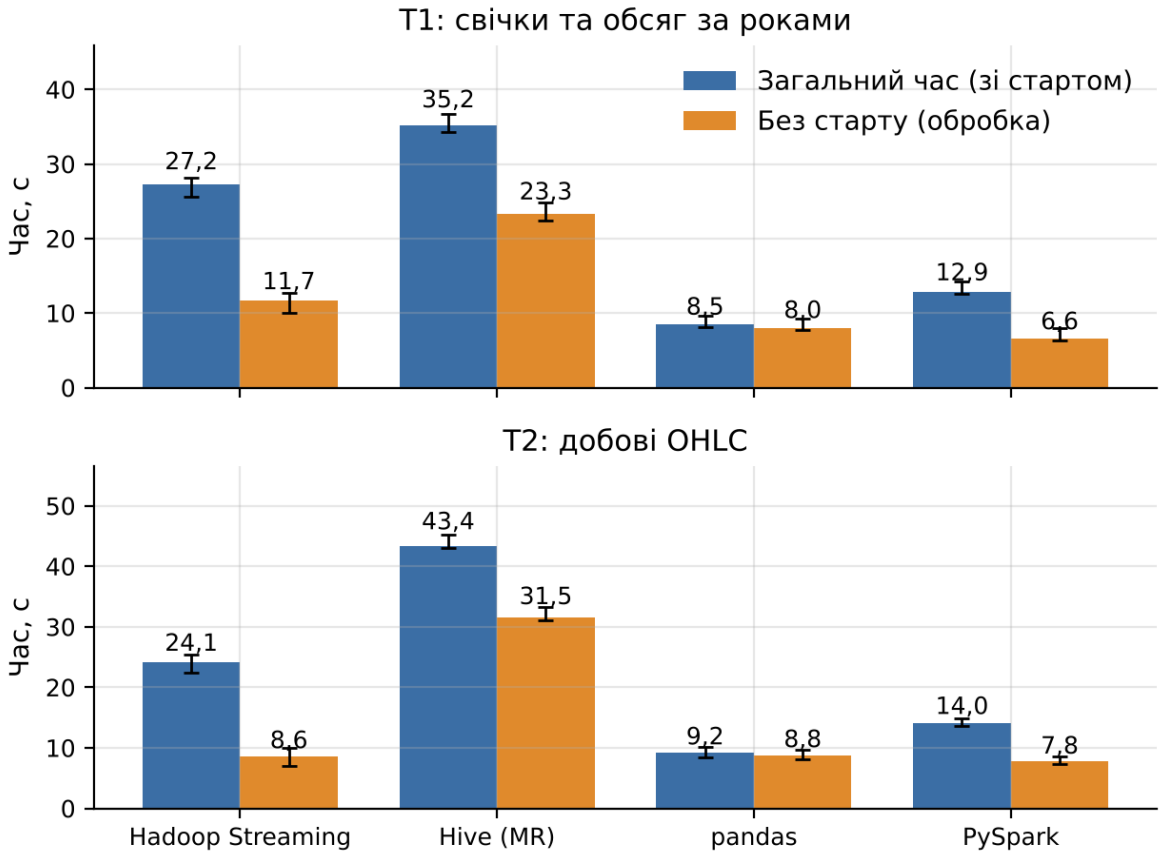


Рисунок 10 – Загальний час і час обробки T1 і T2 (медіана; відрізки – мінімум і максимум 5 запусків)

Таблиця 7 – Час виконання T1 і T2 на 7 816 537 рядках, с (медіана з 5 запусків, 4 vCPU, 15 ГБ)

Рушій	Задача	Загальний час	IQR	Старт	Обробка
Hadoop Streaming	T1	27,2	0,97	15,47	11,73
Hadoop Streaming	T2	24,08	1,74	15,47	8,62
Hive (рушій MR)	T1	35,19	0,83	11,88	23,31
Hive (рушій MR)	T2	43,38	0,38	11,88	31,49
Pandas	T1	8,46	0,21	0,43	8,03
Pandas	T2	9,21	1,37	0,43	8,78
PySpark local[*]	T1	12,88	0,44	6,29	6,58
PySpark local[*]	T2	14,04	0,88	6,29	7,75

IQR не перевищує 1,74 с, тому порядок рушіїв стійкий. На 7,8 млн рядків і 396,8 МБ на одній 4-ядерній машині найшвидший за загальним часом Pandas (8,46 і 9,21 с), старт якого займає 0,43 с. Spark за чистою обробкою найшвидший (6,58 і 7,75 с), бо читає файл на 4 ядрах, але 6,29 с на створення сесії роблять його повільнішим за Pandas. Hadoop Streaming витрачає 15,47 с на старт; його обробка T2 (8,62 с) завдяки in-mapper combining швидша за T1 (11,73 с), де mapper видає запис на кожну свічку.

Hive найповільніший: до старту CLI додаються компіляція плану і запуск задачі MapReduce.

Отже, тут час Hadoop і Hive визначають фіксовані витрати на JVM і контейнери YARN, а не обчислення.

7.4 Зручність розробки

Добові OHLC у Streaming потребували mapper і reducer на 43 і 26 рядків Python без коментарів, з ручною обробкою меж блоків і порядку записів; у Hive – один запит CTAS на 13 рядків HiveQL; у Pandas і Spark – один вираз `groupby`/`groupBy`.

Висновки

Порівняння з Pandas і Spark. Чотири рушії дали ідентичні результати. За медіаною з 5 запусків Pandas виконав задачі за 8,46 і 9,21 с, Spark – за 12,88 і 14,04 с, Hadoop Streaming – за 27,2 і 24,08 с, Hive – за 35,19 і 43,38 с. Різницю визначає старт: 15,47 с у Hadoop і 11,88 с у Hive проти 0,43 с у Pandas.

Переваги Hadoop. HDFS розбила файл на 3 блоки і контролює їх цілісність, а MapReduce автоматично розпаралелив обробку за блоками (3 data-local map-задачі) і коректно злив записи, розрізані межами блоків. На справжньому кластері реплікація і спекулятивне виконання компенсують збої та повільні вузли, але на одному вузлі лише споживають ресурси.

Обмеження. Налаштування вимагало узгодити версії (JDK 8 для Hive, конфлікт guava) і підібрати пам'ять контейнерів YARN. MapReduce вимагає ручної обробки порядку і меж блоків для Open і Close. Hive мовчки ігнорує невідомі властивості таблиці, як сталося з хибною назвою властивості пропуску заголовка.

Доцільність. Для 7,8 млн рядків на машині з 15 GiB RAM Hadoop не виправданий: дані вміщуються в пам'ять Pandas, а один вузол не дає ні масштабування, ні відмовостійкості. Він доцільний для пакетної обробки даних, що перевищують ресурси однієї машини і вже зберігаються в HDFS.

Додаток А. Лістинг програми

Допоміжні скрипти (рендер термінальних скріншотів, захоплення веб-інтерфейсів, побудова рисунків) зберігаються в репозиторії роботи і до лістингу не включені.

А.1 Файл mapper_year.py – mapper річної задачі Hadoop Streaming

```
#!/usr/bin/env python3
# -*- coding: utf-8 -*-
"""
mapper_year.py - Mapper (Hadoop Streaming) для підрахунку кількості хвилинних
свічок та сумарного обсягу торгів за роками.

Вхід  (stdin) : рядки CSV  Timestamp,Open,High,Low,Close,Volume
Вихід (stdout): рік <TAB> 1 <TAB> Volume

Timestamp - це unix-секунди в UTC, тому рік обчислюється через time.gmtime
(без залежності від часового поясу машини).
Заголовок і некоректні рядки пропускаються. Правило фільтрації таке саме,
як у Pandas (dropna за всіма 6 стовпцями), щоб результати можна було зіставити.
"""
import sys
import time


def main():
    year_by_day = {}          # кеш: номер доби -> рік (щоб не викликати gmtime
   для кожного рядка)
    for line in sys.stdin:
        p = line.strip().split(",")
        if len(p) < 6:
            continue
        try:
            vals = [float(x) for x in p[:6]]   # на заголовку тут буде ValueError
        except ValueError:
            continue
        if any(v != v for v in vals):          # NaN != NaN
            continue
        day = int(vals[0]) // 86400
        year = year_by_day.get(day)
        if year is None:
            year = time.gmtime(day * 86400).tm_year
            year_by_day[day] = year
        sys.stdout.write("%d\t1\t%s\n" % (year, p[5]))


if __name__ == "__main__":
    main()
```

А.2 Файл reducer_year.py – reducer і combiner річної задачі

```
#!/usr/bin/env python3
# -*- coding: utf-8 -*-
"""
reducer_year.py - Reducer (і одночасно Combiner) для підрахунку свічок і обсягу
   за роками.

Вхід  (stdin) : рік <TAB> кількість <TAB> обсяг   (відсортовано за ключем - рік)
Вихід (stdout): рік <TAB> сумарна_кількість <TAB> сумарний_обсяг

Формат виходу збігається з форматом входу, тому цей самий скрипт можна
використати як combiner (часткове згортання на стороні mapper).
"""
import sys
from itertools import groupby
```

```
from operator import itemgetter


def parse(stream):
    for line in stream:
        p = line.rstrip("\n").split("\t")
        if len(p) != 3:
            continue
        try:
            yield p[0], int(p[1]), float(p[2])
        except ValueError:
            continue


def main():
    for year, grp in groupby(parse(sys.stdin), key=itemgetter(0)):
        count = 0
        volume = 0.0
        for _, c, v in grp:
            count += c
            volume += v
        sys.stdout.write("%s\t%d\t%r\n" % (year, count, volume))


if __name__ == "__main__":
    main()
```

A.3 Файл mapper_ohlc.py – mapper добових OHLC з in-mapper combining

```
#!/usr/bin/env python3
# -*- coding: utf-8 -*-
"""
mapper_ohlc.py - Mapper для побудови добових OHLC зі свічок 1 хв.

Вхід  (stdin) : CSV  Timestamp,Open,High,Low,Close,Volume
Вихід (stdout): доба <TAB> ts_перша <TAB> open <TAB> high <TAB> low
                <TAB> ts_остання <TAB> close <TAB> volume <TAB> кількість

Застосовано in-mapper combining: у межах одного split зберігається часткова
агрегація по добі (перша/остання свічка за Timestamp, max High, min Low, сума
   Volume),
а в кінці виводиться один запис на добу. Це на два порядки зменшує обсяг shuffle.
Оскільки блок HDFS може розрізати добу навпіл, reducer все одно зливає часткові
записи і сам впорядковує їх за часом.
Значення open/high/low/close передаються як вихідні текстові токени (без втрати
   точності).
"""
import sys
import time


def main():
    day_name = {}     # номер доби -> рядок YYYY-MM-DD
    acc = {}          # доба -> [ts_first, open_s, ts_last, close_s, high_f,
  high_s, low_f, low_s, vol, n]
    for line in sys.stdin:
        p = line.strip().split(",")
        if len(p) < 6:
            continue
        try:
            ts, o, h, l, c, v = [float(x) for x in p[:6]]
        except ValueError:
            continue   # заголовок
        if ts != ts or o != o or h != h or l != l or c != c or v != v:
            continue
        d = int(ts) // 86400
        name = day_name.get(d)
        if name is None:
```

```
            name = time.strftime("%Y-%m-%d", time.gmtime(d * 86400))
            day_name[d] = name
        a = acc.get(name)
        if a is None:
            acc[name] = [ts, p[1], ts, p[4], h, p[2], l, p[3], v, 1]
            continue
        if ts < a[0]:                # раніша свічка -> нове Open
            a[0] = ts
            a[1] = p[1]
        if ts > a[2]:                # пізніша свічка -> нове Close
            a[2] = ts
            a[3] = p[4]
        if h > a[4]:
            a[4] = h
            a[5] = p[2]
        if l < a[6]:
            a[6] = l
            a[7] = p[3]
        a[8] += v
        a[9] += 1
    for name, a in acc.items():
        sys.stdout.write("%s\t%r\t%s\t%s\t%s\t%r\t%s\t%r\t%d\n" %
                         (name, a[0], a[1], a[5], a[7], a[2], a[3], a[8], a[9]))


if __name__ == "__main__":
    main()
```

A.4 Файл reducer_ohlc.py – reducer добових OHLC

```
#!/usr/bin/env python3
# -*- coding: utf-8 -*-
"""
reducer_ohlc.py - Reducer: зливає часткові записи доби в підсумкову свічку OHLCV.

Вхід  (stdin) : доба <TAB> ts_перша <TAB> open <TAB> high <TAB> low
                <TAB> ts_остання <TAB> close <TAB> volume <TAB> кількість
Вихід (stdout): доба <TAB> open <TAB> high <TAB> low <TAB> close <TAB> volume
   <TAB> кількість_свічок

Правила (коректний OHLC):
  open   = Open першої за Timestamp свічки доби,
  high   = max(High), low = min(Low),
  close  = Close останньої за Timestamp свічки доби,
  volume = сума Volume.
Hadoop сортує лише за ключем (доба), порядок часткових записів усередині доби
не гарантований, тому reducer явно сортує їх за ts_перша / ts_остання.
"""
import sys
from itertools import groupby
from operator import itemgetter


def parse(stream):
    for line in stream:
        p = line.rstrip("\n").split("\t")
        if len(p) != 9:
            continue
        try:
            yield (p[0], float(p[1]), p[2], float(p[3]), p[3], float(p[4]), p[4],
                   float(p[5]), p[6], float(p[7]), int(p[8]))
        except ValueError:
            continue


def main():
    # кортеж: 0 доба, 1 ts_first, 2 open_s, 3 high_f, 4 high_s, 5 low_f, 6 low_s,
    #         7 ts_last, 8 close_s, 9 volume, 10 n
    for day, grp in groupby(parse(sys.stdin), key=itemgetter(0)):
        parts = list(grp)
```

```
        first = sorted(parts, key=itemgetter(1))[0]        # найраніша свічка
  доби
        last = sorted(parts, key=itemgetter(7))[-1]        # найпізніша свічка
  доби
        hi = max(parts, key=itemgetter(3))
        lo = min(parts, key=itemgetter(5))
        volume = sum(x[9] for x in parts)
        n = sum(x[10] for x in parts)
        sys.stdout.write("%s\t%s\t%s\t%s\t%s\t%r\t%d\n" %
                         (day, first[2], hi[4], lo[6], last[8], volume, n))


if __name__ == "__main__":
    main()
```

A.5 Файл hive_01_create_table.hql – зовнішня таблиця candles і подання candles_v

```
-- hive_01_create_table.hql
-- Завдання 5: зовнішня (EXTERNAL) таблиця Hive поверх CSV, що вже лежить у HDFS.
-- Дані не копіюються: Hive лише описує схему над каталогом /user/root/btc/raw.
CREATE DATABASE IF NOT EXISTS btc;
USE btc;

DROP VIEW IF EXISTS candles_v;
DROP TABLE IF EXISTS candles;

CREATE EXTERNAL TABLE candles (
  ts     DOUBLE,   -- Timestamp (unix-секунди, UTC)
  open   DOUBLE,
  high   DOUBLE,
  low    DOUBLE,
  close  DOUBLE,
  volume DOUBLE
)
ROW FORMAT DELIMITED FIELDS TERMINATED BY ','
STORED AS TEXTFILE
LOCATION '/user/root/btc/raw'
TBLPROPERTIES ("skip.header.line.count"="1");   -- пропустити рядок із назвами
   стовпців (властивість Hive)

-- Подання з датою UTC (без залежності від часового поясу сесії Hive)
-- та фільтром пропущених значень (аналог dropna у Pandas).
CREATE VIEW candles_v AS
SELECT date_add('1970-01-01', CAST(floor(ts / 86400) AS INT)) AS trade_date,
       ts, open, high, low, close, volume
FROM candles
WHERE ts IS NOT NULL AND open IS NOT NULL AND high IS NOT NULL
  AND low IS NOT NULL AND close IS NOT NULL AND volume IS NOT NULL;
```

A.6 Файл hive_01b_describe.hql – опис таблиці (DESCRIBE FORMATTED)

```
-- hive_01b_describe.hql
-- Метадані зовнішньої таблиці: Location, Table Type, Table Parameters
   (skip.header.line.count, totalSize).
USE btc;
DESCRIBE FORMATTED candles;
```

A.7 Файл hive_02_select.hql – вибірка та підрахунок рядків

```
-- hive_02_select.hql
-- Завдання 6: вибірка та простий підрахунок.
USE btc;
SET hive.cli.print.header=true;
SET hive.resultset.use.unique.column.names=false;
```

```
-- перші рядки таблиці
SELECT * FROM candles LIMIT 5;

-- вибірка з умовою: найбільші за обсягом хвилинні свічки
SELECT trade_date, ts, open, high, low, close, volume
FROM candles_v
WHERE volume > 1000
ORDER BY volume DESC
LIMIT 10;

-- контроль пропуску заголовка: рядків у самій таблиці (без подання)
SELECT COUNT(*) AS raw_rows FROM candles;

-- кількість свічок
SELECT COUNT(*) AS total_candles FROM candles_v;
```

A.8 Файл hive_03a_yearly.hql – групування за роками

```
-- hive_03a_yearly.hql
-- Завдання 6: групування та агрегація за роками.
USE btc;
SET hive.cli.print.header=true;
SET hive.resultset.use.unique.column.names=false;

SELECT year(trade_date)  AS yr,
       COUNT(*)          AS candles,
       SUM(volume)       AS total_volume,
       AVG(close)        AS avg_close,
       MAX(high)         AS max_high,
       MIN(low)          AS min_low
FROM candles_v
GROUP BY year(trade_date)
ORDER BY yr;
```

A.9 Файл hive_03b_monthly.hql – групування за роком і місяцем

```
-- hive_03b_monthly.hql
-- Завдання 6: групування за роком і місяцем.
USE btc;
SET hive.cli.print.header=true;
SET hive.resultset.use.unique.column.names=false;

SELECT year(trade_date)  AS yr,
       month(trade_date) AS mn,
       COUNT(*)          AS candles,
       SUM(volume)       AS total_volume,
       AVG(close)        AS avg_close
FROM candles_v
GROUP BY year(trade_date), month(trade_date)
ORDER BY yr, mn;
```

A.10 Файл hive_04_daily_struct.hql – добова таблиця OHLC (CTAS)

```
-- hive_04_daily_struct.hql
-- Добова таблиця OHLCV зі свічок 1 хв (CTAS).
-- Open = Open свічки з мінімальним ts, Close = Close свічки з максимальним ts:
-- min/max над struct(ts, значення) порівнюють спочатку за ts (перше поле).
USE btc;
DROP VIEW  IF EXISTS daily_range_v;
DROP TABLE IF EXISTS daily_ohlc;

CREATE TABLE daily_ohlc STORED AS TEXTFILE AS
SELECT trade_date,
       min(struct(ts, open)).col2  AS open,
       max(high)                   AS high,
       min(low)                    AS low,
```

```
       max(struct(ts, close)).col2 AS close,
       sum(volume)                 AS volume,
       count(*)                    AS candles
FROM candles_v
GROUP BY trade_date;
```

A.11 Файл hive_05a_top_volume.hql – топ-10 діб за обсягом

```
-- hive_05a_top_volume.hql
-- Топ-10 діб за сумарним обсягом торгів (з добової таблиці).
USE btc;
SET hive.cli.print.header=true;
SET hive.resultset.use.unique.column.names=false;

SELECT trade_date, open, high, low, close, volume, candles
FROM daily_ohlc
ORDER BY volume DESC
LIMIT 10;
```

A.12 Файл hive_05b_top_range.hql – топ-10 діб за амплітудою High − Low

```
-- hive_05b_top_range.hql
-- Топ-10 діб за амплітудою High - Low (через подання daily_range_v).
USE btc;
SET hive.cli.print.header=true;
SET hive.resultset.use.unique.column.names=false;

CREATE VIEW IF NOT EXISTS daily_range_v AS
SELECT trade_date, open, high, low, close, volume, high - low AS price_range
FROM daily_ohlc;

SELECT trade_date, high, low, price_range, volume
FROM daily_range_v
ORDER BY price_range DESC
LIMIT 10;
```

A.13 Файл hive_06_daily_count.hql – контроль добової таблиці

```
-- hive_06_daily_count.hql
-- Контроль: кількість рядків добової таблиці та вибірка перших/останніх діб.
USE btc;
SET hive.cli.print.header=true;
SET hive.resultset.use.unique.column.names=false;

SELECT COUNT(*) AS daily_rows FROM daily_ohlc;
SELECT * FROM daily_ohlc ORDER BY trade_date LIMIT 5;
```

A.14 Файл hive_07_load_data.hql – керована таблиця і LOAD DATA INPATH

```
-- hive_07_load_data.hql
-- Завдання 5, крок «Завантажити дані в таблицю»: керована (MANAGED) таблиця та
   LOAD DATA INPATH.
-- Джерело: копія CSV у /user/root/btc/load_src (файл зовнішньої таблиці в
   /user/root/btc/raw лишається).
-- LOAD DATA INPATH ПЕРЕМІЩУЄ файл у каталог сховища
   /user/hive/warehouse/btc.db/candles_managed.
USE btc;
DROP TABLE IF EXISTS candles_managed;

CREATE TABLE candles_managed (
  ts     DOUBLE,
  open   DOUBLE,
  high   DOUBLE,
```

```
  low    DOUBLE,
  close  DOUBLE,
  volume DOUBLE
)
ROW FORMAT DELIMITED FIELDS TERMINATED BY ','
STORED AS TEXTFILE
TBLPROPERTIES ("skip.header.line.count"="1");

LOAD DATA INPATH '/user/root/btc/load_src/btcusd_1-min_data.csv' INTO TABLE
   candles_managed;

SET hive.cli.print.header=true;
SELECT COUNT(*) AS managed_rows FROM candles_managed;
SELECT * FROM candles_managed LIMIT 3;
```

A.15 Файл run_pz1.py – основний конвеєр: налаштування Hadoop і Hive, HDFS, MapReduce, Hive, Pandas, звірки

```
#!/usr/bin/env python3
# -*- coding: utf-8 -*-
"""run_pz1.py - ПЗ1: HDFS, MapReduce (Hadoop Streaming), Hive на повному наборі
   Bitcoin (1-хв свічки).
Локальний запуск (pseudo-distributed Hadoop 3.3.6 + Hive 3.1.3). Адаптовано з
   Colab-ноутбука.
"""
import os, sys, re, io, json, glob, math, time, shlex, shutil, zipfile, platform,
   traceback, subprocess, datetime
from pathlib import Path
from types import SimpleNamespace

# ---------- шляхи / paths ----------
DRIVE_BASE = Path('/nonexistent_drive')   # на Colab тут був Google Drive;
   локально синхронізація не потрібна
OUT_DRIVE  = DRIVE_BASE / 'colab_results' / 'pz1'
WORK  = Path(__file__).resolve().parents[2]   # робочий каталог курсу (code ->
   pz1 -> work)
OUT   = WORK / 'pz1'                          # каталог результатів ПЗ1
SHOTS = OUT / 'screenshots'
RES   = OUT / 'results'
LOGS  = OUT / 'logs'
CODE  = OUT / 'code'                           # mapper/reducer/hql
DATA  = WORK / 'data/raw'
for d in (SHOTS, RES, LOGS, CODE):
    d.mkdir(parents=True, exist_ok=True)

# ---------- версії та середовище ----------
HADOOP_VER, HIVE_VER = '3.3.6', '3.1.3'
HADOOP_HOME, HIVE_HOME = str(WORK / 'tools/hadoop-3.3.6'), str(WORK /
   'tools/apache-hive-3.1.3-bin')
RT = str(WORK / 'hadoop_runtime')      # дані NameNode/DataNode, pid-файли,
   метасховище Hive
JAVA_HOME = str(WORK / 'mamba/envs/jdk8')   # JDK 8 (потрібен Hive 3.1.3; Hadoop
   3.3.6 теж працює на ній)
HDFS_BASE = '/user/root/btc'
os.environ.pop('JAVA_TOOL_OPTIONS', None)   # сторонні параметри JVM із
   середовища Hadoop не потрібні
os.environ.update({
    'JAVA_HOME': JAVA_HOME, 'HADOOP_HOME': HADOOP_HOME, 'HADOOP_CONF_DIR':
   f'{HADOOP_HOME}/etc/hadoop',
    'HADOOP_MAPRED_HOME': HADOOP_HOME, 'HIVE_HOME': HIVE_HOME,
    'HDFS_NAMENODE_USER': 'root', 'HDFS_DATANODE_USER': 'root',
   'HDFS_SECONDARYNAMENODE_USER': 'root',
    'YARN_RESOURCEMANAGER_USER': 'root', 'YARN_NODEMANAGER_USER': 'root',
   'MAPRED_HISTORYSERVER_USER': 'root',
    'PYTHONHASHSEED': '42',
})
os.environ['PATH'] = ':'.join([f'{HADOOP_HOME}/bin', f'{HADOOP_HOME}/sbin',
   f'{HIVE_HOME}/bin',
                               f'{JAVA_HOME}/bin', os.environ['PATH']])
```

```
STATE = {}          # прапорці готовності: hdfs_up, csv, ...
RUNTIMES = []       # (крок, секунди)
TIMINGS = []        # порівняння інструментів
CHECK = {}          # чекліст: ключ -> 'OK' / 'FAIL: ...'
TASKS = [           # (ключ, опис)
    ('data',         'Дані: archive.zip -> CSV (Data prepared)'),
    ('arch',         'Завдання 1: архітектура Hadoop / HDFS (dfsadmin, fsck,
  jps)'),
    ('install',      'Завдання 2: Java 8 + Hadoop 3.3 встановлено і
  налаштовано'),
    ('daemons',      'Завдання 2: NameNode/DataNode/ResourceManager/NodeManager
  запущено'),
    ('hdfs',         'Завдання 3: CSV завантажено в HDFS (ls/du/cat/fsck)'),
    ('selftest',     'Попередня перевірка mapper/reducer на вибірці (vs
  Pandas)'),
    ('wordcount',    'Завдання 4: WordCount (hadoop-mapreduce-examples)'),
    ('mr_year',      'Завдання 4: власна Streaming-задача, свічки та обсяг за
  роками'),
    ('mr_ohlc',      'Завдання 4: власна Streaming-задача, добові OHLC'),
    ('hive_install', 'Завдання 5: Hive 3.1.3 + Derby metastore'),
    ('hive_table',   'Завдання 5: зовнішня таблиця Hive над CSV у HDFS'),
    ('hive_queries', 'Завдання 6: вибірка, групування за роком/місяцем'),
    ('hive_daily',   'Завдання 6: добова таблиця, топ-10 за обсягом і за High-
  Low'),
    ('pandas',       'Завдання 7: Pandas (ті самі агрегації) + звірка з
  MapReduce'),
    ('spark',        'Завдання 7: PySpark (ті самі агрегації) + звірка'),
    ('timing',       'Завдання 7: таблиця порівняння часу'),
    ('ui_shots',     'Веб-інтерфейси NameNode / YARN / Spark (скріншоти)'),
    ('save',         'Збереження версій, логів, runtimes'),
]
for k, _ in TASKS:
    CHECK[k] = 'FAIL: не виконано / not executed'

def banner(t):
    print('\n' + '=' * 78 + f'\n== {t}\n' + '=' * 78, flush=True)

def sync():
    """Копіює локальні результати на Drive (викликається після кожного кроку)."""
    try:
        if not DRIVE_BASE.exists():
            return
        OUT_DRIVE.mkdir(parents=True, exist_ok=True)
        pd_ = __import__('pandas')
        pd_.DataFrame(RUNTIMES, columns=['step', 'seconds']).to_csv(OUT /
  'runtimes.csv', index=False)
        shutil.copytree(OUT, OUT_DRIVE, dirs_exist_ok=True)
        shutil.copytree(CODE, OUT_DRIVE / 'code', dirs_exist_ok=True)
    except Exception as e:
        print('  [sync] попередження / warning:', e)

class step:
    """Контекст кроку: заголовок, час, перехоплення помилок, запис у чекліст. Run
  all не зупиняється."""
    def __init__(self, key, title):
        self.key, self.title = key, title
    def __enter__(self):
        banner(f'[{self.key}] {self.title}')
        self.t0 = time.time()
        return self
    def __exit__(self, et, ev, tb):
        dt = time.time() - self.t0
        RUNTIMES.append((self.key, round(dt, 1)))
        if et is not None and issubclass(et, Exception):
            msg = f'{et.__name__}: {ev}'
            CHECK[self.key] = 'FAIL: ' + msg.replace('\n', ' ')[:300]
            print('\n!!! ПОМИЛКА / FAILED:', self.key, '\n' + msg)
            traceback.print_exception(et, ev, tb, limit=-3)
            sync()
            return True
```

```
        if CHECK.get(self.key, '').startswith('FAIL: не виконано'):
            CHECK[self.key] = 'OK'
        print(f'--- [{self.key}] завершено за {dt:.1f} с / done in {dt:.1f} s
   ---')
        sync()
        return False

def check(cond, ua, en):
    """Перевірка з двомовним повідомленням / bilingual assertion."""
    if not cond:
        raise AssertionError(f'{ua} | {en}')

def need(flag, ua, en):
    check(STATE.get(flag), f'{ua} (попередній крок не виконано)', f'{en}
   (previous step did not finish)')

def strip_ansi(s):
    return re.sub(r'\x1b\[[0-9;?]*[A-Za-z]', '', s).replace('\r', '')

def sh(cmd, log=None, check_rc=True, timeout=None, quiet=False, tail=25,
   cwd=None, err_to=None, echo=True):
    """Виконує bash-команду, друкує вивід (або лише хвіст при quiet), пише лог.
   Повертає (rc, out, secs)."""
    if echo:
        print('\n$ ' + (cmd if len(cmd) < 400 else cmd[:400] + ' ...'),
   flush=True)
    full = cmd
    if timeout:
        full = f'timeout {int(timeout)} bash -c {shlex.quote(cmd)}'
    t0 = time.time()
    errf = open(err_to, 'a') if err_to else None
    p = subprocess.Popen(full, shell=True, executable='/bin/bash',
   stdout=subprocess.PIPE,
                         stderr=errf if errf else subprocess.STDOUT, text=True,
   errors='replace',
                         cwd=cwd, env=os.environ)
    lines = []
    lf = open(LOGS / log, 'a') if log else None
    if lf:
        lf.write(f'\n$ {cmd}\n')
    for ln in p.stdout:
        lines.append(ln)
        if lf:
            lf.write(ln)
        if not quiet:
            sys.stdout.write(ln)
    p.wait()
    if lf: lf.close()
    if errf: errf.close()
    out = strip_ansi(''.join(lines))
    secs = time.time() - t0
    if quiet and tail:
        print('\n'.join(out.rstrip('\n').split('\n')[-tail:]))
    if p.returncode != 0 and check_rc:
        last = '\n'.join(out.rstrip('\n').split('\n')[-30:])
        raise RuntimeError(f'Команда завершилась з кодом {p.returncode} / command
   failed (rc={p.returncode}): {cmd[:200]}\n{last}')
    return SimpleNamespace(rc=p.returncode, out=out, secs=secs)

# ---------- «скріншоти» терміналу / terminal screenshots ----------
SHOT_N = [0]
sys.path.insert(0, str(Path(__file__).resolve().parent))
from termshot import render_terminal_png   # рендер терміналу в PNG (див.
   termshot.py)

def shot(cmd, text, name):
    SHOT_N[0] += 1
    p = SHOTS / f'{SHOT_N[0]:02d}_{name}.png'
    try:
        render_terminal_png(cmd, text, p)
        print(f'  [скріншот/screenshot] {p.name}')
```

```
    except Exception as e:
        print('  [скріншот не створено / screenshot failed]', name, e)
    return p

def run_shot(cmd, name, log=None, **kw):
    """Виконує команду, показує вивід і зберігає його як PNG-«термінал»."""
    r = sh(cmd, log=log, **kw)
    shot(cmd, r.out, name)
    return r

def save_csv(df, name, **kw):
    p = RES / name
    df.to_csv(p, index=False, **kw)
    print(f'  [csv] {p.name}: {len(df)} рядків / rows')
    return p

print('Службові функції готові / helpers ready. Python', sys.version.split()[0])

with step('data', 'Перевірка вхідного CSV'):
    CSV = DATA / 'btcusd_1-min_data.csv'
    check(CSV.exists(), 'CSV не знайдено', 'CSV not found')
    header = open(CSV).readline().strip()
    print('Заголовок / header:', header)
    check(header.lower().replace(' ', '') ==
  'timestamp,open,high,low,close,volume', f'Несподівані стовпці CSV: {header}',
  'Unexpected CSV columns')
    N_LINES = sum(1 for _ in open(CSV, 'rb'))
    N_ROWS_RAW = N_LINES - 1
    print(f'Файл: {CSV.name}, {CSV.stat().st_size / 1e6:.1f} MB, рядків даних:
  {N_ROWS_RAW:,}')
    check(N_ROWS_RAW == 7816537, 'Кількість рядків не збігається з README', 'Row
  count differs from README')
    STATE['csv'] = True

def download(urls, dest):
    """Пробує кілька дзеркал по черзі (dlcdn -> archive.apache.org)."""
    dest = Path(dest)
    for u in urls:
        r = sh(f'curl -fL --retry 3 --connect-timeout 25 -o "{dest}" "{u}" &&
  gzip -t "{dest}"',
               check_rc=False, quiet=True, tail=3)
        if r.rc == 0:
            print('  завантажено / downloaded:', u, f'({dest.stat().st_size /
  1e6:.0f} MB)')
            return
        print('  не вдалося / failed:', u)
    raise RuntimeError(f'Не вдалося завантажити {dest.name} з жодного дзеркала /
  could not download from any mirror')

def write_xml(path, props):
    body = ''.join(f'  <property><name>{k}</name><value>{v}</value></property>\n'
  for k, v in props.items())
    Path(path).write_text('<?xml version="1.0"?>\n<configuration>\n' + body +
  '</configuration>\n')



with step('install', 'Налаштування Hadoop ' + HADOOP_VER + ' (pseudo-
  distributed)'):
    need('csv', 'Немає даних', 'No data')
    check(Path(JAVA_HOME, 'bin/java').exists(), 'JDK 8 не знайдено', 'JDK 8 not
  found')
    sh('java -version')
    check(Path(HADOOP_HOME, 'bin/hadoop').exists(), 'Hadoop не розпаковано',
  'Hadoop not unpacked')
    for sub in ('nn', 'dn', 'pids', 'tmp'):
        Path(RT, sub).mkdir(parents=True, exist_ok=True)
    conf = Path(HADOOP_HOME, 'etc/hadoop')
    envf = conf / 'hadoop-env.sh'
    txt = envf.read_text()
    txt = txt.split('# ---- PZ1 local ----')[0]
```

```
    txt += f"""# ---- PZ1 local ----
export JAVA_HOME={JAVA_HOME}
export HADOOP_PID_DIR={RT}/pids
export HDFS_NAMENODE_OPTS="-Xmx768m"
export HDFS_DATANODE_OPTS="-Xmx512m"
export YARN_RESOURCEMANAGER_OPTS="-Xmx768m"
export YARN_NODEMANAGER_OPTS="-Xmx768m"
export MAPRED_HISTORYSERVER_OPTS="-Xmx512m"
"""
    envf.write_text(txt)
    write_xml(conf / 'core-site.xml', {
        'fs.defaultFS': 'hdfs://localhost:9000',
        'hadoop.tmp.dir': RT + '/tmp'})
    write_xml(conf / 'hdfs-site.xml', {
        'dfs.replication': '1',
        'dfs.namenode.name.dir': 'file://' + RT + '/nn',
        'dfs.datanode.data.dir': 'file://' + RT + '/dn',
        'dfs.permissions.enabled': 'false',
        'dfs.webhdfs.enabled': 'true'})
    write_xml(conf / 'mapred-site.xml', {
        'mapreduce.framework.name': 'yarn',
        'mapreduce.application.classpath':
   '$HADOOP_MAPRED_HOME/share/hadoop/mapreduce/*:$HADOOP_MAPRED_HOME/share/
   hadoop/mapreduce/lib/*',
        'yarn.app.mapreduce.am.env': 'HADOOP_MAPRED_HOME=' + HADOOP_HOME,
        'mapreduce.map.env': 'HADOOP_MAPRED_HOME=' + HADOOP_HOME,
        'mapreduce.reduce.env': 'HADOOP_MAPRED_HOME=' + HADOOP_HOME,
        'yarn.app.mapreduce.am.resource.mb': '1024',
        'yarn.app.mapreduce.am.command-opts': '-Xmx768m',
        'mapreduce.map.memory.mb': '1024',
        'mapreduce.map.java.opts': '-Xmx768m',
        'mapreduce.reduce.memory.mb': '1536',
        'mapreduce.reduce.java.opts': '-Xmx1024m',
        'mapreduce.task.io.sort.mb': '128',
        'mapreduce.jobhistory.address': 'localhost:10020',
        'mapreduce.jobhistory.webapp.address': 'localhost:19888',
        'mapreduce.jobhistory.intermediate-done-dir': RT +
   '/history/intermediate',
        'mapreduce.jobhistory.done-dir': RT + '/history/done'})
     write_xml(conf / 'yarn-site.xml', {
        'yarn.resourcemanager.hostname': 'localhost',
        'yarn.nodemanager.aux-services': 'mapreduce_shuffle',
        'yarn.nodemanager.env-whitelist':
   'JAVA_HOME,HADOOP_COMMON_HOME,HADOOP_HDFS_HOME,HADOOP_CONF_DIR,CLASSPATH_PREPEN
   D_DISTCACHE,HADOOP_YARN_HOME,HADOOP_MAPRED_HOME',
        'yarn.nodemanager.resource.memory-mb': '5120',
        'yarn.nodemanager.resource.cpu-vcores': '4',
        'yarn.scheduler.minimum-allocation-mb': '256',
        'yarn.scheduler.maximum-allocation-mb': '4096',
        'yarn.nodemanager.vmem-check-enabled': 'false',
        'yarn.nodemanager.pmem-check-enabled': 'false',
        'yarn.nodemanager.local-dirs': RT + '/nm-local',
        'yarn.nodemanager.log-dirs': RT + '/nm-logs',
        'yarn.nodemanager.disk-health-checker.max-disk-utilization-per-disk-
   percentage': '98.5',
        'yarn.log-aggregation-enable': 'false'})
     cs = conf / 'capacity-scheduler.xml'
     t = cs.read_text()
     t = re.sub(r'(<name>yarn.scheduler.capacity.maximum-am-resource-percent</
   name>\s*<value>)[^<]*(</value>)', r'\g<1>0.8\g<2>', t)
     cs.write_text(t)
     r = sh('hadoop version', log='01_install_hadoop.log')
     check('Hadoop ' + HADOOP_VER in r.out, 'Hadoop не встановлено коректно',
   'Hadoop was not installed correctly')
     STATE['hadoop_installed'] = True

def jps_names():
    return set(re.findall(r'^\d+\s+(\w+)', sh('jps', echo=False,
   check_rc=False).out, flags=re.M))

with step('daemons', 'Запуск HDFS + YARN (pseudo-distributed)'):
```

```
    need('hadoop_installed', 'Hadoop не встановлено', 'Hadoop is not installed')
    nn_dir = Path(RT + '/nn/current')
    if not nn_dir.exists():
        sh('hdfs namenode -format -force -nonInteractive', log='02_format.log',
  quiet=True, tail=6)
    names = jps_names()
    if 'NameNode' not in names:
        sh('hdfs --daemon start namenode', log='02_daemons.log')
    if 'DataNode' not in names:
        sh('hdfs --daemon start datanode', log='02_daemons.log')
    if 'ResourceManager' not in names:
        sh('yarn --daemon start resourcemanager', log='02_daemons.log')
    if 'NodeManager' not in names:
        sh('yarn --daemon start nodemanager', log='02_daemons.log')
    sh('mapred --daemon start historyserver', log='02_daemons.log',
  check_rc=False)   # необов'язково (сторінка job)

    ok = False
    for i in range(60):                                  # до ~2 хв очікування
        rep = sh('hdfs dfsadmin -report', echo=False, check_rc=False).out
        nodes = sh('yarn node -list', echo=False, check_rc=False).out
        if 'Live datanodes (1)' in rep and 'RUNNING' in nodes:
            ok = True; break
        time.sleep(2)
    if not ok:
        for f in glob.glob(f'{HADOOP_HOME}/logs/*namenode*.log') +
  glob.glob(f'{HADOOP_HOME}/logs/*datanode*.log'):
            print('--- хвіст логу', f); print(sh(f'tail -n 25 {f}',
  echo=False).out)
    check(ok, 'NameNode/DataNode/NodeManager не запустились за 2 хв (див. логи
  вище)',
          'NameNode/DataNode/NodeManager did not come up within 2 min (see logs
  above)')
    sh('hdfs dfsadmin -safemode wait')
    names = jps_names()
    for need_ in ('NameNode', 'DataNode', 'ResourceManager', 'NodeManager'):
        check(need_ in names, f'Демон {need_} не працює', f'Daemon {need_} is not
  running')
    STATE['hdfs_up'] = True
    run_shot('jps', 'jps_daemons', log='02_daemons.log')
    sh(f'hdfs dfs -mkdir -p {HDFS_BASE}/raw {HDFS_BASE}/wc_in {HDFS_BASE}/out
  /tmp /user/hive/warehouse && hdfs dfs -chmod -R 777 /tmp /user/hive')
    run_shot('yarn node -list', 'yarn_node_list', log='02_daemons.log')
with step('arch', 'Конфігурація кластера: dfsadmin -report, getconf'):
    need('hdfs_up', 'HDFS не запущено', 'HDFS is not running')
    run_shot('hdfs dfsadmin -report', 'hdfs_dfsadmin_report', log='03_arch.log')
    run_shot('for k in fs.defaultFS dfs.replication dfs.blocksize
  dfs.namenode.name.dir; do echo -n "$k = "; hdfs getconf -confKey $k; done',
           'hdfs_getconf', log='03_arch.log')
    run_shot('yarn node -list -all', 'yarn_nodes', log='03_arch.log')
    import pandas as pd
    rep = sh('hdfs dfsadmin -report', echo=False).out
    cap = re.search(r'Configured Capacity: (\d+)', rep)
    arch = pd.DataFrame([
        ('fs.defaultFS', sh('hdfs getconf -confKey fs.defaultFS',
  echo=False).out.strip()),
        ('dfs.replication', sh('hdfs getconf -confKey dfs.replication',
  echo=False).out.strip()),
        ('dfs.blocksize_bytes', sh('hdfs getconf -confKey dfs.blocksize',
  echo=False).out.strip()),
        ('live_datanodes', '1' if 'Live datanodes (1)' in rep else '?'),
        ('configured_capacity_bytes', cap.group(1) if cap else '?')],
  columns=['parameter', 'value'])
    save_csv(arch, 'hdfs_cluster_config.csv')
with step('hdfs', 'HDFS: каталоги, put, ls, du, cat, fsck'):
    need('hdfs_up', 'HDFS не запущено', 'HDFS is not running')
    need('csv', 'Немає CSV', 'No CSV')
    import pandas as pd
    HDFS_CSV = f'{HDFS_BASE}/raw/{CSV.name}'
    run_shot(f'hdfs dfs -mkdir -p {HDFS_BASE}/raw {HDFS_BASE}/wc_in
  {HDFS_BASE}/out && hdfs dfs -ls -R /user/root', 'hdfs_mkdir_ls',
```

```
    log='04_hdfs.log')
     r = sh(f'hdfs dfs -put -f "{CSV}" {HDFS_CSV}', log='04_hdfs.log')
     put_secs = r.secs
     print(f'hdfs put: {put_secs:.1f} c')
     run_shot(f'hdfs dfs -ls -h {HDFS_BASE}/raw', 'hdfs_ls_raw',
    log='04_hdfs.log')
     run_shot(f'hdfs dfs -du -h {HDFS_BASE}', 'hdfs_du', log='04_hdfs.log')
     run_shot(f'hdfs dfs -cat {HDFS_CSV} | head -n 6', 'hdfs_cat_head',
    log='04_hdfs.log', check_rc=False)
     run_shot(f'hdfs dfs -tail {HDFS_CSV}', 'hdfs_tail', log='04_hdfs.log',
    check_rc=False)
     fs = run_shot(f'hdfs fsck {HDFS_BASE}/raw -files -blocks -locations',
    'hdfs_fsck', log='04_hdfs.log')
     check('is HEALTHY' in fs.out, 'fsck: файлова система не HEALTHY', 'fsck:
    filesystem is not HEALTHY')
     size_hdfs = int(sh(f'hdfs dfs -stat %b {HDFS_CSV}', echo=False).out.strip())
     check(size_hdfs == CSV.stat().st_size, f'Розмір у HDFS ({size_hdfs}) !=
    локальний ({CSV.stat().st_size})',
           'HDFS file size differs from local file size')
     blocks = int(re.search(r'Total blocks \(validated\):\s+(\d+)',
    fs.out).group(1))
     save_csv(pd.DataFrame([dict(file=CSV.name, size_bytes=size_hdfs,
    size_mb=round(size_hdfs / 1e6, 1),
                                 hdfs_blocks=blocks, replication=1,
    rows_data=N_ROWS_RAW, put_seconds=round(put_secs, 1))]),
              'hdfs_file_info.csv')
     TIMINGS.append(dict(tool='HDFS', task='put CSV', seconds=round(put_secs, 1),
    note='hdfs dfs -put'))
     STATE['hdfs_data'] = True

def write_code(name, text):
    pass

with step('selftest', 'Локальна перевірка mapper/reducer на вибірці (cat | mapper
   | sort | reducer)'):
    need('csv', 'Немає CSV', 'No CSV')
    import pandas as pd, numpy as np
    smp = Path(RT + '/sample_200k.csv')
    sh(f'head -n 200001 "{CSV}" > {smp}', echo=False)
    S = "LC_ALL=C sort -t $'\\t' -k1,1 -s"
    y_out = sh(f'cat {smp} | python3 {CODE}/mapper_year.py | {S} | python3
    {CODE}/reducer_year.py', quiet=True, tail=3).out
    o_out = sh(f'cat {smp} | python3 {CODE}/mapper_ohlc.py | {S} | python3
    {CODE}/reducer_ohlc.py', quiet=True, tail=3).out
    sm = pd.read_csv(smp, float_precision='round_trip').dropna()
    sm['dt'] = pd.to_datetime(sm['Timestamp'], unit='s')
    y = pd.read_csv(io.StringIO(y_out), sep='\t', header=None, names=['year',
    'n', 'vol'], float_precision='round_trip')
    g = sm.groupby(sm.dt.dt.year).agg(n=('Volume', 'size'), vol=('Volume',
    'sum')).reset_index(names='year')
    mm = y.merge(g, on='year', suffixes=('_mr', '_pd'))
    check(len(mm) == len(g) == len(y) and (mm.n_mr == mm.n_pd).all() and
    np.allclose(mm.vol_mr, mm.vol_pd, rtol=1e-9),
           'Selftest: річні підсумки mapper/reducer не збігаються з Pandas',
    'Selftest: yearly mapper/reducer output differs from Pandas')
    o = pd.read_csv(io.StringIO(o_out), sep='\t', header=None, names=['day',
    'open', 'high', 'low', 'close', 'vol', 'n'], float_precision='round_trip')
    sm = sm.sort_values('Timestamp')
    d = sm.groupby(sm.dt.dt.strftime('%Y-%m-%d')).agg(open=('Open', 'first'),
    high=('High', 'max'), low=('Low', 'min'),
                                                      close=('Close', 'last'),
    vol=('Volume', 'sum'), n=('Volume', 'size')).reset_index(names='day')
    mo = o.merge(d, on='day', suffixes=('_mr', '_pd'))
    ok = len(mo) == len(d) == len(o) and (mo.n_mr == mo.n_pd).all() and
    np.allclose(mo.vol_mr, mo.vol_pd, rtol=1e-9)
    for k in ('open', 'high', 'low', 'close'):
        ok = ok and np.allclose(mo[k + '_mr'], mo[k + '_pd'], rtol=1e-12)
    check(ok, 'Selftest: добові OHLC mapper/reducer не збігаються з Pandas',
    'Selftest: daily OHLC mapper/reducer differs from Pandas')
    print(f'Selftest OK: роки={len(y)}, доби={len(o)}')
with step('wordcount', 'WordCount (hadoop-mapreduce-examples) - перевірка
```

```
   кластера'):
     need('hdfs_up', 'HDFS не запущено', 'HDFS is not running')
     import pandas as pd
     ex_jar = glob.glob(f'{HADOOP_HOME}/share/hadoop/mapreduce/hadoop-mapreduce-
   examples-*.jar')[0]
     sh(f'hdfs dfs -put -f {HADOOP_HOME}/LICENSE.txt {HADOOP_HOME}/NOTICE.txt
   {HDFS_BASE}/wc_in/')
     sh(f'hdfs dfs -rm -r -f {HDFS_BASE}/out/wordcount')
     cmd = f'hadoop jar {ex_jar} wordcount {HDFS_BASE}/wc_in
   {HDFS_BASE}/out/wordcount'
     r = run_shot(cmd, 'wordcount_run', log='05_wordcount.log', quiet=True,
   tail=40, timeout=900)
     check(sh(f'hdfs dfs -test -e {HDFS_BASE}/out/wordcount/_SUCCESS',
   check_rc=False, echo=False).rc == 0,
           'WordCount не завершився успішно (_SUCCESS відсутній)', 'WordCount
   failed (_SUCCESS missing)')
     TIMINGS.append(dict(tool='Hadoop (examples jar)', task='wordcount',
   seconds=round(r.secs, 1), note='LICENSE.txt+NOTICE.txt'))
     run_shot(f'hdfs dfs -ls {HDFS_BASE}/out/wordcount', 'wordcount_ls',
   log='05_wordcount.log')
     run_shot(f'hdfs dfs -cat {HDFS_BASE}/out/wordcount/part-r-00000 | sort -k2 -
   nr | head -n 20', 'wordcount_top20',
              log='05_wordcount.log', check_rc=False)
     wc = pd.read_csv(io.StringIO(sh(f'hdfs dfs -cat
   {HDFS_BASE}/out/wordcount/part-r-*', echo=False, quiet=True, tail=0).out),
                      sep='\t', header=None, names=['word', 'count'], quoting=3)
     check(len(wc) > 100, 'WordCount: підозріло мало слів у результаті',
   'WordCount: suspiciously few words')
     save_csv(wc.sort_values('count', ascending=False).head(50),
   'wordcount_top50.csv')
     print('Унікальних слів / distinct words:', len(wc), ' Усього / total:',
   int(wc['count'].sum()))
import pandas as pd, numpy as np
STREAM_JAR = (glob.glob(f'{HADOOP_HOME}/share/hadoop/tools/lib/hadoop-streaming-
   *.jar') or [''])[0]
JOBIDS = {}

def counters(text):
    """Витягує лічильники MapReduce з логу задачі."""
     want = ['Map input records', 'Map output records', 'Combine input records',
   'Combine output records',
             'Reduce input groups', 'Reduce input records', 'Reduce output
   records', 'Launched map tasks', 'Launched reduce tasks']
     out = {}
     for w in want:
         m = re.search(r'^\s*' + re.escape(w) + r'=(\d+)', text, flags=re.M)
         if m: out[w] = int(m.group(1))
     return out

def run_streaming(name, mapper, reducer, combiner=None, reduces=1):
    """Запускає Hadoop Streaming задачу над CSV у HDFS. Повертає (секунди,
   лічильники, вивід)."""
     outp = f'{HDFS_BASE}/out/{name}'
     sh(f'hdfs dfs -rm -r -f {outp}', echo=False)
     comb = f"-combiner 'python3 {combiner}'" if combiner else ''
     cmd = (f"hadoop jar {STREAM_JAR} -D mapreduce.job.name={name} -D
   mapreduce.job.reduces={reduces} "
            f"-files {CODE}/{mapper},{CODE}/{reducer}"
            + (f",{CODE}/{combiner}" if combiner and combiner not in (reducer,)
   else '') +
            f" -mapper 'python3 {mapper}' {comb} -reducer 'python3 {reducer}' -
   input {HDFS_BASE}/raw -output {outp}")
     r = sh(cmd, log=f'06_{name}.log', quiet=True, tail=40, timeout=1800,
   check_rc=False)
     check(r.rc == 0, f'Задача {name} завершилась помилкою (rc={r.rc}), див.
   logs/06_{name}.log',
           f'Streaming job {name} failed (rc={r.rc}), see logs/06_{name}.log')
     check(sh(f'hdfs dfs -test -e {outp}/_SUCCESS', check_rc=False, echo=False).rc
   == 0,
           f'Задача {name}: немає _SUCCESS', f'Job {name}: _SUCCESS is missing')
     m = re.search(r'Running job: (job_\d+_\d+)', r.out)
```

```
    if m: JOBIDS[name] = m.group(1)
    cnt = counters(r.out)
    check(cnt.get('Map input records', 0) in (N_LINES, N_LINES + 1),
          f'Задача {name}: Map input records={cnt.get("Map input records")} не
   збігається з кількістю рядків файлу {N_LINES}',
          f'Job {name}: Map input records does not match number of lines in
   file')
    shot(cmd, r.out, f'{name}_job_output')
    save_csv(pd.DataFrame(sorted(cnt.items()), columns=['counter', 'value']),
   f'mr_counters_{name}.csv')
    return r.secs, cnt, outp

with step('mr_year', 'Hadoop Streaming: кількість свічок і сумарний обсяг за
   роками'):
    need('hdfs_data', 'CSV не в HDFS', 'CSV is not in HDFS')
    check(STREAM_JAR, 'hadoop-streaming jar не знайдено', 'hadoop-streaming jar
   not found')
    t, cnt, outp = run_streaming('mr_yearly', 'mapper_year.py',
   'reducer_year.py', combiner='reducer_year.py')
    print('Лічильники / counters:', cnt)
    txt = sh(f'hdfs dfs -cat {outp}/part-*', echo=False, quiet=True, tail=0).out
    MR_YEAR = pd.read_csv(io.StringIO(txt), sep='\t', header=None, names=['year',
   'candles', 'volume'], float_precision='round_trip')
    MR_YEAR = MR_YEAR.sort_values('year').reset_index(drop=True)
    shot(f'hdfs dfs -cat {outp}/part-*', txt, 'mr_yearly_result')
    print(MR_YEAR.to_string(index=False))
    check(MR_YEAR['candles'].sum() == N_ROWS_RAW, f'Сума свічок MR
   ({MR_YEAR.candles.sum()}) != рядків у CSV ({N_ROWS_RAW})',
          'MR candle total differs from CSV row count')
    save_csv(MR_YEAR, 'mr_yearly_stats.csv')
    TIMINGS.append(dict(tool='Hadoop Streaming', task='yearly', seconds=round(t,
   1), note='map+combiner+reduce, YARN pseudo-distributed'))

with step('mr_ohlc', 'Hadoop Streaming: добові OHLC зі свічок 1 хв'):
    need('hdfs_data', 'CSV не в HDFS', 'CSV is not in HDFS')
    t, cnt, outp = run_streaming('mr_daily_ohlc', 'mapper_ohlc.py',
   'reducer_ohlc.py')
    print('Лічильники / counters:', cnt)
    txt = sh(f'hdfs dfs -cat {outp}/part-*', echo=False, quiet=True, tail=0).out
    MR_DAILY = pd.read_csv(io.StringIO(txt), sep='\t', header=None, names=['day',
   'open', 'high', 'low', 'close', 'volume', 'candles'],

   float_precision='round_trip').sort_values('day').reset_index(drop=True)
    shot(f'hdfs dfs -cat {outp}/part-* | head', '\n'.join(txt.split('\n')[:12]),
   'mr_daily_ohlc_result')
    check(MR_DAILY['candles'].sum() == N_ROWS_RAW, 'Сума свічок у добових OHLC !=
   рядків CSV', 'Daily OHLC candle total differs from CSV rows')
    check((MR_DAILY.high >= MR_DAILY[['open', 'close', 'low']].max(axis=1)).all()
   and (MR_DAILY.low <= MR_DAILY[['open', 'close', 'high']].min(axis=1)).all(),
          'Некоректні OHLC (High<max(O,C) або Low>min(O,C))', 'Invalid OHLC
   (High<max(O,C) or Low>min(O,C))')
    save_csv(MR_DAILY, 'mr_daily_ohlc_full.csv')
    save_csv(pd.concat([MR_DAILY.head(15), MR_DAILY.tail(15)]),
   'mr_daily_ohlc_sample.csv')
    save_csv(pd.DataFrame([dict(daily_rows=len(MR_DAILY),
   first_day=MR_DAILY.day.min(), last_day=MR_DAILY.day.max(),
                               candles_total=int(MR_DAILY.candles.sum()))]),
   'mr_daily_ohlc_rowcount.csv')
    TIMINGS.append(dict(tool='Hadoop Streaming', task='daily_ohlc',
   seconds=round(t, 1), note='in-mapper combining, 1 reducer'))
    print(MR_DAILY.head(5).to_string(index=False))
HIVE_META = Path(RT + '/hive_meta')

with step('hive_install', f'Hive {HIVE_VER} + Derby (embedded metastore)'):
    need('hdfs_up', 'HDFS не запущено', 'HDFS is not running')
    HIVE_META.mkdir(exist_ok=True)
    if not Path(HIVE_HOME, 'bin/hive').exists():
        tgz = Path(f'/content/hive-{HIVE_VER}.tar.gz')
        download([f'https://archive.apache.org/dist/hive/hive-{HIVE_VER}/apache-
   hive-{HIVE_VER}-bin.tar.gz',
                  f'https://dlcdn.apache.org/hive/hive-{HIVE_VER}/apache-hive-
```

```
    {HIVE_VER}-bin.tar.gz'], tgz)
         sh(f'tar -xzf {tgz} -C /opt && rm -rf {HIVE_HOME} && mv /opt/apache-hive-
    {HIVE_VER}-bin {HIVE_HOME} && rm -f {tgz}')
      # відомий конфлікт guava: Hive 3.1.3 постачається з guava-19, Hadoop 3.3
    потребує guava-27+
      h_guava = glob.glob(f'{HADOOP_HOME}/share/hadoop/common/lib/guava-[0-
    9]*.jar')
      check(h_guava, 'guava не знайдено в Hadoop', 'guava jar not found in Hadoop')
      for g in glob.glob(f'{HIVE_HOME}/lib/guava-[0-9]*.jar'):
          os.remove(g)
      shutil.copy(h_guava[0], f'{HIVE_HOME}/lib/')
      print('guava замінено на / guava replaced with:', Path(h_guava[0]).name)
      write_xml(Path(HIVE_HOME, 'conf/hive-site.xml'), {
          'javax.jdo.option.ConnectionURL':
    f'jdbc:derby:;databaseName={HIVE_META}/metastore_db;create=true',
          'javax.jdo.option.ConnectionDriverName':
    'org.apache.derby.jdbc.EmbeddedDriver',
          'hive.metastore.warehouse.dir': '/user/hive/warehouse',
          'hive.metastore.schema.verification': 'false',
          'datanucleus.schema.autoCreateAll': 'false',
          'hive.execution.engine': 'mr',
          'hive.exec.scratchdir': '/tmp/hive',
          'hive.exec.local.scratchdir': f'{HIVE_META}/scratch',
          'hive.downloaded.resources.dir': f'{HIVE_META}/resources',
          'hive.querylog.location': f'{HIVE_META}/querylog',
          'hive.server2.logging.operation.log.location': f'{HIVE_META}/oplog',
          'hive.exec.mode.local.auto': 'false'})
      if not (HIVE_META / 'metastore_db').exists():
          sh('schematool -dbType derby -initSchema', log='07_hive_install.log',
    cwd=str(HIVE_META), quiet=True, tail=8)
      r = sh('hive --version 2>/dev/null | head -n 3', log='07_hive_install.log',
    cwd=str(HIVE_META), check_rc=False)
      check('Hive' in r.out, 'Hive не запускається (перевірте guava / schematool у
    logs/07_hive_install.log)',
            'Hive does not start (check guava / schematool in
    logs/07_hive_install.log)')
      STATE['hive_ok'] = True

def hive_f(fname, tag, timeout=1800):
    """Запускає .hql файл: stdout (результат) повертається, stderr (прогрес MR)
    іде в лог."""
      errlog = LOGS / f'08_hive_{tag}.err.log'
      r = sh(f'hive -S -f {CODE}/{fname}', log=f'08_hive_{tag}.log',
    err_to=str(errlog), cwd=str(HIVE_META),
             timeout=timeout, check_rc=False, quiet=True, tail=0)
      if r.rc != 0:
          print('--- хвіст stderr Hive / Hive stderr tail ---')
          print(sh(f'tail -n 25 {errlog}', echo=False, check_rc=False).out)
      return r

def hive_df(out):
    return pd.read_csv(io.StringIO(out), sep='\t', float_precision='round_trip')

with step('hive_table', 'Hive: CREATE EXTERNAL TABLE над CSV у HDFS + вибірка'):
    need('hive_ok', 'Hive не встановлено', 'Hive is not installed')
    need('hdfs_data', 'CSV не в HDFS', 'CSV is not in HDFS')
    r = hive_f('hive_01_create_table.hql', 'create_table')
    check(r.rc == 0, 'CREATE TABLE у Hive завершився помилкою', 'Hive CREATE
    TABLE failed')
    shot('hive -f hive_01_create_table.hql', r.out, 'hive_create_table')
    r = hive_f('hive_02_select.hql', 'select')
    check(r.rc == 0, 'SELECT у Hive завершився помилкою', 'Hive SELECT failed')
    shot('hive -f hive_02_select.hql', r.out, 'hive_select')
    print(r.out)
    cnt = int(r.out.strip().split('\n')[-1].strip())
    HIVE_COUNT = cnt
    check(cnt == N_ROWS_RAW, f'Hive COUNT(*)={cnt} != рядків у CSV {N_ROWS_RAW}
    (skip.header?)',
          'Hive COUNT(*) differs from CSV data rows')
    save_csv(pd.DataFrame([dict(hive_count=cnt, csv_rows=N_ROWS_RAW, equal=cnt ==
    N_ROWS_RAW)]), 'hive_count_check.csv')
```

```
with step('hive_queries', 'Hive: GROUP BY рік / рік+місяць'):
    need('hive_ok', 'Hive не встановлено', 'Hive is not installed')
    r = hive_f('hive_03a_yearly.hql', 'yearly')
    check(r.rc == 0, 'Запит за роками у Hive завершився помилкою', 'Hive yearly
   query failed')
    shot('hive -f hive_03a_yearly.hql', r.out, 'hive_yearly')
    HIVE_YEAR = hive_df(r.out)
    hive_year_secs = r.secs
    print(HIVE_YEAR.to_string(index=False))
    check(int(HIVE_YEAR.candles.sum()) == N_ROWS_RAW, 'Hive: сума свічок за
   роками != рядків CSV', 'Hive yearly candle total differs from CSV rows')
    save_csv(HIVE_YEAR, 'hive_yearly_stats.csv')
    TIMINGS.append(dict(tool='Hive (MR engine)', task='yearly',
   seconds=round(hive_year_secs, 1), note='hive -f, включає старт
   JVM/компіляцію'))
    r = hive_f('hive_03b_monthly.hql', 'monthly')
    check(r.rc == 0, 'Запит за рік+місяць у Hive завершився помилкою', 'Hive
   year-month query failed')
    HIVE_MONTH = hive_df(r.out)
    shot('hive -f hive_03b_monthly.hql', r.out, 'hive_monthly')
    check(int(HIVE_MONTH.candles.sum()) == N_ROWS_RAW, 'Hive: сума свічок за
   місяцями != рядків CSV', 'Hive monthly candle total differs from CSV rows')
    save_csv(HIVE_MONTH, 'hive_monthly_stats.csv')
    print('місяців / months:', len(HIVE_MONTH))
    # звірка Hive vs MapReduce (за роками)
    if 'MR_YEAR' in globals():
        m = HIVE_YEAR.merge(MR_YEAR, left_on='yr', right_on='year')
        ok = len(m) == len(MR_YEAR) == len(HIVE_YEAR) and (m.candles_x ==
   m.candles_y).all() and np.allclose(m.total_volume, m.volume, rtol=1e-9)
        save_csv(pd.DataFrame([dict(check='hive_yearly_vs_mapreduce',
   rows_hive=len(HIVE_YEAR), rows_mr=len(MR_YEAR), match=bool(ok))]),
                 'crosscheck_hive_vs_mr_yearly.csv')
        check(ok, 'Hive та MapReduce дають різні річні підсумки', 'Hive and
   MapReduce yearly results differ')

with step('hive_daily', 'Hive: добова таблиця OHLC, топ-10 діб за обсягом і за
   High-Low'):
    need('hive_ok', 'Hive не встановлено', 'Hive is not installed')
    r = hive_f('hive_04_daily_struct.hql', 'daily_struct')
    hive_daily_secs = r.secs
    if r.rc != 0:
        print('Варіант зі struct не спрацював, запасний варіант з вікнами /
   struct variant failed, using window functions')
        r = hive_f('hive_04_daily_window.hql', 'daily_window')
        hive_daily_secs += r.secs
    check(r.rc == 0, 'Створення добової таблиці Hive завершилось помилкою', 'Hive
   daily table creation failed')
    TIMINGS.append(dict(tool='Hive (MR engine)', task='daily_ohlc',
   seconds=round(hive_daily_secs, 1), note='CTAS daily_ohlc'))
    r = hive_f('hive_06_daily_count.hql', 'daily_count')
    check(r.rc == 0, 'Запит до daily_ohlc не виконано', 'Query on daily_ohlc
   failed')
    shot('hive -f hive_06_daily_count.hql', r.out, 'hive_daily_table')
    print(r.out)
    r = hive_f('hive_05a_top_volume.hql', 'top_volume')
    check(r.rc == 0, 'Топ-10 за обсягом: помилка', 'Top-10 by volume failed')
    shot('hive -f hive_05a_top_volume.hql', r.out, 'hive_top10_volume')
    HIVE_TOPV = hive_df(r.out); print(HIVE_TOPV.to_string(index=False))
    save_csv(HIVE_TOPV, 'hive_top10_volume_days.csv')
    r = hive_f('hive_05b_top_range.hql', 'top_range')
    check(r.rc == 0, 'Топ-10 за High-Low: помилка', 'Top-10 by High-Low failed')
    # CREATE VIEW у Hive при print.header=true виводить зайвий рядок заголовка
   подання; лишаємо тільки результат SELECT
    out_r = r.out[r.out.index('trade_date\thigh'):]
    shot('hive -f hive_05b_top_range.hql', out_r, 'hive_top10_range')
    HIVE_TOPR = hive_df(out_r); print(HIVE_TOPR.to_string(index=False))
    save_csv(HIVE_TOPR, 'hive_top10_range_days.csv')
    # вміст добової таблиці (роздільник Hive за замовчуванням \001) і звірка з
   MapReduce
    txt = sh('hdfs dfs -cat /user/hive/warehouse/btc.db/daily_ohlc/*',
   echo=False, quiet=True, tail=0).out
```

```
    HIVE_DAILY = pd.read_csv(io.StringIO(txt), sep='\x01', header=None,
  float_precision='round_trip',
                           names=['day', 'open', 'high', 'low', 'close',
  'volume', 'candles']).sort_values('day').reset_index(drop=True)
    save_csv(pd.DataFrame([dict(hive_daily_rows=len(HIVE_DAILY))]),
  'hive_daily_rowcount.csv')
    if 'MR_DAILY' in globals():
        m = HIVE_DAILY.merge(MR_DAILY, on='day', suffixes=('_h', '_m'))
        ok = len(m) == len(HIVE_DAILY) == len(MR_DAILY) and (m.candles_h ==
  m.candles_m).all() and np.allclose(m.volume_h, m.volume_m, rtol=1e-9)
        for k in ('open', 'high', 'low', 'close'):
            ok = ok and np.allclose(m[k + '_h'], m[k + '_m'], rtol=1e-12)
        save_csv(pd.DataFrame([dict(check='hive_daily_vs_mapreduce_daily',
  rows_hive=len(HIVE_DAILY), rows_mr=len(MR_DAILY), match=bool(ok))]),
                 'crosscheck_hive_vs_mr_daily.csv')
        check(ok, 'Добові OHLC у Hive і MapReduce відрізняються', 'Hive and
  MapReduce daily OHLC differ')
with step('pandas', 'Pandas: ті самі агрегації + звірка з MapReduce/Hive'):
    need('csv', 'Немає CSV', 'No CSV')
    t0 = time.time()
    df = pd.read_csv(CSV, float_precision='round_trip').dropna()
    df['Timestamp'] = df['Timestamp'].astype('int64')
    t_read = time.time() - t0
    check(len(df) == N_ROWS_RAW, f'Pandas прочитав {len(df)} рядків, а в CSV
  {N_ROWS_RAW}', f'Pandas row count {len(df)} differs from CSV {N_ROWS_RAW}')
    t0 = time.time()
    years = pd.to_datetime(df['Timestamp'], unit='s').dt.year
    PD_YEAR = df.groupby(years.rename('year')).agg(candles=('Volume', 'size'),
  volume=('Volume', 'sum')).reset_index()
    t_year = time.time() - t0
    t0 = time.time()
    d = df.sort_values('Timestamp', kind='stable')
    day = (d['Timestamp'] // 86400).rename('day_n')
    PD_DAILY = d.groupby(day).agg(open=('Open', 'first'), high=('High', 'max'),
  low=('Low', 'min'), close=('Close', 'last'),
                                  volume=('Volume', 'sum'), candles=('Volume',
  'size')).reset_index()
    PD_DAILY['day'] = pd.to_datetime(PD_DAILY['day_n'] * 86400,
  unit='s').dt.strftime('%Y-%m-%d')
    PD_DAILY = PD_DAILY[['day', 'open', 'high', 'low', 'close', 'volume',
  'candles']]
    t_daily = time.time() - t0
    PD_T = dict(read=t_read, year=t_year, daily=t_daily)
    print(f'Pandas: читання {t_read:.1f} с, річна агрегація {t_year:.1f} с,
  добові OHLC {t_daily:.1f} с')
    TIMINGS.append(dict(tool='Pandas', task='read_csv', seconds=round(t_read, 1),
  note='read_csv+dropna'))
    TIMINGS.append(dict(tool='Pandas', task='yearly', seconds=round(t_year, 1),
  note='groupby (без читання)'))
    TIMINGS.append(dict(tool='Pandas', task='daily_ohlc', seconds=round(t_daily,
  1), note='sort+groupby (без читання)'))
    save_csv(PD_YEAR, 'pandas_yearly_stats.csv')
    save_csv(PD_DAILY, 'pandas_daily_ohlc_full.csv')
    PD_DAILY.assign(price_range=PD_DAILY.high - PD_DAILY.low).nlargest(10,
  'volume').pipe(lambda x: save_csv(x, 'pandas_top10_volume_days.csv'))
    PD_DAILY.assign(price_range=PD_DAILY.high - PD_DAILY.low).nlargest(10,
  'price_range').pipe(lambda x: save_csv(x, 'pandas_top10_range_days.csv'))
    shot('python3 code/pandas_yearly.py', PD_YEAR.to_string(index=False),
  'pandas_yearly')

    rows, problems = [], []
    def cmp(name, a, b, ok, extra=''):
        rows.append(dict(check=name, left_rows=len(a), right_rows=len(b),
  match=bool(ok), note=extra))
        if not ok: problems.append(name)
    if 'MR_YEAR' in globals():
        m = MR_YEAR.merge(PD_YEAR, on='year', suffixes=('_mr', '_pd'))
        rel = float(np.max(np.abs(m.volume_mr - m.volume_pd) / np.maximum(1e-12,
  np.abs(m.volume_pd))))
        cmp('mapreduce_vs_pandas_yearly', MR_YEAR, PD_YEAR, len(m) ==
  len(MR_YEAR) == len(PD_YEAR) and (m.candles_mr == m.candles_pd).all() and rel <
```

```
    1e-9, f'max_rel_diff_volume={rel:.2e}')
      if 'MR_DAILY' in globals():
          m = MR_DAILY.merge(PD_DAILY, on='day', suffixes=('_mr', '_pd'))
          ok = len(m) == len(MR_DAILY) == len(PD_DAILY) and (m.candles_mr ==
    m.candles_pd).all()
          bad = {k: int((~np.isclose(m[k + '_mr'], m[k + '_pd'], rtol=1e-12,
    atol=0)).sum()) for k in ('open', 'high', 'low', 'close')}
          relv = float(np.max(np.abs(m.volume_mr - m.volume_pd) / np.maximum(1e-12,
    np.abs(m.volume_pd))))
          cmp('mapreduce_vs_pandas_daily_ohlc', MR_DAILY, PD_DAILY, ok and
    sum(bad.values()) == 0 and relv < 1e-9, f'mismatch_OHLC={bad};
    max_rel_diff_volume={relv:.2e}')
      if 'HIVE_YEAR' in globals():
          m = HIVE_YEAR.merge(PD_YEAR, left_on='yr', right_on='year')
          cmp('hive_vs_pandas_yearly', HIVE_YEAR, PD_YEAR, len(m) == len(PD_YEAR)
    and (m.candles_x == m.candles_y).all() and np.allclose(m.total_volume,
    m.volume, rtol=1e-9))
      if 'HIVE_DAILY' in globals():
          cmp('hive_vs_pandas_daily_rows', HIVE_DAILY, PD_DAILY, len(HIVE_DAILY) ==
    len(PD_DAILY))
      if 'HIVE_TOPV' in globals():
          pv = set(PD_DAILY.nlargest(10, 'volume').day); hv =
    set(HIVE_TOPV.trade_date.astype(str))
          cmp('hive_vs_pandas_top10_volume_days', HIVE_TOPV, PD_DAILY.nlargest(10,
    'volume'), pv == hv)
      if 'HIVE_TOPR' in globals():
          pr = set(PD_DAILY.assign(r=PD_DAILY.high - PD_DAILY.low).nlargest(10,
    'r').day); hr = set(HIVE_TOPR.trade_date.astype(str))
          cmp('hive_vs_pandas_top10_range_days', HIVE_TOPR, PD_DAILY, pr == hr)
      CROSS = pd.DataFrame(rows)
      save_csv(CROSS, 'crosscheck_mr_hive_vs_pandas.csv')
      print(CROSS.to_string(index=False))
      check(CROSS.shape[0] > 0 and not problems, f'Розбіжність результатів:
    {problems} (рядків: Hadoop/Hive vs Pandas)',
            f'Result mismatch between Hadoop/Hive and Pandas: {problems}')
      del df, d
with step('save', 'versions.txt, логи, runtimes.csv'):
      import pandas as pd
      def first(cmd):
          return sh(cmd, echo=False, check_rc=False).out.strip().split('\n')[0]
      ver = {
          'Java': first('java -version 2>&1'), 'Hadoop': first('hadoop version'),
    'Hive': first('cd '+str(HIVE_META)+' && hive --version 2>/dev/null | head -n
    1'),
          'Python': sys.version.split()[0], 'pandas': pd.__version__, 'numpy':
    np.__version__,
          'pyspark': first('pip show pyspark 2>/dev/null | grep -i ^Version'),
    'Hadoop JAVA_HOME': JAVA_HOME, 'OS': platform.platform(),
          'CPU': first("lscpu | grep 'Model name' | sed 's/.*: *//'"), 'nproc':
    first('nproc'),
          'RAM': first("free -h | awk '/Mem/{print $2}'"), 'Disk': first("df -h / |
    tail -n 1"),
          'Date UTC': datetime.datetime.utcnow().strftime('%Y-%m-%d %H:%M:%S'),
      }
      lines = [f'{k}: {v}' for k, v in ver.items()]
      lines += ['', '--- nproc / free -h ---', sh('nproc; free -h',
    echo=False).out]
      (OUT / 'versions.txt').write_text('\n'.join(lines))
      save_csv(pd.DataFrame(list(ver.items()), columns=['component', 'version']),
    'env_versions.csv')
      print('\n'.join(lines))
      for f in glob.glob(f'{HADOOP_HOME}/logs/*.log'):
          shutil.copy(f, LOGS / ('daemon_' + Path(f).name))
      for f in glob.glob(f'{HIVE_META}/*.log') +
    glob.glob(f'{HIVE_META}/querylog/*'):
          shutil.copy(f, LOGS / ('hive_' + Path(f).name))
TASKS = [t for t in TASKS if t[0] not in ('spark','timing','ui_shots')]
banner('ПІДСУМКОВИЙ ЧЕКЛІСТ / FINAL CHECKLIST')
lines = []
for k, title in TASKS:
    st = CHECK.get(k, 'FAIL: не виконано')
```

```
    mark = 'OK  ' if st == 'OK' else 'FAIL'
    lines.append(f'[{mark}] {title}' + ('' if st == 'OK' else f'  <- {st[6:]}'))
n_ok = sum(1 for k, _ in TASKS if CHECK.get(k) == 'OK')
lines.append('')
lines.append(f'Разом: {n_ok} з {len(TASKS)} OK. Результати: {OUT}')
lines.append('Скріншоти: ' + str(len(list(SHOTS.glob('*.png')))) + ' файлів; CSV:
   ' + str(len(list(RES.glob('*.csv')))))
summary = '\n'.join(lines)
print(summary)
(OUT / 'summary.txt').write_text(summary)
sync()
print('\nРезультати збережено у', OUT)
```

A.16 Файл pandas_yearly.py – річні підсумки в Pandas

```
# -*- coding: utf-8 -*-
"""pandas_yearly.py - ПЗ1: кількість свічок і сумарний обсяг за роками (Pandas,
   повний CSV)."""
from pathlib import Path
import pandas as pd
CSV = Path(__file__).resolve().parents[2] / 'data/raw/btcusd_1-min_data.csv'   #
   work/data/raw
df = pd.read_csv(CSV, float_precision='round_trip').dropna()
df['Timestamp'] = df['Timestamp'].astype('int64')
years = pd.to_datetime(df['Timestamp'], unit='s').dt.year
print(df.groupby(years.rename('year')).agg(candles=('Volume', 'size'),
   volume=('Volume', 'sum')).reset_index().to_string(index=False))
```

A.17 Файл bench_all.py – порівняльне вимірювання часу Hadoop Streaming, Hive, Pandas і PySpark

```
#!/usr/bin/env python3
# -*- coding: utf-8 -*-
"""
bench_all.py - єдина точка входу: чесне порівняння двох агрегацій у чотирьох
   рушіях.
  T1: кількість свічок і сумарний обсяг за роками;  T2: добові OHLC
   (first/max/min/last/sum за Timestamp).
  Рушії: Hadoop Streaming (YARN), Hive (рушій MR), pandas, PySpark local[*].
Запуск:  python3 bench_all.py            (повний прогін: очікування тиші, 1
   прогрів + 5 вимірюваних кіл)
         python3 bench_all.py --smoke    (одне коло для перевірки, результати у
   bench/smoke, не рахуються)
Службовий режим:  bench_all.py --job <engine> <T1|T2|start> <outdir>
   (виконується у дочірньому процесі).
"""
import os, sys, re, time, subprocess, shutil, json
from pathlib import Path

W = Path(__file__).resolve().parents[2]; B = W / 'bench'; CODE = B / 'code'
CSV = W / 'data/raw/btcusd_1-min_data.csv'
SCR = Path('/tmp/bench_scratch')            # локальний каталог виводу
   pandas/Spark
HDFS_RAW = '/user/root/btc/raw'; HDFS_OUT = '/user/root/btc/out'; HDFS_TINY =
   '/user/root/btc/bench_tiny'
HH = W / 'tools/hadoop-3.3.6'; HV = W / 'tools/apache-hive-3.1.3-bin'
JDK8 = W / 'mamba/envs/jdk8'; JDK21 = '/usr/lib/jvm/java-21-openjdk-amd64'
HIVE_META = W / 'hadoop_runtime/hive_meta'
SELF = str(CODE / 'bench_all.py')
ROUNDS = 5

# ------------------------------------------------------------------ дочірні
   завдання
def job_pandas(task, out):
    import pandas as pd
    df = pd.read_csv(CSV, float_precision='round_trip').dropna()
    if task == 'T1':
        y = pd.to_datetime(df['Timestamp'], unit='s').dt.year.rename('year')
```

```
        r = df.groupby(y).agg(candles=('Volume', 'size'), volume=('Volume',
   'sum')).reset_index()
    else:
        d = df.sort_values('Timestamp', kind='stable')
        day = (d['Timestamp'] // 86400).rename('day_n')
        r = d.groupby(day).agg(open=('Open', 'first'), high=('High', 'max'),
   low=('Low', 'min'), close=('Close', 'last'),
                               volume=('Volume', 'sum'), candles=('Volume',
   'size')).reset_index()
        r['day_n'] = pd.to_datetime(r['day_n'] * 86400,
   unit='s').dt.strftime('%Y-%m-%d')
    r.to_csv(Path(out) / 'result.csv', index=False, header=False)

def spark_session():
    from pyspark.sql import SparkSession
    s =
   (SparkSession.builder.master('local[*]').appName('bench').config('spark.driver.
   memory', '3g')
          .config('spark.sql.session.timeZone',
   'UTC').config('spark.sql.shuffle.partitions', '8')
          .config('spark.ui.enabled', 'false').getOrCreate())
    s.sparkContext.setLogLevel('ERROR')
    return s

def job_spark(task, out):
    from pyspark.sql import functions as F
    spark = spark_session()
    if task == 'start':
        spark.stop(); return
    schema = 'Timestamp DOUBLE, Open DOUBLE, High DOUBLE, Low DOUBLE, Close
   DOUBLE, Volume DOUBLE'
    s = spark.read.csv(f'file://{CSV}', header=True, schema=schema).na.drop()
    s = s.withColumn('t', F.timestamp_seconds(F.col('Timestamp').cast('long')))
    if task == 'T1':
        r =
   s.groupBy(F.year('t').alias('year')).agg(F.count('*').alias('candles'),
   F.sum('Volume').alias('volume'))
    else:
        r = (s.withColumn('day', F.date_format('t', 'yyyy-MM-dd')).groupBy('day')
             .agg(F.min_by('Open', 'Timestamp'), F.max('High'), F.min('Low'),
   F.max_by('Close', 'Timestamp'),
                  F.sum('Volume'), F.count('*')))
    r.coalesce(1).write.mode('overwrite').option('header',
   'false').csv(f'file://{out}/result')
    spark.stop()

if len(sys.argv) > 1 and sys.argv[1] == '--job':
    eng, task, out = sys.argv[2:5]
    {'pandas': job_pandas, 'spark': job_spark}[eng](task, out)
    sys.exit(0)

# ---------------------------------------------------------------- головний
   процес
import numpy as np, pandas as pd
os.environ.pop('JAVA_TOOL_OPTIONS', None)
ENV8 = dict(os.environ, JAVA_HOME=str(JDK8), HADOOP_HOME=str(HH),
   HIVE_HOME=str(HV), HADOOP_CONF_DIR=str(HH / 'etc/hadoop'),
            HADOOP_MAPRED_HOME=str(HH), PATH=f'{HH}/bin:{HV}/bin:{JDK8}/bin:' +
   os.environ['PATH'])
ENV21 = dict(os.environ, JAVA_HOME=JDK21, PATH=f'{JDK21}/bin:' +
   os.environ['PATH'])
STREAM_JAR = next((HH / 'share/hadoop/tools/lib').glob('hadoop-streaming-*.jar'))
PY = sys.executable

def sh(cmd, env=ENV8, cwd=None):
    t0 = time.perf_counter()
    p = subprocess.run(cmd, shell=True, executable='/bin/bash', env=env, cwd=cwd,
   capture_output=True, text=True)
    return p.returncode, p.stdout, p.stderr, time.perf_counter() - t0

def streaming_cmd(task):
```

```
    out = f'{HDFS_OUT}/bench_hs_{task}'
    if task == 'T1':
        m, r, c = 'mapper_year.py', 'reducer_year.py', 'reducer_year.py'
    else:
        m, r, c = 'mapper_ohlc.py', 'reducer_ohlc.py', None
    P1 = W / 'pz1/code'
    files = ','.join(str(P1 / f) for f in dict.fromkeys([m, r] + ([c] if c else
   [])))
    comb = f"-combiner 'python3 {c}'" if c else ''
    return out, (f"hadoop jar {STREAM_JAR} -D mapreduce.job.name=bench_{task} -D
   mapreduce.job.reduces=1 -files {files} "
                 f"-mapper 'python3 {m}' {comb} -reducer 'python3 {r}' -input
   {HDFS_RAW} -output {out}")

def prepare(engine, task):
    """Очищення вихідних каталогів (поза вимірюваним часом)."""
    if engine in ('pandas', 'spark'):
        d = SCR / f'{engine}_{task}'; shutil.rmtree(d, ignore_errors=True);
   d.mkdir(parents=True)
    elif engine == 'hadoop':
        sh(f'hdfs dfs -rm -r -f {HDFS_OUT}/bench_hs_{task}')
    elif engine == 'hive':
        sh(f'hdfs dfs -rm -r -f {HDFS_OUT}/bench_hive_{task}')

def command(engine, task):
    """Команда, яка вимірюється (від запуску процесу до готового результату)."""
    if engine == 'pandas':
        if task == 'start': return f'{PY} -c "import pandas"', ENV8, None
        return f'{PY} {SELF} --job pandas {task} {SCR}/pandas_{task}', ENV8, None
    if engine == 'spark':
        return f'{PY} {SELF} --job spark {task} {SCR}/spark_{task}', ENV21, None
    if engine == 'hadoop':
        if task == 'start':
            return (f"hadoop jar {STREAM_JAR} -D mapreduce.job.reduces=0 -mapper
   cat -input {HDFS_TINY} "
                    f"-output {HDFS_OUT}/bench_hs_start", ENV8, None)
        return streaming_cmd(task)[1], ENV8, None
    if engine == 'hive':
        if task == 'start': return 'hive -S -e "select 1"', ENV8, str(HIVE_META)
        return f'hive -S -f {CODE}/bench_{"yearly" if task == "T1" else
   "daily"}.hql', ENV8, str(HIVE_META)

def fetch(engine, task):
    """Результат у DataFrame без назв стовпців (поза вимірюваним часом)."""
    if engine in ('pandas', 'spark'):
        d = SCR / f'{engine}_{task}'
        f = d / 'result.csv' if engine == 'pandas' else next((d /
   'result').glob('part-*.csv'))
        return pd.read_csv(f, header=None, float_precision='round_trip')
    d = f'{HDFS_OUT}/bench_hs_{task}' if engine == 'hadoop' else
   f'{HDFS_OUT}/bench_hive_{task}'
    rc, o, e, _ = sh(f'hdfs dfs -cat {d}/*')
    assert rc == 0, e[-500:]
    import io
    return pd.read_csv(io.StringIO(o), sep='\t', header=None,
   float_precision='round_trip')

def normalise(df, task):
    if task == 'T1':
        df = df.iloc[:, :3].copy(); df.columns = ['year', 'candles', 'volume']
        return df.sort_values('year').reset_index(drop=True)
    df = df.iloc[:, :7].copy(); df.columns = ['day', 'open', 'high', 'low',
   'close', 'volume', 'candles']
    return df.sort_values('day').reset_index(drop=True)

REF = {}
def verify(engine, task):
    cur = normalise(fetch(engine, task), task)
    if engine == 'pandas' and task not in REF:
        REF[task] = cur
        return 'reference'
```

```
    ref = REF[task]
    ok = len(cur) == len(ref)
    if ok:
        ok = bool((cur.iloc[:, 0].astype(str).values == ref.iloc[:,
  0].astype(str).values).all())
        ok = ok and bool((cur['candles'].astype('int64').values ==
  ref['candles'].astype('int64').values).all())
        ok = ok and bool(np.allclose(cur['volume'], ref['volume'], rtol=1e-6,
  atol=0))
        if task == 'T2':
            for k in ('open', 'high', 'low', 'close'):
                ok = ok and bool((cur[k].values == ref[k].values).all())
    return 'ok' if ok else 'MISMATCH'

def mem_avail_gb():
    return round(int(re.search(r'MemAvailable:\s+(\d+)',
  open('/proc/meminfo').read()).group(1)) / 1048576, 2)

def run_once(engine, task, rnd, warm, rows, runs_csv):
    prepare(engine, task)
    if engine == 'hadoop' and task == 'start': sh(f'hdfs dfs -rm -r -f
  {HDFS_OUT}/bench_hs_start')
    cmd, env, cwd = command(engine, task)
    l1, mem, ts = os.getloadavg()[0], mem_avail_gb(), time.strftime('%Y-%m-%d %H:
  %M:%S')
    rc, o, e, t = sh(cmd, env, cwd)
    l2 = os.getloadavg()[0]
    status = 'rc=%d' % rc
    if rc == 0 and task != 'start':
        status = verify(engine, task)
    row = dict(round=rnd, warmup=warm, engine=engine, task=task, seconds=round(t,
  3), load1_before=l1, load1_after=l2,
               mem_available_gb=mem, timestamp=ts, check=status)
    print(row, flush=True)
    if rc != 0: print(e[-1500:], flush=True)
    rows.append(row); pd.DataFrame(rows).to_csv(runs_csv, index=False)
    return row

def quiet_wait(log, max_min=90):
    """Опитування щохвилини: load1 < 1,5 тричі поспіль і жодних сторонніх
  java/spark-процесів."""
    streak, quiet, polls = 0, False, []
    for i in range(max_min):
        la = os.getloadavg()[0]
        ps = subprocess.run("ps -eo pid,args", shell=True, capture_output=True,
  text=True).stdout.splitlines()
        others = []
        for l in ps:
            if re.search(r'java|spark-submit|pyspark|pz\d?_spark', l) and 'grep'
  not in l and 'bench_all' not in l:
                if re.search(r'org\.apache\.hadoop|kafka\.Kafka|kafka_2\.13|\bps
  -eo', l): continue   # демони Hadoop, Kafka (лише записується)
                others.append(l.strip()[:120])
        ok = la < 1.5 and not others
        streak = streak + 1 if ok else 0
        polls.append(dict(poll=i, time=time.strftime('%H:%M:%S'), load1=la,
  other_procs=len(others), streak=streak))
        print(polls[-1], flush=True)
        if streak >= 3: quiet = True; break
        time.sleep(60)
    pd.DataFrame(polls).to_csv(log, index=False)
    return quiet, len(polls)

def conditions(quiet, npolls, resdir):
    ver = lambda c, env=ENV8: subprocess.run(c, shell=True, env=env,
  capture_output=True, text=True).stdout.strip().splitlines()[:1]
    ps = subprocess.run("ps -eo comm,args", shell=True, capture_output=True,
  text=True).stdout
    import pyspark
    c = dict(start_time=time.strftime('%Y-%m-%d %H:%M:%S'), quiet_reached=quiet,
  polls=npolls,
```

```
            load1_start=os.getloadavg()[0], load5_start=os.getloadavg()[1],
   nproc=os.cpu_count(), mem_available_gb=mem_avail_gb(),
            kafka_running=bool(re.search(r'kafka\.Kafka|kafka_2\.13', ps)),
   mongod_running='mongod' in ps,
            pandas=pd.__version__, pyspark=pyspark.__version__,
   python=sys.version.split()[0],
            hadoop='3.3.6', hive='3.1.3 (MR)', jdk_hadoop_hive='8u472',
   jdk_spark='21',
            spark_cfg='local[*], driver 3g, shuffle.partitions 8, UI off',
   hadoop_cfg='1 reducer, 1 node YARN/HDFS (pseudo-distributed)')
     pd.DataFrame([c]).to_csv(resdir / 'bench_conditions.csv', index=False)

def summarise(runs, resdir):
    r = runs[~runs.warmup]
    ok = r[r.task.isin(['T1', 'T2'])]
    st = r[r.task == 'start'].groupby('engine').seconds.median()
    out = []
    for (e, t), g in ok.groupby(['engine', 'task'], sort=False):
        s = g.seconds; sm = st[e]; p = s - sm
        q1, q3 = s.quantile(.25), s.quantile(.75)
        out.append(dict(engine=e, task=t, median_total_s=round(s.median(), 2),
   median_startup_s=round(sm, 2),
                        median_processing_s=round(s.median() - sm, 2),
   min=round(s.min(), 2), max=round(s.max(), 2),
                        iqr=round(q3 - q1, 2), n=len(s),
   min_processing_s=round(p.min(), 2), max_processing_s=round(p.max(), 2),
                        all_checks_ok=bool((g.check.isin(['ok',
   'reference'])).all())))
    S = pd.DataFrame(out); S.to_csv(resdir / 'bench_summary.csv', index=False)
    return S

def figure(S, figdir):
    sys.path.insert(0, str(W / 'tools_report')); import plotstyle
    import matplotlib.pyplot as plt
    names = {'hadoop': 'Hadoop Streaming', 'hive': 'Hive (MR)', 'pandas':
   'pandas', 'spark': 'PySpark'}
    fig, axs = plt.subplots(2, 1, figsize=plotstyle.TWO_PANEL, sharex=True)
    for ax, (task, ttl) in zip(axs, [('T1', 'T1: свічки та обсяг за роками'),
   ('T2', 'T2: добові OHLC')]):
        g = S[S.task == task].set_index('engine').loc[list(names)]
        x = np.arange(len(g)); w = .38
        for off, col, lo, hi, lab, c in [(-w / 2, 'median_total_s', 'min', 'max',
   'Загальний час (зі стартом)', '#3b6ea5'),
                                         (w / 2, 'median_processing_s',
   'min_processing_s', 'max_processing_s', 'Без старту (обробка)', '#e08a2c')]:
            v = g[col].values
            ax.bar(x + off, v, w, color=c, label=lab, yerr=[v - g[lo].values,
   g[hi].values - v], capsize=3, error_kw=dict(lw=1))
            for xi, vi in zip(x + off, v): ax.text(xi, vi * 1.04 + 1,
   plotstyle.dec(vi, 1), ha='center', fontsize=9)
        ax.set_title(ttl); ax.set_ylabel('Час, с'); ax.set_ylim(0, g['max'].max()
   * 1.25)
        plotstyle.commas(ax)
    axs[0].legend(loc='upper right', frameon=False)
    axs[1].set_xticks(x); axs[1].set_xticklabels([names[e] for e in g.index])
    fig.tight_layout(); fig.savefig(figdir / 'fig_bench.png'); plt.close(fig)

def main():
    smoke = '--smoke' in sys.argv
    res = B / ('smoke' if smoke else 'results'); res.mkdir(parents=True,
   exist_ok=True)
    if not smoke: quiet, npolls = quiet_wait(res / 'bench_quiet_polls.csv')
    else: quiet, npolls = False, 0
    # підготовка: крихітний вхід для порожнього MR-завдання; перевірка заголовка
   таблиці Hive
    sh(f'hdfs dfs -mkdir -p {HDFS_TINY} && echo x | hdfs dfs -put -f -
   {HDFS_TINY}/one.txt')
    rc, o, e, _ = sh('hive -S -e "select count(*) from btc.candles"',
   cwd=str(HIVE_META))
    assert rc == 0 and o.strip().splitlines()[-1] == '7816537', (o, e[-500:])
    conditions(quiet, npolls, res)
```

```
    combos = [(e, t) for e in ('hadoop', 'hive', 'pandas', 'spark') for t in
  ('T1', 'T2')] + [(e, 'start') for e in ('hadoop', 'hive', 'pandas', 'spark')]
    # pandas T1/T2 першими в нульовому колі, щоб мати еталон для звірки
    combos.sort(key=lambda c: 0 if c[0] == 'pandas' and c[1] != 'start' else 1)
    # чергування: кожне коло проходить усі рушії та задачі; порядок рушіїв
  циклічно зсувається
    rows, runs_csv = [], res / 'bench_runs.csv'
    for rnd in range(0, 1 if smoke else ROUNDS + 1):
        order = combos[:]
        if rnd > 0:
            k = rnd % len(order); order = order[k:] + order[:k]
        else:
            order = combos
        for e, t in order:
            run_once(e, t, rnd, rnd == 0, rows, runs_csv)
    runs = pd.DataFrame(rows)
    if smoke: return
    S = summarise(runs, res); print(S.to_string(index=False))
    figure(S, B / 'figures')
    for p in (W / 'pz1/results', W / 'pz2/results'): shutil.copy(res /
  'bench_summary.csv', p / 'engine_benchmark.csv')

main()
```

A.18 Файл bench_yearly.hql – Hive-запит T1 для вимірювання часу

```
-- T1: свічки і сумарний обсяг за роками (без ORDER BY, як у Streaming);
  результат пишеться в HDFS
USE btc;
INSERT OVERWRITE DIRECTORY '/user/root/btc/out/bench_hive_T1'
ROW FORMAT DELIMITED FIELDS TERMINATED BY '\t'
SELECT year(trade_date), COUNT(*), SUM(volume)
FROM candles_v
GROUP BY year(trade_date);
```

A.19 Файл bench_daily.hql – Hive-запит T2 для вимірювання часу

```
-- T2: добові OHLC (open = open свічки з min ts, close = close свічки з max ts);
  результат пишеться в HDFS
USE btc;
INSERT OVERWRITE DIRECTORY '/user/root/btc/out/bench_hive_T2'
ROW FORMAT DELIMITED FIELDS TERMINATED BY '\t'
SELECT CAST(trade_date AS STRING), min(struct(ts, open)).col2, max(high),
  min(low),
      max(struct(ts, close)).col2, sum(volume), count(*)
FROM candles_v
GROUP BY trade_date;
```