Міністерство освіти і науки України
Харківський національний університет радіоелектроніки

Кафедра штучного інтелекту

Дисципліна «Аналітика великих даних»

Практичне заняття №5

«Інтелектуальний аналіз великих даних засобами Apache Spark MLlib»

Виконав:
ст. гр. ДМм-26-1
Зелінський В.С.

Прийняв:
Золотухін О.В.

Харків – 2026

# Інтелектуальний аналіз великих даних засобами Apache Spark MLlib

## Мета роботи

Мета роботи: ознайомитися з можливостями Apache Spark MLlib для інтелектуального аналізу великих даних; отримати практичні навички підготовки даних до машинного навчання, формування ознак, побудови та оцінювання моделей класифікації засобами PySpark на прикладі погодинних свічок BTC/USD (Bitcoin Historical Data), отриманих у ПЗ2 агрегацією 7 816 537 хвилинних записів, з прогнозом режиму волатильності наступної години.

## Короткі теоретичні відомості

Основу Spark MLlib становлять дві абстракції: трансформатор (Transformer) перетворює один DataFrame на інший методом `transform()`, оцінювач (Estimator) методом `fit()` навчається на даних і повертає трансформатор-модель. `Pipeline.fit()` навчає етапи послідовно лише на переданих даних і повертає `PipelineModel`, яку можна зберегти й застосувати до нових рядків.

Підготовка ознак виконується етапами того ж типу: `Imputer` заповнює пропуски статистикою навчальної вибірки, `StringIndexer` і `OneHotEncoder` кодують категоріальні значення, `VectorAssembler` збирає числові стовпці у вектор `features`, `StandardScaler` стандартизує ознаки, а `SQLTransformer` додає рядкові вирази SQL. Їх статистики обчислюються під час `fit()`, тож тестові дані не впливають на підготовку.

У роботі використано три класифікатори MLlib. Логістична регресія (`LogisticRegression`) – лінійна модель ймовірності класу з L1/L2-регуляризацією. Випадковий ліс (`RandomForestClassifier`) усереднює дерева, навчені на бутстреп-підвибірках. Градієнтний бустинг дерев (`GBTClassifier`) послідовно додає неглибокі дерева, кожне з яких виправляє помилки попередніх.

`BinaryClassificationEvaluator` обчислює ROC-AUC і PR-AUC за неперервною оцінкою; accuracy, precision, recall і F1 залежать від порогу. При частці класу 1 близько 25 % константа має accuracy 75 %, тому основними метриками обрано PR-AUC і F1.

Сусідні години мають схожу волатильність, тому вибірки формуються хронологічно, з проміжком (ембарго) між частинами, гіперпараметри підбираються крос-валідацією з розширюваним вікном, а невизначеність метрик оцінюється блочним бутстрепом.

Результати виконання практичного заняття

1 Визначення задачі

Вхідні дані – погодинна таблиця ознак ПЗ2 (`pz2_hourly_features.parquet`, 130 276 рядків) з OHLC, обсягом, кількістю flat-хвилин і реалізованою волатильністю `rv` (корінь із суми квадратів хвилинних лог-дохідностей). Відносно попереднього запуску ПЗ2 змінилася `rv` у 137 годинах на початку місяців (105 з них з 2018 року); ціни, обсяги й `n_minutes` збігаються. Кандидатів на ціль два: напрям ціни і рівень волатильності наступної години. Автокореляції годинних дохідностей `r` і їх модуля `|r|` за 2018–2026 роки показано на рисунку 1.

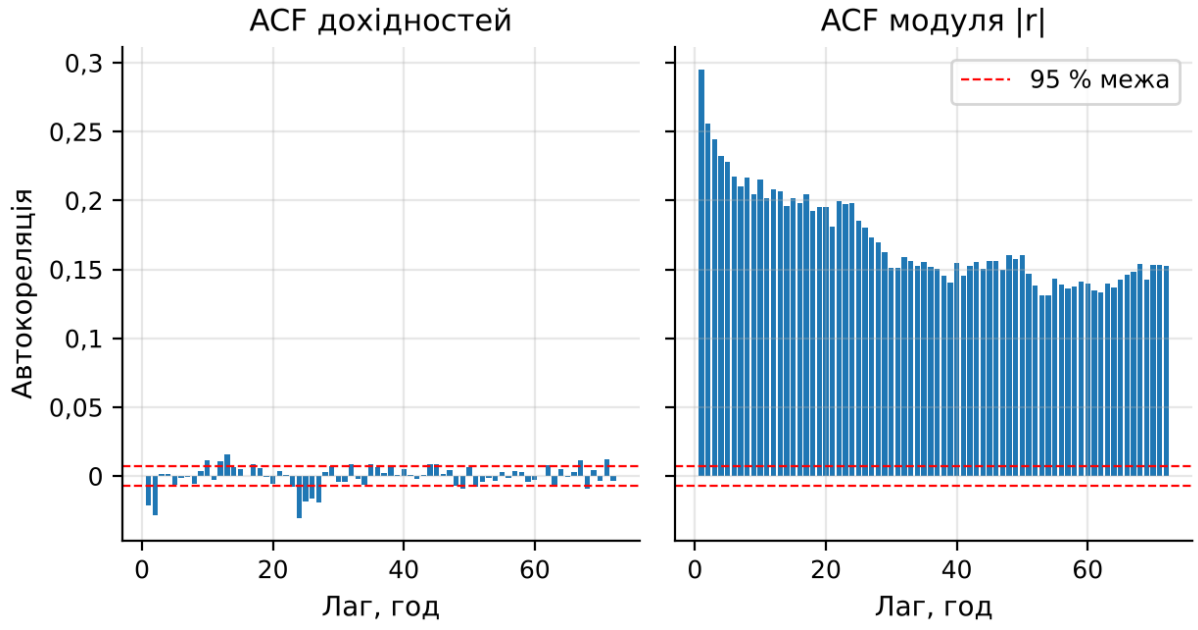



Рисунок 1 – Автокореляційні функції годинних дохідностей і їх модуля, 2018–2026 роки

Числові показники зведено в таблицю 1, разом з контрольною LR на мітці «дохідність наступної години > 0».

Таблиця 1 – Передбачуваність напряму ціни і волатильності (2018–2026 роки, 77 666 годин)

| Показник | Значення |
|---|---|
| ACF дохідності, лаг 1 / лаг 2 / лаг 24 | −0,0213 / −0,0288 / −0,0304 |
| ACF модуля дохідності, лаг 1 / лаг 24 / лаг 168 | 0,2951 / 0,1982 / 0,1445 |
| 95 % межа незначущої автокореляції | ±0,0070 |
| Частка годин зі зростанням ціни | 0,5066 |
| Правило «той самий знак»: усі години / train / test | 0,4644 / 0,4593 / 0,4847 |
| Правило «протилежний знак»: усі години / train / test | 0,5356 / 0,5407 / 0,5153 |
| Кореляція Спірмена r_t і r_t+1 | −0,0677 |
| LR для напряму на тесті: ROC-AUC / accuracy | 0,5266 / 0,5132 |
| Мажоритарний клас для напряму на тесті: accuracy | 0,5000 |

LR вгадала напрям у 7961 з 15 511 тестових годин: accuracy 0,5132, біноміальний тест дає z = 3,30, p = 0,001. Напрям статистично передбачуваний краще за 0,5, але перевага в 1,3 відсоткового пункта економічно мізерна. Точність 0,4644 правила «той самий знак» і 0,5356 правила «протилежний знак» пояснюються від'ємною кореляцією сусідніх годинних дохідностей (Спірмен −0,0677): після зростання частіше йде зниження, тобто діє короткострокове повернення до середнього. Ефект слабшає з часом (train 0,5407, test 0,5153). Волатильність має значно сильніший сигнал (ACF модуля 0,2951 на лагу 1), тому обрано задачу бінарної класифікації: чи буде наступна година високоволатильною.

## 2 Підготовка даних

### 2.1 Період моделювання

У П32 встановлено, що flat-хвилини – заповнення сітки, і при великій їх частці `rv` відображає неліквідність (доба 27.01.2012 з 98,1 % flat-хвилин потрапила до топ-5 за `rv`). Частку flat-хвилин за роками разом із часткою позитивного класу наведено в таблиці 2.

Таблиця 2 – Частка flat-хвилин, медіана rv і частка класу 1 за роками

| Показник | 2017 | 2018 | 2019 | 2020 | 2021 | 2022 | 2023 | 2024 | 2025 | 2026 |
|---|---|---|---|---|---|---|---|---|---|---|
| Flat, % | 8,04 | 3,77 | 3,28 | 1,55 | 0,70 | 2,66 | 3,95 | 3,33 | 1,13 | 0,34 |
| Медіана rv | 0,01010 | 0,00720 | 0,00579 | 0,00579 | 0,00735 | 0,00502 | 0,00294 | 0,00412 | 0,00324 | 0,00318 |
| Клас 1, ковзний поріг | – | 0,2185 | 0,2408 | 0,2665 | 0,2483 | 0,2305 | 0,2669 | 0,2617 | 0,2503 | 0,2482 |
| Клас 1, глоб. поріг | – | 0,4400 | 0,2597 | 0,2469 | 0,4352 | 0,2029 | 0,0581 | 0,1185 | 0,0711 | 0,0671 |

З 2018 року частка flat-хвилин не перевищує 3,95 %, а у 2017 році вона ще 8,04 %, тому моделювання почато з 01.01.2018. Відкинуто неповні години (`n_minutes < 60`) і години з неповною наступною: остання година 11.11.2026 03:00 має 38 хвилин, тому рядок 02:00 мітки не отримує. Залишилося 77 666 годин до 11.11.2026 01:00 UTC. Решту flat-хвилин не видалено, щоб не ламати годинну сітку, а їх частку `flat_share` передано моделі як ознаку.

2.2 Цільова змінна

Мітка години t дорівнює 1, якщо `rv` години t+1 перевищує 75-й перцентиль `rv` за останні 720 годин, включно з годиною t, і година t+1 повна:

```
d = (d.withColumn("thr_rv", F.expr(f"percentile_approx(rv, {PCT},
   10000)").over(roll(HI_WIN)))
        .withColumn("next_rv", F.lead("rv", 1).over(w_all))
        .withColumn("next_nmin", F.lead("n_minutes", 1).over(w_all))
        .withColumn("label", F.when(F.col("next_nmin") == 60,
                                    (F.col("next_rv") >
   F.col("thr_rv")).cast("int"))))
```

Поріг відомий у момент прогнозу. Перцентиль 75 % дає клас 1 близько чверті годин. Вікно 720 год (30 діб) встигає за зміною режиму: медіана `rv` впала з 0,00720 у 2018 році до 0,00318 у 2026 році (таблиця 2). Глобальний поріг 0,00793 (75-й перцентиль навчальної вибірки) дав би частку класу 1 від 0,0581 (2023) до 0,4400 (2018), тобто модель вчилася б розрізняти епохи, а не години. Ковзний поріг утримує частку в межах 0,2185–0,2669, що видно на рисунку 2.

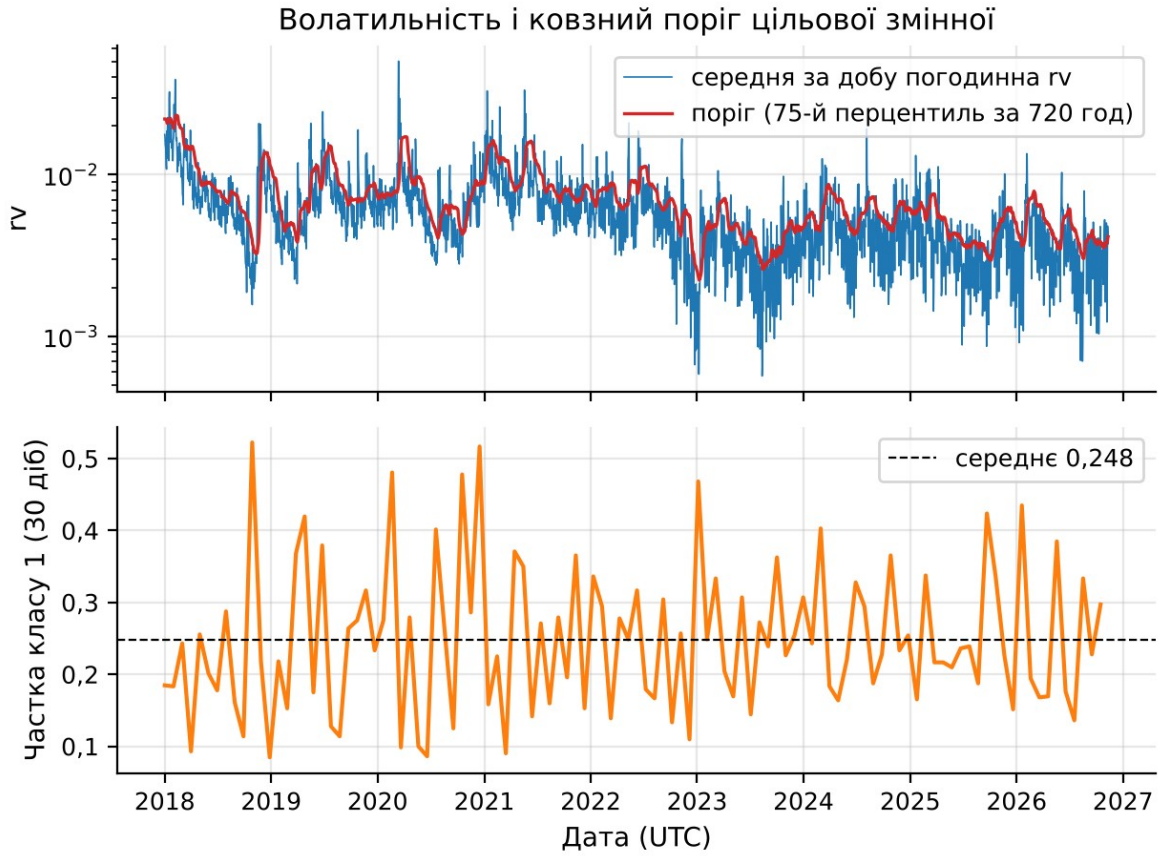



Рисунок 2 – Середня за добу погодинна rv, ковзний поріг і частка класу 1 у 30-добових вікнах

Частка класу 1 коливається навколо 0,248 без тренду, тож мітка не дрейфує.

2.3 Ознаки, пропуски та категоріальні змінні

Ознаки побудовано віконними функціями Spark (`lag` і рамки `rowsBetween`), тобто лише з годин до t включно. Волатильність прологарифмовано з доданком $10^{-5}$, бо її розподіл має важкий правий хвіст (годинний надлишковий ексцес дохідностей у ПЗ2 – 118,11), а поодинокі години з `rv = 0` дали б `log 0`. Склад ознак наведено в таблиці 3.

Таблиця 3 – Ознаки моделі та кількість пропусків (уся історія / рядки моделі)

| Група | Ознаки | Зміст | Пропуски |
|---|---|---|---|
| Рівень rv | log_rv_l0, _l1, _l2, _l5, _l23 | log rv години t і лагів | 0, 1, 2, 5, 23 / 0 |
| Ковзні середні rv | log_rv_m3, _m6, _m24, _m168 | log середньої rv за 3–168 год | 0 / 0 |
| Відносний рівень | log_rv_over_thr | log(rv_t / поріг_t) | 0 / 0 |
| Дохідність | ret_1h, abs_ret_1h, ret_6h | дохідність за 1 і 6 год, модуль | 1, 1, 6 / 0 |
| Діапазон і обсяг | log_rel_range, log_volume, vol_z168, flat_share | розмах, обсяг, z-оцінка обсягу, частка flat-хвилин | 0, 0, 1, 0 / 0 |
| Календар | hour_sin, hour_cos, is_weekend, dow | година (sin/cos), вихідний, день тижня (OneHot) | 0 / 0 |

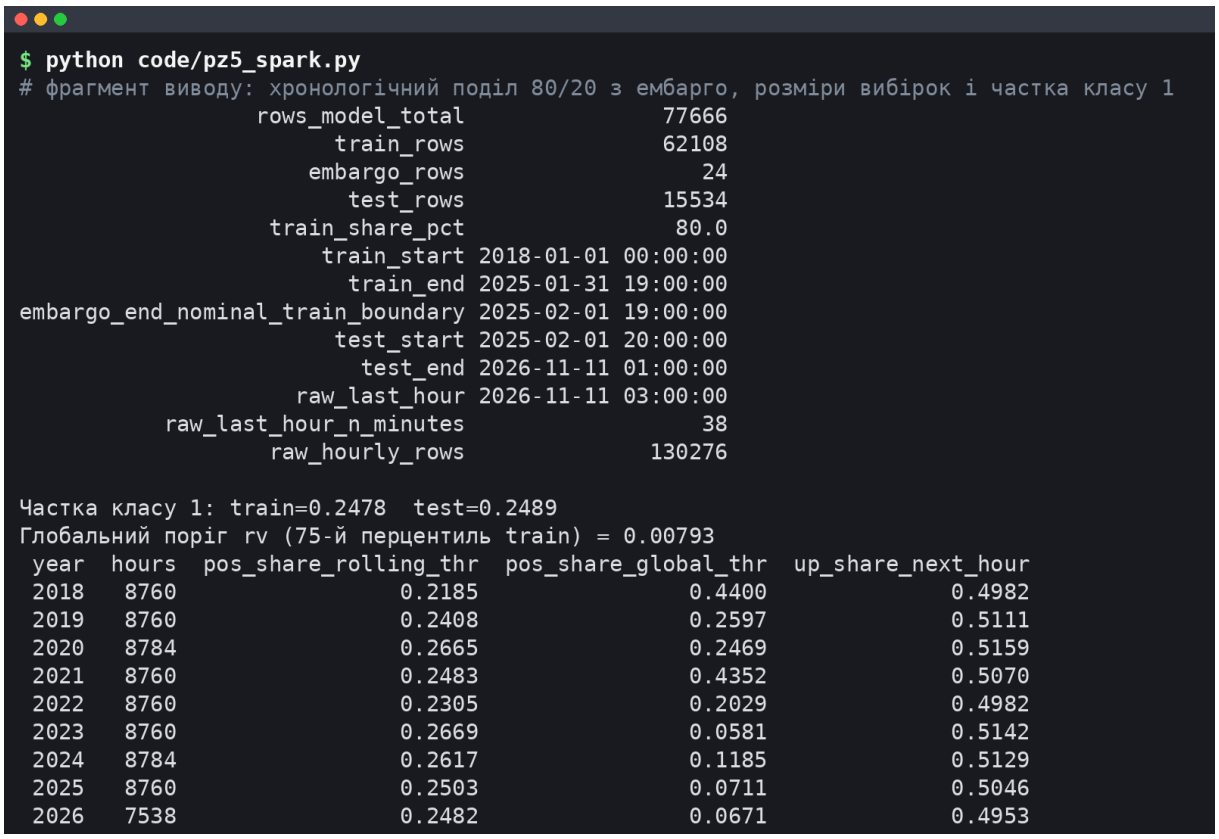
Пропуски є лише на початку історії 2012 року, де лагам і вікнам бракує попередніх годин (до 23 значень для `log_rv_l23`), тому в рядках з 2018 року їх немає. `Imputer` (медіана train) все одно включено в конвеєр для нових рядків. Годину закодовано через sin/cos, щоб 23:00 і 00:00 були поруч, день тижня як категоріальна ознака закодовано `StringIndexer` і `OneHotEncoder` (`dropLast=False`). Вектор ознак має 29 позицій разом зі службовими індикаторами невідомої категорії, які `OneHotEncoder` додає через `handleInvalid="keep"`. Ознаки відібрано за змістом; розділ 8.1 показує, що день тижня можна відкинути.

3 Формування вибірок

Ряд упорядковано за часом і поділено 80/20 за номером рядка: перші 80 % – навчальна вибірка, останні 20 % – тестова. Останні 24 години навчальної частини вилучено як ембарго:

```
n_train = int(N * 0.8)
train = m.filter(F.col("rn") <= n_train - EMB).cache()   # ембарго EMB = 24 год
test = m.filter(F.col("rn") > n_train).cache()
```

Розміри і межі вибірок, виведені програмою, показано на рисунку 3.



```
$ python code/pz5_spark.py
# фрагмент виводу: хронологічний поділ 80/20 з ембарго, розміри вибірок і частка класу 1
                  rows_model_total               77666
                        train_rows               62108
                       embargo_rows                  24
                          test_rows               15534
                     train_share_pct                80.0
                         train_start 2018-01-01 00:00:00
                           train_end 2025-01-31 19:00:00
embargo_end_nominal_train_boundary 2025-02-01 19:00:00
                         test_start 2025-02-01 20:00:00
                           test_end 2026-11-11 01:00:00
                      raw_last_hour 2026-11-11 03:00:00
            raw_last_hour_n_minutes                   38
                    raw_hourly_rows               130276

Частка класу 1: train=0.2478  test=0.2489
Глобальний поріг rv (75-й перцентиль train) = 0.00793
 year  hours  pos_share_rolling_thr  pos_share_global_thr  up_share_next_hour
 2018   8760                 0.2185                0.4400              0.4982
 2019   8760                 0.2408                0.2597              0.5111
 2020   8784                 0.2665                0.2469              0.5159
 2021   8760                 0.2483                0.4352              0.5070
 2022   8760                 0.2305                0.2029              0.4982
 2023   8760                 0.2669                0.0581              0.5142
 2024   8784                 0.2617                0.1185              0.5129
 2025   8760                 0.2503                0.0711              0.5046
 2026   7538                 0.2482                0.0671              0.4953
```

Рисунок 3 – Хронологічний поділ 80/20 з ембарго: межі, розміри вибірок і частка класу 1

Навчальна вибірка охоплює 62 108 годин (01.01.2018 00:00 – 31.01.2025 19:00), ембарго – 24 години, тестова – 15 534 години (01.02.2025 20:00 – 11.11.2026 01:00). Частка класу 1 майже однакова (0,2478 і 0,2489).

Мінімально необхідне ембарго – 1 год: мітка години t залежить від години t+1, і без проміжку остання навчальна мітка обчислювалася б з першої тестової години. 24 години взято із запасом. Проте ACF самої мітки становить 0,5165 на лагу 1, 0,2908 на лагу 24 і 0,0331 на лагу 720 і перевищує межу ±0,0070 для 675 з 720 лагів. Отже, ембарго усуває перекриття міток, але не залежність між навчальними і тестовими годинами; для повної незалежності знадобився б проміжок понад місяць, що лише відсунуло б тест без зміни висновків.

## 4 Побудова моделей

### 4.1 Моделі та гіперпараметри

Першою моделлю побудовано інтерпретовану LR, другою – деревні ансамблі RF і GBT, що вловлюють нелінійності й взаємодії.

Гіперпараметри підібрано на навчальній вибірці крос-валідацією з розширюваним вікном: валідаційні блоки – 50–66,7 %, 66,7–83,3 % і 83,3–100 % навчальної частини, кожен навчається на всіх попередніх годинах мінус 24 години ембарго. Критерій – середній PR-AUC, чутливий до рідшого класу 1; за ним же обирається модель, тест у виборі не бере участі. Сітки: regParam {0; 0,001; 0,01; 0,1} × elasticNetParam {0; 0,5}, numTrees {100; 200} × maxDepth {4; 8} × minInstancesPerNode {20; 100}, maxIter {50; 100} × maxDepth {3; 5} × stepSize {0,05; 0,1}. Результати наведено в таблиці 4.

Таблиця 4 – Сітки гіперпараметрів і найкращі конфігурації (часова крос-валідація, 3 блоки)

| Модель | Сітка (8 конфігурацій) | Найкраща конфігурація | CV ROC-AUC | CV PR-AUC за блоками | CV PR-AUC ± σ |
|---|---|---|---|---|---|
| LR | regParam × elasticNetParam | 0,001; 0 | 0,8625 | 0,7001 / 0,7557 / 0,7810 | 0,7456 ± 0,0338 |
| RF | numTrees × maxDepth × minInstancesPerNode | 100; 8; 20 | 0,8536 | 0,6753 / 0,7289 / 0,7683 | 0,7241 ± 0,0381 |
| GBT | maxIter × maxDepth × stepSize | 100; 3; 0,1 | 0,8680 | 0,7025 / 0,7438 / 0,7938 | 0,7467 ± 0,0373 |

За середнім CV PR-AUC обрано GBT (0,7467), але LR відстає лише на 0,0011 (0,7456) при розкиді між блоками 0,034–0,038, а в другому блоці LR навіть краща (0,7557 проти 0,7438). Отже, CV GBT і LR практично не розрізняє; RF нижчий в усіх блоках. Сильна регуляризація LR (regParam 0,1) знижує PR-AUC до 0,7193, для RF глибина 8 краща за 4 (0,7241 проти 0,6980). Повна сітка (24 конфігурації × 3 блоки) тривала 1038,573 с.

4.2 Поріг рішення

Поріг 0,5 не оптимальний для F1 при частці класу 1 близько 0,25, тому поріг обрано за максимумом середнього F1 трьох валідаційних блоків (перебір 0,05–0,95 з кроком 0,01), без доступу до тесту: LR 0,33 (F1 0,6585), RF 0,26 (0,6439), GBT 0,33 (0,6664). Оптимуми блоків різняться (для GBT 0,32, 0,30 і 0,36), тож усереднення стійкіше. Для GBT крива F1 полога: 0,6563 при 0,25 і 0,6372 при 0,45. У RF вона крутіша (0,5698 при 0,45), тому RF чутливіший до вибору порогу. Класові ваги (`weightCol`) не застосовано: ранжувальні метрики від них не залежать, а для F1 достатньо порогу.

5 ML Pipeline

У конвеєрі Data → Preprocessing → Feature Engineering → Model → Prediction → Evaluation читання Parquet і віконні ознаки виконуються до `Pipeline`, бо потребують упорядкування всього ряду, а етапи, що навчаються на даних (`SQLTransformer`, `Imputer`, `StringIndexer`, `OneHotEncoder`, `VectorAssembler`, масштабування і класифікатор), зібрано в `Pipeline` (рисунок 4).

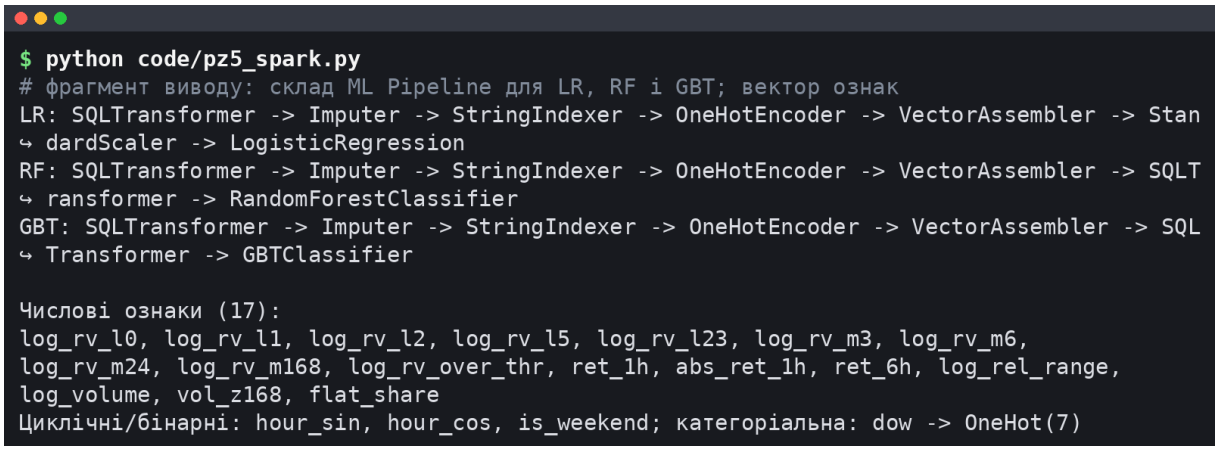



Рисунок 4 – Етапи ML Pipeline для LR, RF і GBT та склад вектора ознак

Стандартизація потрібна лише LR, у деревах замість `StandardScaler` стоїть тотожний `SQLTransformer`. Prediction – `PipelineModel.transform(test)`, Evaluation – `BinaryClassificationEvaluator` і матриця помилок. Обрану за CV модель (GBT) збережено `write().save()` у `results/model/best_pipeline_GBT` за 1,912 с і завантажено `PipelineModel.load()` за 2,338 с. Програма запустила 12 663 джоби (jobs) і 48 483 етапи (stages) Spark. Увесь сценарій на 4 ядрах Intel Xeon 2,10 ГГц тривав 1429,708 с, з них 41,642 с – віконні ознаки. Навантаження машини (load1 1,15–1,70) робить секундні виміри наближеними.

6 Оцінювання

Метрики методички (accuracy, precision, recall, F1, ROC-AUC) доповнено PR-AUC і коефіцієнтом Метьюза (MCC), коректними при нерівних класах; precision, recall і F1 – для класу 1. Базові лінії – мажоритарний клас (завжди 0), персистентність (клас 1, якщо `rv` поточної

години вже вища за поріг) і ранжування за однією ознакою `log(rv_t/порir_t)`. Персистентність має один робочий пункт (FPR 0,105, TPR 0,680). PR-AUC у Spark (`areaUnderPR`) – площа трапеціями з лінійною інтерполяцією, що для бінарної оцінки завищує площу: average precision персистентності 0,5441 проти PR-AUC 0,6135. Розрахунок у numpy збігся зі Spark з точністю 0,00003.

## 7 Порівняння моделей

### 7.1 Моделі та базові лінії

Метрики на тестовій вибірці, виведені програмою, показано на рисунку 5 і зведено в таблицю 5.

```
$ python code/pz5_spark.py
# фрагмент виводу: метрики на тесті: базові лінії та моделі (поріг 0,5 і поріг з валідації
Частка класу 1 у test: 0.2489; n=15534
Пороги з валідації: LR 0.33, RF 0.26, GBT 0.33
         модель  thr   acc  prec   rec    f1   mcc   ROC    PR
   Мажоритарний 0.50 0.751 0.000 0.000 0.000 0.000 0.500 0.249
Персистентність 0.50 0.842 0.683 0.680 0.682 0.576 0.788 0.614
   log(rv/порir 0.00 0.842 0.682 0.683 0.683 0.577 0.877 0.761
        LR @0.5 0.50 0.855 0.790 0.567 0.660 0.584 0.888 0.782
       LR @0.33 0.33 0.833 0.645 0.727 0.684 0.573 0.888 0.782
        RF @0.5 0.50 0.854 0.852 0.501 0.631 0.578 0.891 0.783
       RF @0.26 0.26 0.842 0.665 0.736 0.699 0.593 0.891 0.783
       GBT @0.5 0.50 0.864 0.816 0.588 0.683 0.613 0.901 0.802
      GBT @0.33 0.33 0.852 0.692 0.731 0.711 0.611 0.901 0.802

Час, с:
model  fit_seconds  inference_seconds_test  inference_rows_per_sec
   LR         4.08                    0.69                22410.55
   RF        23.45                    1.23                12652.42
  GBT        23.60                    0.57                27159.17
```

Рисунок 5 – Метрики моделей і базових ліній на тесті та час навчання й прогнозу

Таблиця 5 – Порівняння моделей і базових ліній на тестовій вибірці (15 534 год, частка класу 1 0,2489)

| Модель (поріг) | Accuracy | Precision | Recall | F1 | ROC-AUC | PR-AUC | MCC |
|---|---|---|---|---|---|---|---|
| Мажоритарний | 0,7511 | 0,0000 | 0,0000 | 0,0000 | 0,5000 | 0,2489 | 0,0000 |
| Персистентність | 0,8418 | 0,6829 | 0,6801 | 0,6815 | 0,7877 | 0,6135 | 0,5763 |
| log(rv/поріг) (0) | 0,8419 | 0,6821 | 0,6835 | 0,6828 | 0,8773 | 0,7608 | 0,5775 |
| LR (0,5) | 0,8548 | 0,7905 | 0,5668 | 0,6602 | 0,8875 | 0,7820 | 0,5838 |
| LR (0,33) | 0,8327 | 0,6455 | 0,7274 | 0,6840 | 0,8875 | 0,7820 | 0,5727 |
| RF (0,5) | 0,8541 | 0,8519 | 0,5012 | 0,6311 | 0,8907 | 0,7827 | 0,5776 |
| RF (0,26) | 0,8419 | 0,6649 | 0,7357 | 0,6985 | 0,8907 | 0,7827 | 0,5931 |
| GBT (0,5) | 0,8644 | 0,8162 | 0,5878 | 0,6834 | 0,9010 | 0,8024 | 0,6131 |
| GBT (0,33) | 0,8518 | 0,6916 | 0,7305 | 0,7105 | 0,9010 | 0,8024 | 0,6114 |

Поріг з валідації підвищив F1 усіх моделей за рахунок recall ціною precision: у RF F1 зріс з 0,6311 до 0,6985, recall – з 0,5012 до 0,7357, а

precision впала з 0,8519 до 0,6649. Accuracy малоінформативна (константа – 0,7511). Навчання тривало 23,448 с (RF), 23,602 с (GBT) і 4,080 с (LR).

Для оцінки невизначеності тест поділено на 93 тижневі блоки і виконано 1000 повторів блочного бутстрепу (seed 42) з парними різницями на тих самих блоках (таблиця 6).

Таблиця 6 – Тестові метрики та різниці з 95 % довірчими інтервалами (блочний бутстреп)

| Модель / порівняння | PR-AUC | 95 % ДІ | ROC-AUC | 95 % ДІ | F1 | 95 % ДІ |
|---|---|---|---|---|---|---|
| LR | 0,7820 | [0,7394; 0,8206] | 0,8875 | [0,8742; 0,8997] | 0,6840 | [0,6480; 0,7173] |
| RF | 0,7827 | [0,7402; 0,8200] | 0,8907 | [0,8788; 0,9021] | 0,6985 | [0,6648; 0,7283] |
| GBT | 0,8024 | [0,7630; 0,8363] | 0,9010 | [0,8896; 0,9113] | 0,7105 | [0,6797; 0,7390] |
| Персистентність | 0,6135 | [0,5731; 0,6533] | 0,7877 | [0,7708; 0,8035] | 0,6815 | [0,6468; 0,7153] |
| log(rv/поріг) | 0,7608 | [0,7132; 0,8022] | 0,8773 | [0,8632; 0,8901] | 0,6828 | [0,6482; 0,7159] |
| GBT − LR | +0,0203 | [+0,0144; +0,0280] | +0,0134 | [+0,0103; +0,0172] | +0,0265 | [+0,0174; +0,0356] |
| GBT − RF | +0,0197 | [+0,0142; +0,0261] | +0,0103 | [+0,0083; +0,0124] | +0,0120 | [+0,0075; +0,0168] |
| GBT − персистентність | +0,1888 | [+0,1785; +0,1990] | +0,1132 | [+0,1064; +0,1214] | +0,0290 | [+0,0211; +0,0373] |
| GBT − log(rv/поріг) | +0,0415 | [+0,0333; +0,0515] | +0,0236 | [+0,0205; +0,0275] | +0,0277 | [+0,0200; +0,0361] |

Інтервали окремих моделей широкі (для PR-AUC близько ±0,04) і перекриваються, а парні різниці вужчі, бо спільні важкі тижні компенсуються. Перевага GBT над LR мала (+0,0203 PR-AUC, +0,0134 ROC-AUC), але її інтервал не містить 0, так само як і перевага над RF. На тесті GBT стабільно, хоча й ненабагато, кращий, що узгоджується з вибором за CV. Над персистентністю виграш великий у PR-AUC (+0,1888), але в F1 лише +0,0290, а над однією ознакою `log(rv_t/порiг_t)` – +0,0415 PR-AUC.

7.2 Хронологічний і випадковий поділ

Вплив способу поділу перевірено на однакових годинах тесту з тими самими гіперпараметрами. A – хронологічна модель, B навчено на випадкових 80 % передтестового періоду. Варіант C – `randomSplit([0.8,`

`0.2], seed=42)` усіх 77 666 годин; C* – тестові години C, що потрапляють у період хронологічного тесту, а A* – хронологічна модель на тих самих 3180 годинах. Результати наведено в таблиці 7 і на рисунку 6.

Таблиця 7 – PR-AUC при хронологічному і випадковому поділі на однакових годинах

| Варіант | Train | Test | LR | RF | GBT |
|---|---|---|---|---|---|
| A: хронологічний | 62 108 | 15 534 | 0,7820 | 0,7827 | 0,8024 |
| B: випадкові 80 % до тесту | 49 550 | 15 534 | 0,7819 | 0,7846 | 0,8019 |
| B − A (95 % ДІ) | – | 15 534 | −0,0001 [−0,0004; +0,0002] | +0,0019 [+0,0003; +0,0038] | −0,0005 [−0,0030; +0,0018] |
| A*: хронологічний на годинах C* | 62 108 | 3 180 | 0,7743 | 0,7744 | 0,7946 |
| C*: випадковий 80/20, години тесту | 61 920 | 3 180 | 0,7795 | 0,7864 | 0,8077 |
| C* − A* (95 % ДІ) | – | 3 180 | +0,0052 [+0,0030; +0,0077] | +0,0120 [+0,0070; +0,0196] | +0,0131 [+0,0062; +0,0205] |
| C: випадковий 80/20, свій тест | 61 920 | 15 746 | 0,7441 | 0,7200 | 0,7520 |

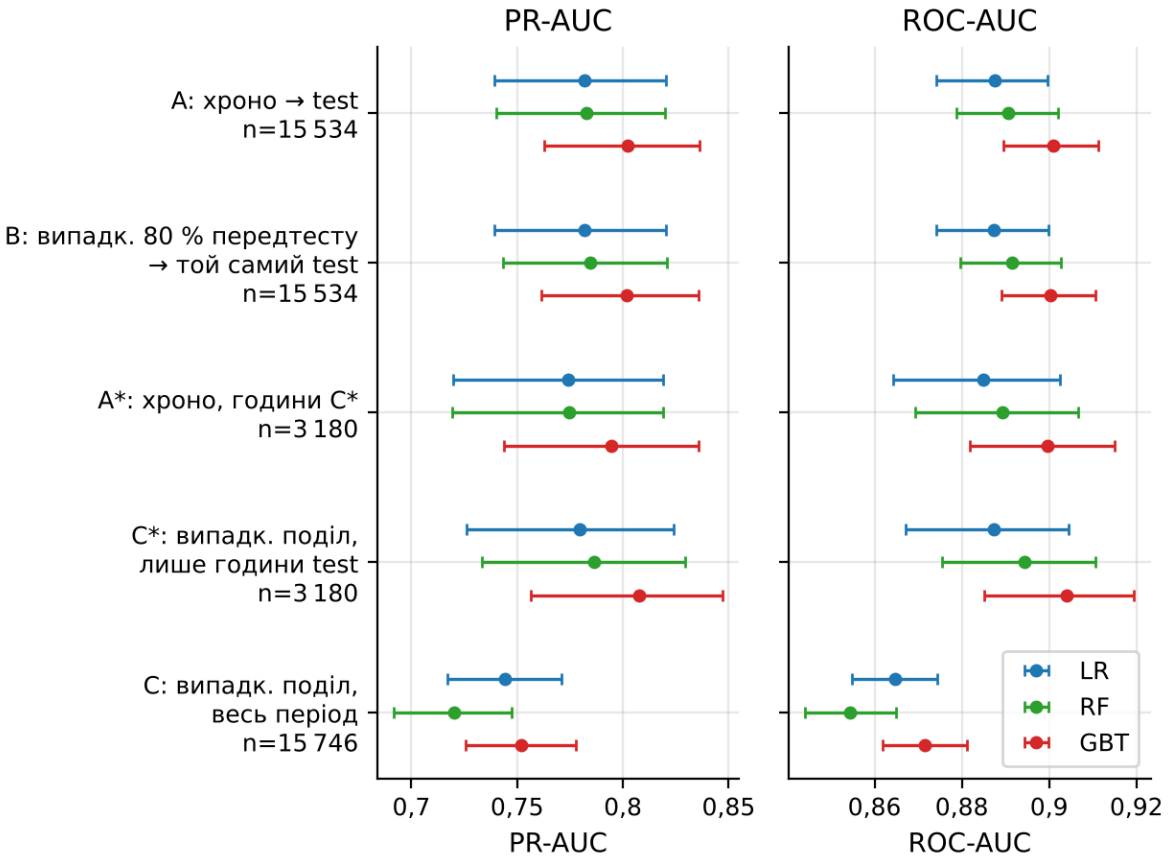



Рисунок 6 – PR-AUC і ROC-AUC з 95 % ДІ при хронологічному і випадковому поділі

Коли обидві моделі навчаються на порівнянному періоді до тесту (B і A), різниця PR-AUC не перевищує 0,002, тобто саме перемішування рядків навчальної вибірки метрик не змінює. Коли ж випадковий train містить сусідні години тестового періоду (C* і A*), PR-AUC вищий на 0,005–0,013 і інтервали не містять 0. Частка 0,6399 тестових годин C* має обох сусідів у train (у хронологічному поділі – жодна). Це помірний виток через часових сусідів: рядок t+1 містить `rv` години t+1 як ознаку, а від неї залежить мітка рядка t. На власному тесті C PR-AUC нижчий на 0,04–0,06, але це інші рядки 2018–2026 років, тож різниця відображає склад тесту. Тому для оцінки використано хронологічний поділ.

## 8 Аналіз результатів

### 8.1 Інформативність ознак

Важливості ознак показано на рисунку 7.

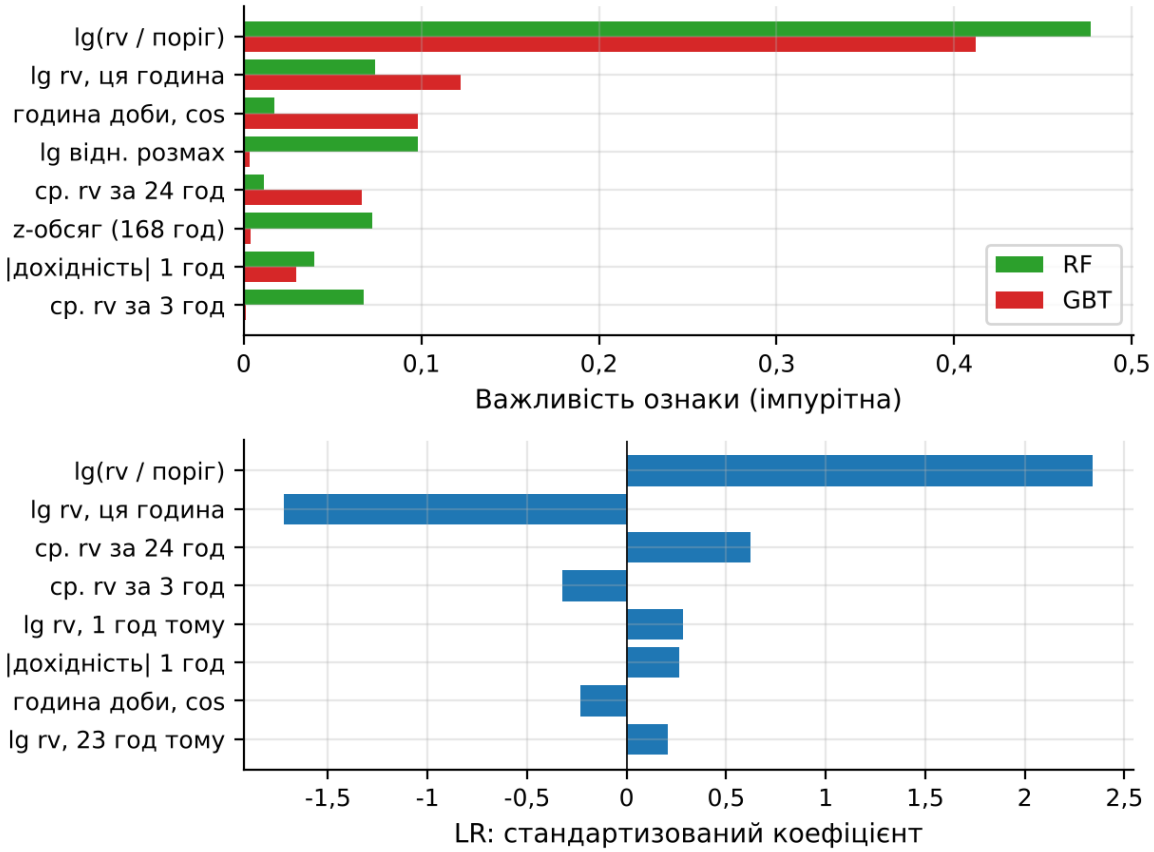



Рисунок 7 – Важливість ознак RF і GBT та стандартизовані коефіцієнти LR (8 найбільших)

Найінформативніша ознака в усіх трьох моделях – `log_rv_over_thr`: 0,4770 важливості в RF, 0,4121 у GBT і коефіцієнт

2,3413 у LR, що узгоджується з ROC-AUC 0,8773 цієї ознаки окремо. Далі в RF ідуть `log_rel_range` (0,0981), `log_rv_l0` (0,0741) і `vol_z168` (0,0722). GBT другою ставить `log_rv_l0` (0,1223), третьою – `hour_cos` (0,0978), а разом з `hour_sin` (0,0426) година доби набирає 0,1404 (внутрішньодобова сезонність, у П32 максимум обсягу о 14:00 UTC). Дохідності разом мають 0,0539 у RF і 0,0770 у GBT; день тижня (0,0027 у RF) і частка flat-хвилин (0,0054) майже не використовуються. Від'ємний коефіцієнт LR при `log_rv_l0` (−1,7199) – наслідок колінеарності з `log_rv_over_thr`. Імпурітні важливості зміщені на користь неперервних і корельованих ознак, тому це лише порядок величини.

8.2 Помилки моделей

З порогами з валідації GBT робить 2302 помилки з 15 534 (1260 хибно позитивних, 1042 хибно негативних), RF – 2456, LR – 2599. Помилки GBT за групами зведено в таблицю 8.

Таблиця 8 – Помилки GBT (поріг 0,33) за групами тестових годин

| Група | n | Частка класу 1 | Частка помилок | Recall | Precision |
|---|---|---|---|---|---|
| Поточна година нижче порогу | 11 683 | 0,1059 | 0,1064 | 0,2369 | 0,4949 |
| Поточна година вище порогу | 3 851 | 0,6829 | 0,2750 | 0,9627 | 0,7249 |
| Режим зберігається | 13 076 | – | 0,0304 | – | – |
| Початок сплеску (0 → 1) | 1 237 | – | 0,7631 | – | – |
| Завершення сплеску (1 → 0) | 1 221 | – | 0,7871 | – | – |
| 2025 рік | 7 996 | 0,2496 | 0,1471 | 0,7405 | 0,6919 |
| 2026 рік | 7 538 | 0,2482 | 0,1494 | 0,7199 | 0,6911 |

Основне джерело помилок – зміна режиму. Коли режим зберігається, частка помилок лише 0,0304, а на початку сплеску – 0,7631: recall у спокійних годинах 0,2369, тобто сплеск передбачається переважно тоді, коли він уже триває. Так само модель запізнюється із завершенням сплеску (частка помилок 0,7871), і 961 з 1260 хибних тривог припадає на години, коли поточна `rv` вища за поріг, а наступна вже спадає. Частка помилок 0,1471 у 2025 році і 0,1494 у 2026 році, тож деградації за 21 місяць немає. Розподіл за годиною доби показано на рисунку 8 (рядок години t прогнозує годину t+1).

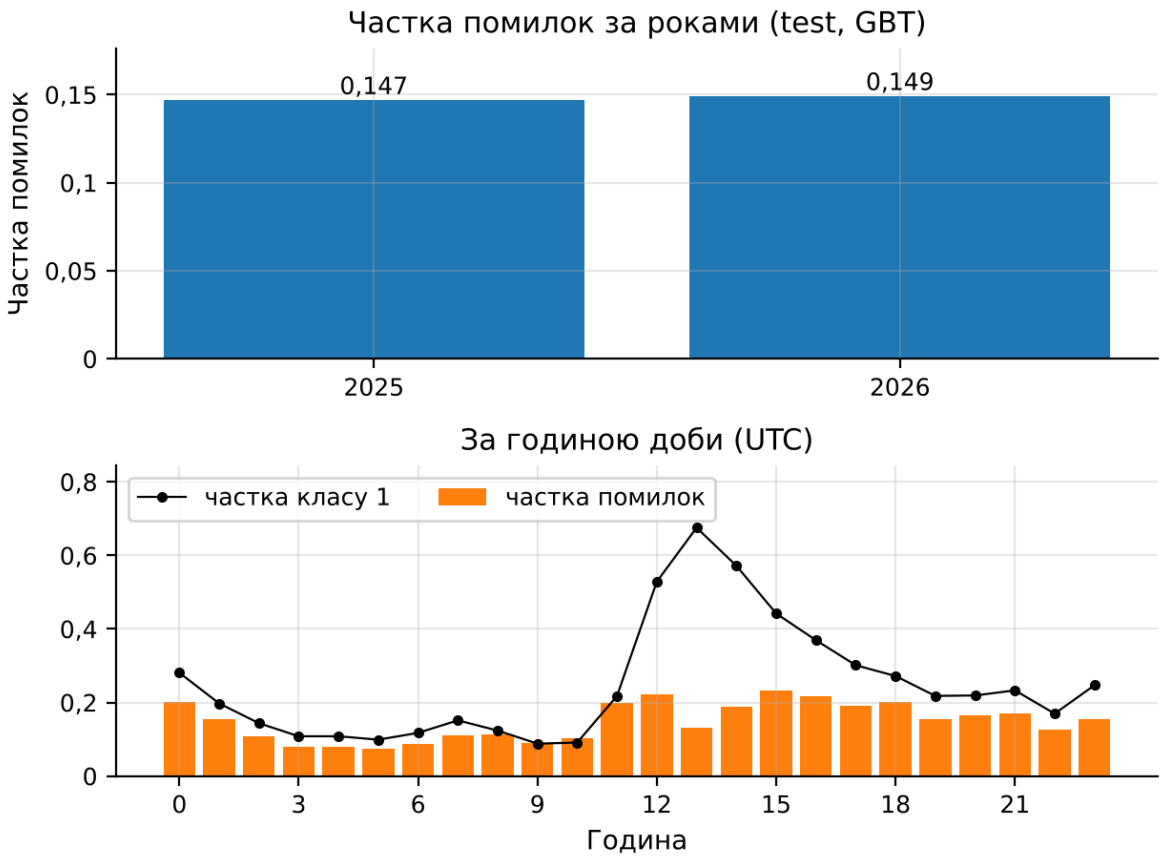



Рисунок 8 – Частка помилок GBT за роками та годиною доби (UTC)

Помилок найменше вночі (0,0742 у рядках 05:00) і найбільше вдень: 0,2226 у рядку 12:00 і 0,2318 у рядку 15:00. У рядку 12:00 частка класу 1 становить 0,5286, а recall лише 0,6959: сплеск на початку американської сесії (13:30–14:30 UTC залежно від літнього часу США) модель передбачає лише частково; за періодами літнього і зимового часу цю гіпотезу не перевіряли.

8.3 Шляхи вдосконалення

Резерв – у передбаченні початку і завершення сплесків: доцільно додати ознаки всередині години з хвилинних даних (`rv` останніх 15 хв, кількість стрибків, нахил обсягу) і календар подій (сесії США, макростатистика). Поріг доцільно обирати за вартістю помилок конкретного застосування, а модель перенавчати на ковзному вікні.

Висновки

1. Обрано задачу «чи буде наступна година високоволатильною»: напрям ціни передбачуваний статистично (accuracy 0,5132, p = 0,001),

але економічно мізерно, а правило «протилежний знак» (0,5356) відображає короткострокове повернення до середнього.

2. Дані підготовлено для 2018–2026 років (77 666 годин); ціль – перевищення `rv` над 75-м перцентилем за 720 годин, ознаки – 17 числових з минулого, година і день тижня.
3. Вибірки сформовано хронологічно 80/20 з ембарго 24 год (62 108 і 15 534 годин); ембарго усуває перекриття міток, але не залежність.
4. Побудовано LR (перша модель), RF і GBT (друга); модель обрано часовою CV за PR-AUC, де GBT (0,7467) і LR (0,7456) практично рівноцінні.
5. Реалізовано повний ML Pipeline MLlib; обрану модель збережено і повторно завантажено.
6. Якість оцінено метриками accuracy, precision, recall, F1, ROC-AUC, PR-AUC, MCC з 95 % інтервалами блочного бутстрепу.
7. Найкращі значення має GBT з порогом 0,33: F1 0,7105, ROC-AUC 0,9010, PR-AUC 0,8024 [0,7630; 0,8363]. Перевага над LR мала (+0,0203 PR-AUC), але її інтервал [+0,0144; +0,0280] не містить 0. Випадковий поділ завищує PR-AUC на 0,005–0,013, лише коли train містить сусідні години тесту.
8. Найінформативніша ознака – відношення `rv` до порогу; основні помилки – пропуск початку сплеску (0,7631) і запізнення з його завершенням (0,7871), резерв – внутрішньогодинні ознаки.

Набуто навичок формування ознак, побудови ML Pipeline, навчання та оцінювання моделей у Spark MLlib.

# Додаток А. Лістинг програми

Наведено повний код файлів, які запускає `code/run_all.sh` і які формують результати звіту. Допоміжний рендер текстового виводу в зображення терміналу (`make_screens.py` і спільні модулі оформлення `plotstyle.py`, `term_png.py`) результатів не змінює і тому не наведений.

## A.1 Файл run_all.sh – сценарій повного відтворюваного запуску

```
#!/usr/bin/env bash
# Повний відтворюваний запуск ПЗ5 одним командою:  bash code/run_all.sh   (з
   будь-якого каталогу). Seed 42.
# results/, figures/, screenshots/ створюються лише цим кодом (попередній запуск
   – у _old_run/).
set -euo pipefail
cd "$(dirname "$0")/.."
export JAVA_HOME=${JAVA_HOME:-/usr/lib/jvm/java-21-openjdk-amd64}
export PATH=$JAVA_HOME/bin:$PATH
mkdir -p results figures screenshots/txt
echo "start $(date '+%F %T'); loadavg: $(cat /proc/loadavg); nproc: $(nproc)" |
   tee results/run_all_log.txt
T0=$(date +%s)
step() { local s=$(date +%s); echo "== $1 ($(date '+%T'), loadavg $(cut -d' ' -
   f1-3 /proc/loadavg))" | tee -a results/run_all_log.txt; shift; "$@"; echo "   $
   (( $(date +%s)-s )) s" | tee -a results/run_all_log.txt; }
step "1 вхідні дані: порівняння з попереднім запуском ПЗ2" python
   code/input_diff.py
step "2 Spark MLlib (повний конвеєр, Spark UI)"           bash -c 'python
   code/pz5_spark.py 2>&1 | tee results/run.log'
step "3 статистика: бутстреп, поділи, напрям, ембарго"     bash -c 'python
   code/pz5_stats.py 2>&1 | tee results/stats.log'
step "4 рисунки"                                           python
   code/make_figures.py
step "5 рендер терміналів у PNG"                           python
   code/make_screens.py
T1=$(date +%s)
echo "run_all.sh wall-clock: $((T1-T0)) s (end $(date '+%F %T'); loadavg $(cat
   /proc/loadavg))" | tee -a results/run_all_log.txt
```

## A.2 Файл pz5_common.py – спільні шляхи, seed і захоплення виводу

```
# -*- coding: utf-8 -*-
"""Спільні шляхи та захоплення виводу для ПЗ5. Файл screenshots/txt/<name>.txt:
рядок 1 – справжня команда ('$ python code/...'), рядок 2 – коментар ('# …'),
   далі – реальний вивід."""
import os, io, sys, contextlib
BASE = os.path.abspath(os.path.join(os.path.dirname(__file__), ".."))
RES, FIG, SHOTS, TXT = f"{BASE}/results", f"{BASE}/figures",
   f"{BASE}/screenshots", f"{BASE}/screenshots/txt"
for _d in (RES, FIG, SHOTS, TXT):
    os.makedirs(_d, exist_ok=True)
SEED = 42

class Tee(io.StringIO):
    def write(self, s):
        sys.__stdout__.write(s); return super().write(s)

@contextlib.contextmanager
def cap(name, script, desc):
    """Дублює stdout у screenshots/txt/<name>.txt: '$ python code/<script>' + '#
   desc' + реальний вивід."""
    buf = Tee()
    with contextlib.redirect_stdout(buf):
        yield
```

```
    with open(f"{TXT}/{name}.txt", "w", encoding="utf-8") as f:
        f.write(f"$ python code/{script}\n# {desc}\n" + buf.getvalue())

def save(df, name):
    df.to_csv(f"{RES}/{name}.csv", index=False, encoding="utf-8")
```

## А.3 Файл input_diff.py – порівняння вхідних даних П32 з попереднім запуском

```
# -*- coding: utf-8 -*-
"""Порівняння вхідного parquet П32: попередній запуск (_old_run) проти поточного
   запуску; опорні числа П32 для звіту.
Запуск: python code/input_diff.py   ->  results/pz5_input_diff.csv,
   results/pz2_reference_numbers.csv"""
import os, sys
import numpy as np, pandas as pd
sys.path.insert(0, os.path.dirname(os.path.abspath(__file__)))
from pz5_common import RES, save
P2 = os.path.join(os.path.dirname(RES), "..", "pz2")
o =
   pd.read_parquet(f"{P2}/_old_run/results/pz2_hourly_features.parquet").set_index
   ("datetime_utc")
n =
   pd.read_parquet(f"{P2}/results/pz2_hourly_features.parquet").set_index("datetim
   e_utc")
rows = [("rows_old", len(o), len(o[o.index.year >= 2018]), None, None),
   ("rows_new", len(n), len(n[n.index.year >= 2018]), None, None),
        ("same_datetime_index (1=yes)", int(o.index.equals(n.index)),
   int(o.index.equals(n.index)), None, None),
        ("same_columns (1=yes)", int(list(o.columns) == list(n.columns)),
   int(list(o.columns) == list(n.columns)), None, None)]
common = o.index.intersection(n.index)
mod = common[common.year >= 2018]
for c in o.columns:
    a, b = o.loc[common, c], n.loc[common, c]
    if a.dtype.kind == "f":
        dif = ~np.isclose(a, b, rtol=1e-9, atol=0, equal_nan=True)
        rows.append((c, int(dif.sum()), int(dif[a.index.year >= 2018].sum()),
   float((a - b).abs().max()), float(((a - b).abs() / a.abs().clip(lower=1e-
   12)).max())))
    else:
        dif = (a != b).values
        rows.append((c, int(dif.sum()), int(dif[a.index.year >= 2018].sum()),
   0.0, 0.0))
out = pd.DataFrame(rows, columns=["item", "n_rows_differing_all_years",
   "n_rows_differing_2018plus", "max_abs_diff", "max_rel_diff"])
# уточнення: у яких годинах відрізняється rv
dif = ~np.isclose(o.loc[common, "rv"], n.loc[common, "rv"], rtol=1e-9, atol=0,
   equal_nan=True)
di = common[dif]
fm = (di.day == 1) & (di.hour == 0)
extra = pd.DataFrame([("rv_diff_rows_at_month_start_00h", int(fm.sum()), int((fm
   & (di.year >= 2018)).sum()), None, None),
                      ("rv_diff_rows_other_hours", int((~fm).sum()), int(((~fm) &
   (di.year >= 2018)).sum()), None, None)],
                     columns=out.columns)
save(pd.concat([out, extra]), "pz5_input_diff")
print(pd.concat([out, extra]).to_string(index=False))
# опорні числа П32, на які посилається звіт П35
sk = pd.read_csv(f"{P2}/results/pz2_skew_kurtosis.csv"); sk = sk[sk.iloc[:, 0] ==
   "1 год, усі"].iloc[0]
top = pd.read_csv(f"{P2}/results/pz2_top10_rv.csv")
vh =
   pd.read_csv(f"{P2}/results/pz2_volume_by_hour.csv").sort_values("volume_total",
   ascending=False).iloc[0]
cl = pd.read_csv(f"{P2}/results/pz2_cleaning.csv").set_index("metric").value
ref = pd.DataFrame([("pz2_rows_raw", int(cl["rows_raw"])), ("pz2_hourly_rows",
   len(n)),
                    ("pz2_hourly_return_excess_kurtosis_all", sk.iloc[5]),
```

```
                    ("pz2_flat_share_2012_01_27", float(top[top.date == "2012-01-
  27"].flat_share.iloc[0])),
                    ("pz2_top_volume_hour_utc", int(vh.hour)),
  ("pz2_top_volume_hour_share_pct", float(vh.share_pct))], columns=["parameter",
  "value"])
save(ref, "pz2_reference_numbers")
print(ref.to_string(index=False))
```

## A.4 Файл pz5_spark.py – конвеєр Spark MLlib: ознаки, мітка, поділ, навчання, оцінювання

```
# -*- coding: utf-8 -*-
"""ПЗ5. Apache Spark MLlib: прогноз «чи буде наступна година високоволатильною»
  (BTC/USD).
Запуск (з каталогу pz5):  python code/pz5_spark.py      (seed 42)
Результати -> results/, скріншоти терміналів (txt) -> screenshots/txt, знімки
  Spark UI -> screenshots/
"""
import os, sys, time, platform, subprocess, itertools, json, shutil
import numpy as np
import pandas as pd
sys.path.insert(0, os.path.dirname(os.path.abspath(__file__)))
from pz5_common import BASE, RES, SHOTS, TXT, SEED, cap as _cap, save
np.random.seed(SEED)
SRC = os.path.join(BASE, "..", "pz2", "results", "pz2_hourly_features.parquet")
  # результат попередньої обробки (ПЗ2)
SCRIPT = "pz5_spark.py"
def cap(name, desc): return _cap(name, SCRIPT, desc)
os.makedirs(f"{RES}/model", exist_ok=True)

from pyspark.sql import SparkSession, Window, functions as F
from pyspark.ml import Pipeline, PipelineModel
from pyspark.ml.feature import (Imputer, StringIndexer, OneHotEncoder,
  VectorAssembler,
                                StandardScaler, SQLTransformer)
from pyspark.ml.classification import LogisticRegression, RandomForestClassifier,
  GBTClassifier
from pyspark.ml.evaluation import BinaryClassificationEvaluator
from pyspark.ml.functions import vector_to_array
import pyspark

# ---------- допоміжні засоби ----------
TIMINGS, LOAD = [], []
def rec(step, secs, note=""):
    TIMINGS.append((step, round(secs, 3), note)); print(f"[timing] {step}:
  {secs:.2f} с {note}")
def sh(c):
    return subprocess.run(c, shell=True, capture_output=True,
  text=True).stdout.strip()
def loadavg(step):
    l1, l5, l15 = open("/proc/loadavg").read().split()[:3]
    top = sh("ps -eo pcpu,comm --sort=-pcpu --no-headers | head -4 | awk '{printf
  \"%s:%s \", $2, $1}'")
    LOAD.append((step, time.strftime("%Y-%m-%d %H:%M:%S"), float(l1), float(l5),
  float(l15), os.cpu_count(), top.strip()))

T_ALL = time.perf_counter()
loadavg("start")
spark = (SparkSession.builder.appName("PZ5_BTC_MLlib").master("local[*]")
         .config("spark.driver.memory", "8g")
         .config("spark.sql.shuffle.partitions", "16")
         .config("spark.sql.session.timeZone", "UTC")
         .config("spark.ui.port", "4040").config("spark.ui.showConsoleProgress",
  "false")
         .config("spark.sql.ansi.enabled", "false")
         .getOrCreate())
sc = spark.sparkContext; sc.setLogLevel("ERROR")

env = [("Java", sh("java -version 2>&1 | grep -v Picked | head -1")), ("Spark",
```

```
   spark.version),
       ("PySpark", pyspark.__version__), ("Python", platform.python_version()),
   ("pandas", pd.__version__),
       ("numpy", np.__version__), ("playwright", sh("pip show playwright | awk
   '/^Version/{print $2}'")),
       ("OS", platform.platform()),
       ("CPU", sh("lscpu | grep 'Model name' | sed 's/.*: *//'")),
   ("CPU_logical_cores", str(os.cpu_count())),
       ("RAM_GB", sh("free -g | awk '/Mem:/{print $2}'")), ("spark.master",
   sc.master),
       ("spark.driver.memory", "8g"), ("spark.sql.shuffle.partitions", "16"),
   ("seed", str(SEED)),
       ("spark.ui.url", sc.uiWebUrl), ("run_started", time.strftime("%Y-%m-%d %H:
   %M:%S")),
       ("loadavg_at_start", open("/proc/loadavg").read().strip()),
   ("input_parquet", SRC)]
pd.DataFrame(env, columns=["parameter",
   "value"]).to_csv(f"{RES}/env_versions.csv", index=False)
with cap("01_env", "версії ПЗ, ресурси машини та конфігурація SparkSession"):
    for k, v in env: print(f"{k:<20}{v}")

# ---------- Крок 1. Завантаження результатів попередньої обробки (ПЗ2)
   ----------
t = time.perf_counter()
raw = spark.read.parquet(SRC).orderBy("datetime_utc")
n_raw = raw.count()
rec("load_parquet_pz2", time.perf_counter() - t, f"{n_raw} годинних рядків")
last_raw = raw.orderBy(F.col("datetime_utc").desc()).select("datetime_utc",
   "n_minutes").first()
with cap("02_schema", "схема та перші рядки вхідного parquet (результат ПЗ2)"):
    raw.printSchema(); print("rows:", n_raw)
    raw.select("datetime_utc", "close", "volume", "n_minutes", "rv",
   "ret_1h").show(3, False)

# ---------- Крок 2. Обґрунтування вибору періоду та задачі (з даних) ----------
flat_year = (raw.groupBy("year").agg(F.count("*").alias("hours"), F.round(100 *
   F.sum("n_flat") / F.sum("n_minutes"), 2).alias("flat_share_pct"),
                                        F.round(F.avg("rv"), 5).alias("mean_rv"),
   F.round(F.expr("percentile_approx(rv,0.5)"), 5).alias("median_rv"),
                                        F.sum((F.col("volume") ==
   0).cast("int")).alias("zero_vol_hours")).orderBy("year").toPandas())
save(flat_year, "pz5_flat_share_by_year")
START_YEAR = 2018   # з 2018 р. частка «пласких» хвилин < 4 % щороку (див.
   pz5_flat_share_by_year.csv)
with cap("03_period", "частка пласких хвилин і rv за роками (вибір періоду
   моделювання)"):
    print(flat_year.to_string(index=False)); print(f"\nПеріод моделювання: з
   {START_YEAR} р.")

# ---------- Крок 3. Формування ознак і цільової змінної (лише з минулого)
   ----------
HI_WIN, PCT = 720, 0.75     # поріг «висока волатильність» = 75-й перцентиль rv
   за останні 720 год (30 діб), включно з поточною годиною
EMB = 24                    # ембарго (год) між навчальною та тестовою частинами
w_all = Window.orderBy("datetime_utc")
def roll(n): return w_all.rowsBetween(-(n - 1), 0)
EPS = 1e-5
d = raw.withColumn("log_rv", F.log(F.col("rv") + EPS))
for k in (1, 2, 5, 23): d = d.withColumn(f"log_rv_l{k}", F.lag("log_rv",
   k).over(w_all))
d = d.withColumn("log_rv_l0", F.col("log_rv"))
for n in (3, 6, 24, 168): d = d.withColumn(f"log_rv_m{n}",
   F.log(F.avg("rv").over(roll(n)) + EPS))
d = (d.withColumn("thr_rv", F.expr(f"percentile_approx(rv, {PCT},
   10000)").over(roll(HI_WIN)))   # лише рядки <= t
       .withColumn("log_rv_over_thr", F.log(F.col("rv") + EPS) -
   F.log(F.col("thr_rv") + EPS))
       .withColumn("abs_ret_1h", F.abs("ret_1h"))
       .withColumn("ret_6h", F.log(F.col("close") / F.lag("close",
   6).over(w_all)))
       .withColumn("log_rel_range", F.log(F.col("rel_range") + EPS))
```

```
        .withColumn("vol_z168", (F.col("log_volume") -
   F.avg("log_volume").over(roll(168))) / (F.stddev("log_volume").over(roll(168))
   + 1e-9))
        .withColumn("next_rv", F.lead("rv", 1).over(w_all))
        .withColumn("next_ret", F.lead("ret_1h", 1).over(w_all))
        .withColumn("next_nmin", F.lead("n_minutes", 1).over(w_all))
        # мітка визначена лише якщо НАСТУПНА година повна (60 хв): неповна остання
   година мітку не формує
        .withColumn("label", F.when(F.col("next_nmin") == 60, (F.col("next_rv") >
   F.col("thr_rv")).cast("int")))
        .withColumn("label_dir", F.when(F.col("next_nmin") == 60,
   F.when(F.col("next_ret") > 0, 1).when(F.col("next_ret") < 0, 0)))
        .withColumn("persist", (F.col("rv") > F.col("thr_rv")).cast("double")))
NUM = ["log_rv_l0", "log_rv_l1", "log_rv_l2", "log_rv_l5", "log_rv_l23",
   "log_rv_m3", "log_rv_m6", "log_rv_m24", "log_rv_m168",
        "log_rv_over_thr", "ret_1h", "abs_ret_1h", "ret_6h", "log_rel_range",
   "log_volume", "vol_z168", "flat_share"]
base_cols = ["datetime_utc", "year", "hour", "dow", "n_minutes", "label",
   "label_dir", "persist", "rv", "next_rv", "thr_rv", "ret_1h", "next_ret"] + NUM
base_cols = list(dict.fromkeys(base_cols))
t = time.perf_counter()
m = d.select(*base_cols)
# кількість пропусків ДО фільтрації (розігрів вікон на початку історії)
nulls_before = m.select([F.sum(F.col(c).isNull().cast("int")).alias(c) for c in
   NUM + ["label"]]).toPandas().T.reset_index()
nulls_before.columns = ["column", "nulls_full_history"]
m = (m.filter((F.col("year") >= START_YEAR) & (F.col("n_minutes") == 60) &
   F.col("label").isNotNull())   # неповні бари (поточний і наступний) виключені
        .withColumn("rn",
   F.row_number().over(Window.orderBy("datetime_utc"))).cache())
N = m.count()
rec("feature_engineering", time.perf_counter() - t, f"{N} рядків моделювання")
nulls_after = m.select([F.sum(F.col(c).isNull().cast("int")).alias(c) for c in
   NUM + ["label"]]).toPandas().T.reset_index()
nulls_after.columns = ["column", "nulls_model_rows"]
save(nulls_before.merge(nulls_after, on="column"), "pz5_missing_values")

# ---------- Хронологічний поділ 80/20 ----------
n_train = int(N * 0.8)
bounds = m.filter(F.col("rn").isin(1, n_train - EMB, n_train, n_train + 1,
   N)).select("rn", "datetime_utc").orderBy("rn").toPandas()
train = m.filter(F.col("rn") <= n_train - EMB).cache()      # ембарго: останні 24
   год навчальної частини вилучено
test = m.filter(F.col("rn") > n_train).cache()
n_tr, n_te = train.count(), test.count()
TEST_START = pd.Timestamp(bounds.datetime_utc[3])
sp = pd.DataFrame([("rows_model_total", N), ("train_rows", n_tr),
   ("embargo_rows", EMB), ("test_rows", n_te),
                   ("train_share_pct", round(100 * n_train / N, 2)),
   ("train_start", str(bounds.datetime_utc[0])),
                   ("train_end", str(bounds.datetime_utc[1])),
   ("embargo_end_nominal_train_boundary", str(bounds.datetime_utc[2])),
                   ("test_start", str(bounds.datetime_utc[3])), ("test_end",
   str(bounds.datetime_utc[4])),
                   ("raw_last_hour", str(last_raw["datetime_utc"])),
   ("raw_last_hour_n_minutes", int(last_raw["n_minutes"])),
                   ("raw_hourly_rows", n_raw)], columns=["parameter", "value"])
save(sp, "pz5_split")
lab = {}
for nm, df in (("train", train), ("test", test)):
    r = df.agg(F.avg("label").alias("pos"),
   F.avg("label_dir").alias("up")).first(); lab[nm] = (r["pos"], r["up"])
# Дрейф: частка позитивних за роками при ковзному порозі (основний) і при
   глобальному порозі з навчальної вибірки
glob_thr = train.approxQuantile("next_rv", [PCT], 1e-4)[0]
yr = (m.withColumn("label_global", (F.col("next_rv") >
   glob_thr).cast("int")).groupBy("year")
        .agg(F.count("*").alias("hours"), F.round(F.avg("label"),
   4).alias("pos_share_rolling_thr"),
             F.round(F.avg("label_global"), 4).alias("pos_share_global_thr"),
   F.round(F.avg("label_dir"),
```

```
   4).alias("up_share_next_hour")).orderBy("year").toPandas())
save(yr, "pz5_target_share_by_year")
ts = m.select("datetime_utc", "year", "label", "rv", "next_rv", "thr_rv",
   "ret_1h", "next_ret", "label_dir", "rn").toPandas().sort_values("datetime_utc")
ts["split"] = np.where(ts.rn <= n_train - EMB, "train", np.where(ts.rn > n_train,
   "test", "embargo"))
ts.drop(columns=["rn"]).to_csv(f"{RES}/pz5_target_series.csv", index=False)
with cap("04_split", "хронологічний поділ 80/20 з ембарго, розміри вибірок і
   частка класу 1"):
    print(sp.to_string(index=False, header=False))
    print(f"\nЧастка класу 1: train={lab['train'][0]:.4f}  test={lab['test']
   [0]:.4f}")
    print(f"Глобальний поріг rv (75-й перцентиль train) = {glob_thr:.5f}")
    print(yr.to_string(index=False))

# ---------- Чому не напрям ціни: ACF та базові лінії ----------
pdf = ts[["datetime_utc", "ret_1h", "label_dir", "next_ret"]]
r = pdf.ret_1h.values; ar = np.abs(r)
def acf(x, k):
    x = x - x.mean(); return float((x[:-k] * x[k:]).sum() / (x * x).sum())
nn = len(r); conf = 1.96 / np.sqrt(nn)
acf_df = pd.DataFrame({"lag_h": range(1, 73), "acf_ret": [acf(r, k) for k in
   range(1, 73)], "acf_abs_ret": [acf(ar, k) for k in range(1, 73)]})
acf_df["conf95"] = conf
save(acf_df, "pz5_acf")
dirv = pdf.dropna(subset=["label_dir"])
up_share = dirv.label_dir.mean()
same_sign_acc = float(((np.sign(dirv.ret_1h) > 0).astype(int) == dirv.label_dir)
   [dirv.ret_1h != 0].mean())   # правило «знак як у поточній годині»
dir_base = pd.DataFrame([("n_hours", nn), ("conf95_bound", conf),
   ("acf_ret_lag1", acf_df.acf_ret[0]), ("acf_abs_ret_lag1",
   acf_df.acf_abs_ret[0]),
                            ("acf_abs_ret_lag24", acf_df.acf_abs_ret[23]),
   ("acf_abs_ret_lag168_not_shown", acf(ar, 168)),
                            ("up_share_next_hour", up_share),
   ("majority_accuracy_direction", max(up_share, 1 - up_share)),
                            ("same_sign_rule_accuracy_all_hours", same_sign_acc),
   ("opposite_sign_rule_accuracy_all_hours", 1 - same_sign_acc)],
                          columns=["metric", "value"])
with cap("05_acf", "ACF дохідностей і модуля дохідностей; базові лінії задачі
   «напрям»"):
    print(dir_base.to_string(index=False))
    print("\nlag  ACF(ret)  ACF(|ret|)");
   print(acf_df.head(6).round(4).to_string(index=False))

# ---------- Пайплайни ----------
SQLT = SQLTransformer(statement="SELECT *, sin(2*pi()*hour/24.0) AS hour_sin,
   cos(2*pi()*hour/24.0) AS hour_cos, "
                                   "CAST(dow AS STRING) AS dow_str, CASE WHEN dow IN
   (1,7) THEN 1.0 ELSE 0.0 END AS is_weekend FROM __THIS__")
CYC = ["hour_sin", "hour_cos", "is_weekend"]
FEATS = NUM
def stages(model, scale):
    st = [SQLT,
          Imputer(inputCols=FEATS, outputCols=[c + "_imp" for c in FEATS],
   strategy="median"),     # пропуски -> медіана train
          StringIndexer(inputCol="dow_str", outputCol="dow_idx",
   handleInvalid="keep"),
          OneHotEncoder(inputCols=["dow_idx"], outputCols=["dow_ohe"],
   handleInvalid="keep", dropLast=False),  # категоріальна ознака
          VectorAssembler(inputCols=[c + "_imp" for c in FEATS] + CYC +
   ["dow_ohe"], outputCol="features_raw", handleInvalid="keep")]
    if scale:
        st.append(StandardScaler(inputCol="features_raw", outputCol="features",
   withMean=True, withStd=True))
    else:
        st.append(SQLTransformer(statement="SELECT *, features_raw AS features
   FROM __THIS__"))
    return st + [model]
def mk(name, p):
    if name == "LR":
```

```
        return Pipeline(stages=stages(LogisticRegression(featuresCol="features",
   labelCol="label", maxIter=200, regParam=p["regParam"],

   elasticNetParam=p["elasticNetParam"], standardization=False), True))
    if name == "RF":
        return
   Pipeline(stages=stages(RandomForestClassifier(featuresCol="features",
   labelCol="label", seed=SEED, numTrees=p["numTrees"],

   maxDepth=p["maxDepth"], minInstancesPerNode=p["minInstancesPerNode"],
   subsamplingRate=0.8), False))
    return Pipeline(stages=stages(GBTClassifier(featuresCol="features",
   labelCol="label", seed=SEED, maxIter=p["maxIter"], maxDepth=p["maxDepth"],
                                               stepSize=p["stepSize"],
   subsamplingRate=0.8), False))
GRIDS = {"LR": {"regParam": [0.0, 0.001, 0.01, 0.1], "elasticNetParam": [0.0,
   0.5]},
         "RF": {"numTrees": [100, 200], "maxDepth": [4, 8],
   "minInstancesPerNode": [20, 100]},
         "GBT": {"maxIter": [50, 100], "maxDepth": [3, 5], "stepSize": [0.05,
   0.1]}}
def combos(g): return [dict(zip(g, v)) for v in itertools.product(*g.values())]
import textwrap
with cap("06_pipeline", "склад ML Pipeline для LR, RF і GBT; вектор ознак"):
    for nm in ("LR", "RF", "GBT"):
        pl = mk(nm, combos(GRIDS[nm])[0])
        print(f"{nm}: " + " -> ".join(type(s).__name__ for s in pl.getStages()))
    print(f"\nЧислові ознаки ({len(FEATS)}):"); print("\n".join(textwrap.wrap(",
   ".join(FEATS), 86)))
    print(f"Циклічні/бінарні: {', '.join(CYC)}; категоріальна: dow -> OneHot(7)")

# ---------- Метрики ----------
ev_roc = BinaryClassificationEvaluator(rawPredictionCol="p1", labelCol="label",
   metricName="areaUnderROC")
ev_pr = BinaryClassificationEvaluator(rawPredictionCol="p1", labelCol="label",
   metricName="areaUnderPR")
def with_p1(pred):
    return pred.withColumn("p1", vector_to_array("probability")[1])
def metrics(df, thr=0.5, auc=True):
    """df має p1 (оцінка класу 1) та label. precision/recall/F1 – для класу
   «висока волатильність» (1)."""
    q = df.withColumn("yhat", (F.col("p1") >= thr).cast("int"))
    c = q.groupBy("label", "yhat").count().toPandas()
    g = lambda a, b: int(c[(c.label == a) & (c.yhat == b)]["count"].sum())
    tn, fp, fn, tp = g(0, 0), g(0, 1), g(1, 0), g(1, 1)
    n = tn + fp + fn + tp
    prec = tp / (tp + fp) if tp + fp else 0.0; rec_ = tp / (tp + fn) if tp + fn
   else 0.0
    f1 = 2 * prec * rec_ / (prec + rec_) if prec + rec_ else 0.0
    spec = tn / (tn + fp) if tn + fp else 0.0
    mcc_d = np.sqrt(float(tp + fp) * (tp + fn) * (tn + fp) * (tn + fn))
    return dict(threshold=thr, accuracy=(tp + tn) / n, precision=prec,
   recall=rec_, f1=f1, balanced_accuracy=(rec_ + spec) / 2,
                mcc=((tp * tn - fp * fn) / mcc_d) if mcc_d else 0.0,
                roc_auc=ev_roc.evaluate(df) if auc else np.nan,
   pr_auc=ev_pr.evaluate(df) if auc else np.nan,
                tn=tn, fp=fp, fn=fn, tp=tp, n=n)

# ---------- Часова валідація: розширюване вікно (3 фолди) з ембарго ----------
FOLDS = [(0.50, 0.667), (0.667, 0.833), (0.833, 1.0)]
cuts = [(int(n_tr * a), int(n_tr * b)) for a, b in FOLDS]
def fold_data(i):
    a, b = cuts[i]
    return train.filter(F.col("rn") <= a - EMB), train.filter((F.col("rn") > a) &
   (F.col("rn") <= b))
fold_rows = []
for i in range(3):
    a, b = cuts[i]; tri, vai = fold_data(i)
    fold_rows.append(dict(fold=i + 1, train_rows=tri.count(), embargo=EMB,
   val_rows=vai.count(), val_rn_from=a + 1, val_rn_to=b,
                          val_pos_share=vai.agg(F.avg("label")).first()[0]))
```

```
save(pd.DataFrame(fold_rows), "pz5_cv_folds")
tune_rows, best = [], {}
loadavg("before_tuning")
t_tune = time.perf_counter()
for nm in ("LR", "RF", "GBT"):
    for p in combos(GRIDS[nm]):
        sc_roc, sc_pr = [], []
        t = time.perf_counter()
        for i in range(3):
            tr_i, va_i = fold_data(i)
            pr_ = with_p1(mk(nm, p).fit(tr_i).transform(va_i))
            sc_roc.append(ev_roc.evaluate(pr_));
   sc_pr.append(ev_pr.evaluate(pr_))
        tune_rows.append(dict(model=nm, **{k: p.get(k) for k in ("regParam",
   "elasticNetParam", "numTrees", "maxDepth", "minInstancesPerNode", "maxIter",
   "stepSize")},
                              cv_roc_auc=np.mean(sc_roc),
   cv_pr_auc=np.mean(sc_pr), cv_pr_auc_std=np.std(sc_pr),
                              cv_pr_f1=sc_pr[0], cv_pr_f2=sc_pr[1],
   cv_pr_f3=sc_pr[2],
                              cv_roc_f1=sc_roc[0], cv_roc_f2=sc_roc[1],
   cv_roc_f3=sc_roc[2], seconds=time.perf_counter() - t))
        print(f"[tune] {nm} {p} PR-AUC={np.mean(sc_pr):.4f} ROC-
   AUC={np.mean(sc_roc):.4f}")
rec("hyperparameter_tuning_all", time.perf_counter() - t_tune, "3 моделі, 3
   фолди, ембарго 24 год")
loadavg("after_tuning")
tune = pd.DataFrame(tune_rows); save(tune, "pz5_tuning")
tb = {}
for nm in ("LR", "RF", "GBT"):
    sub = tune[tune.model == nm].sort_values("cv_pr_auc",
   ascending=False).iloc[0]
    tb[nm] = sub
    best[nm] = {k: (int(sub[k]) if k in ("numTrees", "maxDepth",
   "minInstancesPerNode", "maxIter") else float(sub[k]))
                for k in GRIDS[nm]}
json.dump(best, open(f"{RES}/pz5_best_params.json", "w"), indent=1)
# ВИБІР МОДЕЛІ – лише за середнім PR-AUC часової крос-валідації (test у виборі не
   бере участі)
sel = max(("LR", "RF", "GBT"), key=lambda k: tb[k].cv_pr_auc)
sel_df = pd.DataFrame([dict(model=k, cv_pr_auc=tb[k].cv_pr_auc,
   cv_pr_auc_std_between_folds=tb[k].cv_pr_auc_std, cv_roc_auc=tb[k].cv_roc_auc,
                           selected_by_cv=(k == sel)) for k in ("LR", "RF",
   "GBT")])
save(sel_df, "pz5_model_selection_cv")
with cap("07_tuning", "підбір гіперпараметрів: часова CV (3 фолди), найкращі
   конфігурації та вибір моделі"):
    for nm in ("LR", "RF", "GBT"):
        s = tune[tune.model == nm].sort_values("cv_pr_auc",
   ascending=False).head(3)
        s = s.dropna(axis=1, how="all").rename(columns={"cv_roc_auc": "cv_roc",
   "cv_pr_auc": "cv_pr", "cv_pr_auc_std": "std"})
        s = s[[c for c in s.columns if not c.startswith(("cv_pr_f", "cv_roc_f"))
   and c not in ("seconds", "model")]]
        print(f"\n{nm}: найкраще {best[nm]}");
   print(s.round(4).to_string(index=False))
    print("\nВибір моделі за CV PR-AUC (test не використано):");
   print(sel_df.round(4).to_string(index=False))

# ---------- Поріг рішення: середній F1 за 3 валідаційними фолдами (без доступу
   до test) ----------
thr_grid = np.round(np.arange(0.05, 0.96, 0.01), 2)
chosen_thr, thr_rows, thr_detail = {}, [], []
for nm in ("LR", "RF", "GBT"):
    F1 = np.zeros((3, len(thr_grid))); PR = np.zeros_like(F1); RC =
   np.zeros_like(F1)
    for i in range(3):
        tr_v, va_v = fold_data(i)
        pv = with_p1(mk(nm, best[nm]).fit(tr_v).transform(va_v)).select("label",
   "p1").toPandas()
        for j, th in enumerate(thr_grid):
```

```
            yh = (pv.p1 >= th).astype(int); tp = ((yh == 1) & (pv.label ==
   1)).sum(); fp = ((yh == 1) & (pv.label == 0)).sum(); fn = ((yh == 0) &
   (pv.label == 1)).sum()
            PR[i, j] = tp / (tp + fp) if tp + fp else 0; RC[i, j] = tp / (tp +
   fn) if tp + fn else 0
            F1[i, j] = 2 * PR[i, j] * RC[i, j] / (PR[i, j] + RC[i, j]) if PR[i,
   j] + RC[i, j] else 0
        thr_detail.append(dict(model=nm, fold=i + 1,
   best_threshold=float(thr_grid[F1[i].argmax()]), best_f1=float(F1[i].max())))
     chosen_thr[nm] = float(thr_grid[int(np.argmax(F1.mean(axis=0)))])
     for j, th in enumerate(thr_grid):
        thr_rows.append(dict(model=nm, threshold=th, f1_fold1=F1[0, j],
   f1_fold2=F1[1, j], f1_fold3=F1[2, j],
                             val_f1=F1[:, j].mean(), val_precision=PR[:,
   j].mean(), val_recall=RC[:, j].mean()))
     thr_detail.append(dict(model=nm, fold="mean", best_threshold=chosen_thr[nm],
   best_f1=float(F1.mean(axis=0).max())))
save(pd.DataFrame(thr_rows), "pz5_threshold_validation")
save(pd.DataFrame(thr_detail), "pz5_threshold_per_fold")
json.dump(chosen_thr, open(f"{RES}/pz5_chosen_thresholds.json", "w"))

# ---------- Остаточне навчання на train і оцінка на test ----------
models, preds, timing_models = {}, {}, []
for nm in ("LR", "RF", "GBT"):
    t = time.perf_counter(); pm = mk(nm, best[nm]).fit(train); t_fit =
   time.perf_counter() - t
    t = time.perf_counter(); pr_ = with_p1(pm.transform(test)).cache(); n_ =
   pr_.count(); t_inf = time.perf_counter() - t
    models[nm] = pm; preds[nm] = pr_
    timing_models.append(dict(model=nm, fit_seconds=t_fit,
   inference_seconds_test=t_inf, test_rows=n_, inference_rows_per_sec=n_ / t_inf))
    rec(f"fit_{nm}", t_fit, f"train {n_tr} рядків"); rec(f"inference_{nm}",
   t_inf, f"test {n_te} рядків")
save(pd.DataFrame(timing_models), "pz5_model_runtimes")
base_test = test.withColumn("p1", F.lit(0.0))
persist_test = test.withColumn("p1", F.col("persist"))
ratio_test = test.withColumn("p1", F.col("log_rv_over_thr"))
all_rows = []
def add(name, df, thr, kind):
    mt = metrics(df, thr); mt.update(model=name, kind=kind); all_rows.append(mt)
add("Мажоритарний клас (завжди 0)", base_test, 0.5, "baseline")
add("Персистентність (rv_t > порогу)", persist_test, 0.5, "baseline")
add("Ранжування за log(rv_t/поріг), поріг 0", ratio_test, 0.0, "baseline")
for nm in ("LR", "RF", "GBT"):
    add(f"{nm} (поріг 0,5)", preds[nm], 0.5, "model")
    add(f"{nm} (поріг {chosen_thr[nm]:.2f}, з валідації)", preds[nm],
   chosen_thr[nm], "model_tuned_thr")
res = pd.DataFrame(all_rows)[["model", "kind", "threshold", "accuracy",
   "precision", "recall", "f1", "balanced_accuracy", "mcc", "roc_auc", "pr_auc",
   "tn", "fp", "fn", "tp", "n"]]
save(res, "pz5_metrics_test")
def short(n): return (n.replace("Мажоритарний клас (завжди 0)",
   "Мажоритарний").replace("Персистентність (rv_t > порогу)", "Персистентність")
                      .replace("Ранжування за log(rv_t/поріг), поріг 0",
   "log(rv/поріг)").replace(", з валідації", "").replace("(поріг ",
   "@").replace(")", "").replace(",", "."))
with cap("08_metrics", "метрики на тесті: базові лінії та моделі (поріг 0,5 і
   поріг з валідації)"):
    print(f"Частка класу 1 у test: {lab['test'][0]:.4f}; n={n_te}")
    print("Пороги з валідації: " + ", ".join(f"{k} {v:.2f}" for k, v in
   chosen_thr.items()))
    q = res.drop(columns=["kind", "n", "balanced_accuracy", "tn", "fp", "fn",
   "tp"]).copy(); q["model"] = q.model.map(short)
    q = q.rename(columns={"model": "модель", "threshold": "thr", "accuracy":
   "acc", "precision": "prec", "recall": "rec", "roc_auc": "ROC", "pr_auc": "PR"})
    print(q.round(3).to_string(index=False))
    print("\nЧас, с:");
   print(pd.DataFrame(timing_models).drop(columns=["test_rows"]).round(2).to_strin
   g(index=False))

# ---------- Збереження прогнозів ----------
```

```
pcols = test.select("datetime_utc", "year", "hour", "dow", "label", "persist",
   "log_rv_over_thr", "log_rv_l0", "rv", "next_rv", "thr_rv").toPandas()
for nm in ("LR", "RF", "GBT"):
    pcols[f"p_{nm}"] = preds[nm].select("datetime_utc",
   "p1").toPandas().set_index("datetime_utc").loc[pcols.datetime_utc, "p1"].values
pcols = pcols.sort_values("datetime_utc")
pcols.to_csv(f"{RES}/pz5_predictions_test_full.csv", index=False)
pcols.head(200).to_csv(f"{RES}/pz5_predictions_sample.csv", index=False)

# ---------- Важливість ознак / коефіцієнти ----------
def feat_names(pm):
    sch = pm.transform(test.limit(5)).schema["features_raw"].metadata["ml_attr"]
   ["attrs"]
    items = [x for grp in sch.values() for x in grp]; items.sort(key=lambda x:
   x["idx"])
    return [x["name"].replace("_imp", "") for x in items]
names = feat_names(models["RF"])
imp = pd.DataFrame({"feature": names})
imp["RF_importance"] = models["RF"].stages[-1].featureImportances.toArray()
imp["GBT_importance"] = models["GBT"].stages[-1].featureImportances.toArray()
imp["LR_coef_standardized"] = models["LR"].stages[-1].coefficients.toArray()
imp["LR_abs_coef"] = imp.LR_coef_standardized.abs()
imp = imp.sort_values("RF_importance", ascending=False)
save(imp, "pz5_feature_importance")
with cap("09_importance", "model.stages[-1].featureImportances / coefficients
   (перші 14 з 29 за RF)"):

   print(imp.head(14).drop(columns=["LR_abs_coef"]).rename(columns={"LR_coef_stand
   ardized": "LR_coef"}).round(4).to_string(index=False))
    print(f"... ще {len(imp) - 14} рядків у results/pz5_feature_importance.csv;
   LR intercept:", round(models['LR'].stages[-1].intercept, 4))

# ---------- Випадковий поділ проти хронологічного: порівняння на ОДНАКОВИХ
   годинах ----------
#  A  – хронологічна модель (train до ембарго) -> хронологічний test (n_te)
#  B  – випадкова вибірка 80 % передтестового періоду (train) -> ТОЙ САМИЙ
   хронологічний test (ті самі рядки, що й A)
#  C  – випадковий поділ 80/20 усього періоду -> його випадковий test (вся
   історія 2018–2026)
#  C* – C, обмежений годинами з періоду хронологічного test (>= test_start):
   модель випадкового поділу, тест лише на цих годинах
#  A* – хронологічна модель на тих самих годинах, що й C*
loadavg("before_random_vs_chrono")
rnd_pre = train.sample(False, 0.8, seed=SEED)
n_B = rnd_pre.count()
rnd_tr, rnd_te = m.randomSplit([0.8, 0.2], seed=SEED)
n_Ctr, n_Cte = rnd_tr.count(), rnd_te.count()
rnd_te = rnd_te.cache(); rnd_te_star = rnd_te.filter(F.col("datetime_utc") >=
   F.lit(str(TEST_START))).cache()
n_Cs = rnd_te_star.count()
star_keys = rnd_te_star.select("datetime_utc")
cmp_rows, pred_B, pred_C = [], {}, {}
def row(nm, split, df, thr_tuned):
    r_ = metrics(df, 0.5); r2 = metrics(df, thr_tuned, auc=False)
    r_.update(model=nm, split=split, n_test=r_["n"], f1_at_cv_threshold=r2["f1"],
   cv_threshold=thr_tuned); cmp_rows.append(r_)
for nm in ("LR", "RF", "GBT"):
    th = chosen_thr[nm]
    row(nm, "A chrono -> chrono test", preds[nm], th)
    row(nm, "A* chrono -> test hours of C*", preds[nm].join(star_keys,
   "datetime_utc"), th)
    pmB = mk(nm, best[nm]).fit(rnd_pre); pB =
   with_p1(pmB.transform(test)).cache(); pred_B[nm] = pB
    row(nm, "B random 80% of pre-test -> chrono test", pB, th)
    pmC = mk(nm, best[nm]).fit(rnd_tr); pC =
   with_p1(pmC.transform(rnd_te)).cache(); pred_C[nm] = pC
    row(nm, "C random 80/20 whole period -> random test", pC, th)
    row(nm, "C* random 80/20 -> random test, hours >= test_start",
   pC.join(star_keys, "datetime_utc"), th)
cmp = pd.DataFrame(cmp_rows)[["model", "split", "n_test", "accuracy",
   "precision", "recall", "f1", "f1_at_cv_threshold", "cv_threshold", "roc_auc",
```

```
   "pr_auc"]]
save(cmp, "pz5_random_vs_chrono")
def collect_preds(pd_, keycols):
    out = pd_["LR"].select("datetime_utc",
   "label").toPandas().set_index("datetime_utc")
    for nm in ("LR", "RF", "GBT"):
        out[f"p_{nm}"] = pd_[nm].select("datetime_utc",
   "p1").toPandas().set_index("datetime_utc").p1.reindex(out.index)
    return out.sort_index().reset_index()
collect_preds(pred_B,
   None).to_csv(f"{RES}/pz5_pred_random_pretest_on_chrono_test.csv", index=False)
collect_preds(pred_C, None).to_csv(f"{RES}/pz5_pred_random_whole_test.csv",
   index=False)
rs = pd.DataFrame([("A_chrono_train_rows", n_tr), ("A_chrono_test_rows", n_te),
   ("B_random_pretest_train_rows", n_B), ("B_test_rows", n_te),
                  ("C_random_train_rows", n_Ctr), ("C_random_test_rows", n_Cte),
   ("C_star_test_rows(>=test_start)", n_Cs), ("test_start", str(TEST_START))],
                 columns=["parameter", "value"])
save(rs, "pz5_random_split_sizes")
with cap("10_random_vs_chrono", "випадковий і хронологічний поділ: ті самі
   моделі, ті самі години тесту (поріг 0,5)"):
    print(rs.to_string(index=False, header=False))
    q = cmp.drop(columns=["accuracy", "precision", "recall",
   "f1_at_cv_threshold", "cv_threshold"]).copy()
    q["split"] = q.split.str.split(" ").str[0]
    print(q.rename(columns={"n_test": "n", "roc_auc": "ROC", "pr_auc":
   "PR"}).round(3).to_string(index=False))

# ---------- Перевірка «напрямок ціни» (лише LR, для обґрунтування вибору задачі)
   ----------
dir_tr, dir_te = train.filter(F.col("label_dir").isNotNull()),
   test.filter(F.col("label_dir").isNotNull())
ev_d = BinaryClassificationEvaluator(rawPredictionCol="p1", labelCol="label_dir",
   metricName="areaUnderROC")
st_ = stages(LogisticRegression(featuresCol="features", labelCol="label_dir",
   maxIter=200, regParam=0.01, standardization=False), True)
pd_ = with_p1(Pipeline(stages=st_).fit(dir_tr).transform(dir_te)).cache()
acc_d = pd_.select(F.avg(((F.col("p1") >= 0.5).cast("int") ==
   F.col("label_dir")).cast("double"))).first()[0]
n_dir = pd_.count()
maj_d = dir_te.agg(F.avg("label_dir")).first()[0]
dir_res = pd.DataFrame([("LR direction: ROC-AUC", ev_d.evaluate(pd_)), ("LR
   direction: accuracy", acc_d), ("LR direction: n_test", n_dir),
                        ("LR direction: n_correct", round(acc_d * n_dir)),
                        ("majority accuracy (test)", max(maj_d, 1 - maj_d)), ("up
   share test", maj_d)], columns=["metric", "value"])
save(pd.concat([dir_base, dir_res]), "pz5_direction_check")
pd_.select("datetime_utc", "label_dir", "p1", "ret_1h",
   "next_ret").toPandas().sort_values("datetime_utc").to_csv(f"{RES}/
   pz5_direction_pred_test.csv", index=False)
with cap("11_direction", "LogisticRegression на label = (дохідність наступної
   години > 0): контрольний експеримент"):
    print(dir_res.round(4).to_string(index=False))

# ---------- Вибір та збереження моделі: за CV (не за test) ----------
best_name = sel
for stale in os.listdir(f"{RES}/model"):
    if stale != f"best_pipeline_{best_name}":
   shutil.rmtree(f"{RES}/model/{stale}", ignore_errors=True)
t = time.perf_counter();
   models[best_name].write().overwrite().save(f"{RES}/model/best_pipeline_{best_na
   me}")
rec("save_best_pipeline", time.perf_counter() - t, best_name)
t = time.perf_counter(); reloaded =
   PipelineModel.load(f"{RES}/model/best_pipeline_{best_name}")
chk = with_p1(reloaded.transform(test)).agg(F.max("p1")).first()[0];
   rec("load_best_pipeline", time.perf_counter() - t, f"max p1={chk:.4f}")
pd.DataFrame([("best_model_selected_by", "mean CV PR-AUC (3 expanding folds),
   test not used"), ("best_model", best_name),
              ("cv_pr_auc_LR", tb["LR"].cv_pr_auc), ("cv_pr_auc_RF",
   tb["RF"].cv_pr_auc), ("cv_pr_auc_GBT", tb["GBT"].cv_pr_auc)],
```

```
            columns=["parameter", "value"]).to_csv(f"{RES}/pz5_best_model.csv",
   index=False)
with cap("12_model_saved",
   f"model.write().save('results/model/best_pipeline_{best_name}');
   PipelineModel.load(...)"):
    print("модель обрано за CV PR-AUC:", best_name); print("збережено:",
   f"results/model/best_pipeline_{best_name}")
    print(sh(f"ls {RES}/model/best_pipeline_{best_name}")); print("етапи:",
   [type(s).__name__ for s in reloaded.stages])

# ---------- Таймінги та знімки Spark UI (поки сесія Spark працює) ----------
rec("total_script_before_ui", time.perf_counter() - T_ALL)
loadavg("end")
try:
    from playwright.sync_api import sync_playwright
    def hide_fixed(pg):

   pg.evaluate("document.querySelectorAll('*').forEach(e=>{if(getComputedStyle(e).
   position=='fixed')e.style.display='none'})")
    def snap(pg, sel, path, maxh=520):
        el = pg.locator(sel).first; el.wait_for(timeout=30000)
        bb = el.bounding_box()
        pg.screenshot(path=path, full_page=True, clip={"x": max(bb["x"] - 4, 0),
   "y": max(bb["y"] - 4, 0),
                      "width": min(bb["width"] + 8, 1280), "height":
   min(bb["height"] + 8, maxh)})
    with sync_playwright() as p:
        b = p.chromium.launch(executable_path="/opt/pw-browsers/chromium-1243/
   chrome-linux64/chrome", args=["--no-sandbox"])
        pg = b.new_page(viewport={"width": 1280, "height": 800},
   device_scale_factor=2)
        pages = {"jobs": ("jobs/", "#completedJob-table", [6]), "stages":
   ("stages/", "#completedStage-table", [6, 7, 8, 9]),
                 "storage": ("storage/", "#storage-by-rdd-table", []), "sql":
   ("SQL/", "table:has(th:has-text('Description'))", []),
                 "executors": ("executors/", "#summary-execs-table", []),
   "environment": ("environment/", "#runtime-table", [])}
        for k, (u, sel_, hid) in pages.items():
            try:
                pg.goto(f"{sc.uiWebUrl}/{u}", wait_until="load");
   pg.wait_for_timeout(2500)
                hide_fixed(pg)
                # приховано найширші стовпці (смуга прогресу завдань,
   Input/Output/Shuffle), щоб таблиця влізла у 1280 px при збільшенні 1,5
                pg.evaluate("(a)=>{const
   [sel,h]=a;h.forEach(n=>document.querySelectorAll(sel+' tr > :nth-
   child('+n+')').forEach(e=>e.style.display='none'));document.body.style.zoom=1.5
   }", [sel_, hid]); pg.wait_for_timeout(500)
                snap(pg, sel_, f"{SHOTS}/spark_ui_{k}.png")
            except Exception as e:
                print(f"Spark UI {k} failed:", e)
        b.close()
except Exception as e:
    print("Spark UI screenshots failed:", e)
try:
    # Spark UI зберігає лише ~1000 останніх завдань/етапів, тому загальна
   кількість = максимальний id + 1
    ui_jobs = max(j["jobId"] for j in json.loads(sh(f"curl -s
   {sc.uiWebUrl}/api/v1/applications/{sc.applicationId}/jobs"))) + 1
    ui_stages = max(j["stageId"] for j in json.loads(sh(f"curl -s
   {sc.uiWebUrl}/api/v1/applications/{sc.applicationId}/stages?length=100000"))) +
   1
    rec("spark_ui_totals", 0.0, f"jobs={ui_jobs} stages={ui_stages}")
except Exception as e:
    print("Spark UI REST failed:", e)
rec("total_script", time.perf_counter() - T_ALL)
pd.DataFrame(TIMINGS, columns=["step", "seconds",
   "note"]).to_csv(f"{RES}/timings.csv", index=False)
pd.DataFrame(LOAD, columns=["moment", "time", "load1", "load5", "load15",
   "cpu_cores", "top_processes_pcpu"]).to_csv(f"{RES}/loadavg.csv", index=False)
spark.stop()
```

## А.5 Файл pz5_stats.py – блочний бутстреп, випадковий і хронологічний поділ, напрям ціни, ембарго

```
# -*- coding: utf-8 -*-
"""ПЗ5: статистика поверх прогнозів pz5_spark.py (numpy/pandas, без Spark; seed
   42).
 1. блочний бутстреп (тижневі блоки, 1000 повторів) 95 % ДІ для PR-AUC, ROC-AUC,
   F1 і різниць GBT-LR, GBT-RF, GBT-персистентність;
 2. випадковий і хронологічний поділ на ОДНАКОВИХ годинах (ДІ та парні різниці);
 3. напрям ціни: біноміальний тест, z, правила «той самий / протилежний знак»;
 4. перевірка ембарго (ACF мітки).
Запуск (з каталогу pz5):  python code/pz5_stats.py"""
import os, sys, json, math, time
import numpy as np, pandas as pd
sys.path.insert(0, os.path.dirname(os.path.abspath(__file__)))
from pz5_common import RES, SEED, cap as _cap, save
SCRIPT = "pz5_stats.py"
def cap(name, desc): return _cap(name, SCRIPT, desc)
NBOOT, BLOCK_H = 1000, 168     # 1000 повторів; блок = 1 тиждень (168 год)
T0 = time.perf_counter()

# ---------- метрики (numpy) ----------
def roc_auc(y, s):
    r = pd.Series(s).rank().values; n1 = int(y.sum()); n0 = len(y) - n1
    return float((r[y == 1].sum() - n1 * (n1 + 1) / 2) / (n1 * n0))
def _curve(y, s):
    o = np.argsort(-s, kind="mergesort"); ys, ss = y[o], s[o]
    tp = np.cumsum(ys); fp = np.cumsum(1 - ys)
    keep = np.r_[np.where(np.diff(ss) != 0)[0], len(ss) - 1]
    tp, fp = tp[keep], fp[keep]
    return tp / ys.sum(), tp / (tp + fp)
def pr_auc(y, s):
    """Площа під PR-кривою трапеціями (як areaUnderPR у Spark: перша точка (0;
   precision першого порога))."""
    rc, pr = _curve(y, s); return float(np.trapezoid(np.r_[pr[0], pr], np.r_[0,
   rc]))
def avg_prec(y, s):
    """Average precision (ступінчаста інтерполяція, sklearn-подібна)."""
    rc, pr = _curve(y, s); return float(np.sum(np.diff(np.r_[0, rc]) * pr))
def f1_at(y, s, thr):
    yh = s >= thr; tp = int((yh & (y == 1)).sum()); fp = int((yh & (y ==
   0)).sum()); fn = int((~yh & (y == 1)).sum())
    return 2 * tp / (2 * tp + fp + fn) if 2 * tp + fp + fn else 0.0
def all_metrics(y, s, thrs):
    d = {"roc_auc": roc_auc(y, s), "pr_auc": pr_auc(y, s), "avg_precision":
   avg_prec(y, s)}
    for k, th in thrs.items(): d[k] = f1_at(y, s, th)
    return d

def week_groups(dt):
    wk = ((dt - dt.min()).dt.days // 7).values
    return [np.where(wk == w)[0] for w in np.unique(wk)]
def boot_metrics(groups, y, scores, thrs, seed, nboot=NBOOT):
    """scores: {name: array}; thrs: {name: {metric_name: thr}}. Повертає {(name,
   metric): array(nboot)}.
    Блоки = календарні тижні; повторна вибірка блоків із поверненням (кількість
   блоків зберігається)."""
    rng = np.random.default_rng(seed); nb = len(groups); out = {}
    for b in range(nboot):
        idx = np.concatenate([groups[g] for g in rng.integers(0, nb, nb)])
        yb = y[idx]
        for nm, s in scores.items():
            for k, v in all_metrics(yb, s[idx], thrs[nm]).items():
                out.setdefault((nm, k), np.empty(nboot))[b] = v
    return out
def ci(a): return float(np.percentile(a, 2.5)), float(np.percentile(a, 97.5))
def pboot(d): return float(min(1.0, 2 * min((d <= 0).mean(), (d >= 0).mean())))

# =============== 1. Бутстреп на хронологічному test ===============
```

```
P = pd.read_csv(f"{RES}/pz5_predictions_test_full.csv",
   parse_dates=["datetime_utc"]).sort_values("datetime_utc").reset_index(drop=True
   )
thr = json.load(open(f"{RES}/pz5_chosen_thresholds.json"))
M = pd.read_csv(f"{RES}/pz5_metrics_test.csv")
y = P.label.values.astype(int)
score = {"LR": P.p_LR.values, "RF": P.p_RF.values, "GBT": P.p_GBT.values,
   "Персистентність": P.persist.values, "log(rv/поріг)": P.log_rv_over_thr.values}
TH = {"LR": {"f1": thr["LR"], "f1_05": 0.5}, "RF": {"f1": thr["RF"], "f1_05":
   0.5}, "GBT": {"f1": thr["GBT"], "f1_05": 0.5},
      "Персистентність": {"f1": 0.5}, "log(rv/поріг)": {"f1": 0.0}}
groups = week_groups(P.datetime_utc)
est = {nm: all_metrics(y, s, TH[nm]) for nm, s in score.items()}
bs = boot_metrics(groups, y, score, TH, SEED)
rows = []
for (nm, k), a in bs.items():
    lo, hi = ci(a); rows.append(dict(set="chrono test", model=nm, metric=k,
   estimate=est[nm][k], ci_lo=lo, ci_hi=hi, n=len(y), n_blocks=len(groups),
   block_hours=BLOCK_H, n_boot=NBOOT, seed=SEED))
cidf = pd.DataFrame(rows); save(cidf, "pz5_bootstrap_ci")
# звірка власних ROC/PR із Spark-значеннями (pz5_metrics_test.csv)
chk = []
mname = {"LR": "LR (поріг 0,5)", "RF": "RF (поріг 0,5)", "GBT": "GBT (поріг
   0,5)", "Персистентність": "Персистентність (rv_t > порогу)", "log(rv/поріг)":
   "Ранжування за log(rv_t/поріг), поріг 0"}
for nm, mn in mname.items():
    r = M[M.model == mn].iloc[0]
    chk.append(dict(model=nm, spark_roc=r.roc_auc, numpy_roc=est[nm]["roc_auc"],
   spark_pr=r.pr_auc, numpy_pr=est[nm]["pr_auc"],
                    abs_diff_roc=abs(r.roc_auc - est[nm]["roc_auc"]),
   abs_diff_pr=abs(r.pr_auc - est[nm]["pr_auc"])))
save(pd.DataFrame(chk), "pz5_metric_check_spark_vs_numpy")
drows = []
for other in ("LR", "RF", "Персистентність", "log(rv/поріг)"):
    for k in ("pr_auc", "roc_auc", "f1"):
        d = bs[("GBT", k)] - bs[(other, k)]; lo, hi = ci(d)
        drows.append(dict(comparison=f"GBT - {other}", metric=k, diff=est["GBT"]
   [k] - est[other][k], ci_lo=lo, ci_hi=hi, p_boot=pboot(d),
                          ci_excludes_0=bool(lo > 0 or hi < 0), n=len(y),
   n_blocks=len(groups), n_boot=NBOOT, seed=SEED))
# якщо за CV обрано не GBT – додаємо порівняння обраної моделі
sel =
   pd.read_csv(f"{RES}/pz5_best_model.csv").set_index("parameter").value["best_mod
   el"]
if sel != "GBT":
    for other in [m_ for m_ in ("LR", "RF", "GBT", "Персистентність",
   "log(rv/поріг)") if m_ != sel]:
        for k in ("pr_auc", "roc_auc", "f1"):
            d = bs[(sel, k)] - bs[(other, k)]; lo, hi = ci(d)
            drows.append(dict(comparison=f"{sel} - {other}", metric=k,
   diff=est[sel][k] - est[other][k], ci_lo=lo, ci_hi=hi, p_boot=pboot(d),
                              ci_excludes_0=bool(lo > 0 or hi < 0), n=len(y),
   n_blocks=len(groups), n_boot=NBOOT, seed=SEED))
ddf = pd.DataFrame(drows); save(ddf, "pz5_bootstrap_diff")
with cap("13_bootstrap", f"блочний бутстреп (тижневі блоки, {NBOOT} повторів,
   seed {SEED}): 95 % ДІ на test, n={len(y)}"):
    t_ = cidf[cidf.metric.isin(["pr_auc", "roc_auc", "f1"])].copy()
    t_["95% ДІ"] = t_.apply(lambda r: f"[{r.ci_lo:.4f}; {r.ci_hi:.4f}]", axis=1)
    print(t_[["model", "metric", "estimate", "95%
   ДІ"]].round(4).to_string(index=False))
    print("\nРізниці (парний бутстреп на тих самих блоках):")
    q = ddf.copy(); q["95% ДІ"] = q.apply(lambda r: f"[{r.ci_lo:+.4f}; {r.ci_hi:
   +.4f}]", axis=1)
    print(q[["comparison", "metric", "diff", "95% ДІ",
   "p_boot"]].round(4).to_string(index=False))

# =============== 2. Випадковий і хронологічний поділ на однакових годинах
   ===============
A = P[["datetime_utc", "label", "p_LR", "p_RF", "p_GBT"]]
B = pd.read_csv(f"{RES}/pz5_pred_random_pretest_on_chrono_test.csv",
   parse_dates=["datetime_utc"])
```

```
C = pd.read_csv(f"{RES}/pz5_pred_random_whole_test.csv",
   parse_dates=["datetime_utc"])
spl = pd.read_csv(f"{RES}/pz5_split.csv").set_index("parameter").value
TEST_START = pd.Timestamp(spl["test_start"])
MODELS = ("LR", "RF", "GBT")
def th2(nm): return {"f1": thr[nm], "f1_05": 0.5}
def mset(df, pref, seed):
    sc_ = {nm: df[f"{pref}{nm}"].values for nm in MODELS}
    yv = df.label.values.astype(int)
    return yv, sc_, boot_metrics(week_groups(df.datetime_utc), yv, sc_, {nm:
   th2(nm) for nm in MODELS}, seed), {nm: all_metrics(yv, sc_[nm], th2(nm)) for nm
   in MODELS}, len(week_groups(df.datetime_utc))
rows, drows = [], []
def put(variant, nm, k, e, a, n, nbk):
    lo, hi = ci(a); rows.append(dict(variant=variant, model=nm, metric=k,
   estimate=e, ci_lo=lo, ci_hi=hi, n=n, n_blocks=nbk))
# A: хроно -> хроно test; B: випадкові 80 % передтестового -> той самий test
   (парно)
AB = A.merge(B, on="datetime_utc", suffixes=("_A", "_B")); assert (AB.label_A ==
   AB.label_B).all()
dA = AB.rename(columns={"label_A": "label"})
yv = dA.label.values.astype(int); g = week_groups(dA.datetime_utc)
scA = {nm: dA[f"p_{nm}_A"].values for nm in MODELS}; scB = {nm:
   dA[f"p_{nm}_B"].values for nm in MODELS}
sc_all = {**{f"A{nm}": scA[nm] for nm in MODELS}, **{f"B{nm}": scB[nm] for nm in
   MODELS}}
th_all = {**{f"A{nm}": th2(nm) for nm in MODELS}, **{f"B{nm}": th2(nm) for nm in
   MODELS}}
bsAB = boot_metrics(g, yv, sc_all, th_all, SEED)
for nm in MODELS:
    for k in ("pr_auc", "roc_auc", "f1", "f1_05"):
        eA, eB = all_metrics(yv, scA[nm], th2(nm))[k], all_metrics(yv, scB[nm],
   th2(nm))[k]
        put("A хроно -> хроно test", nm, k, eA, bsAB[(f"A{nm}", k)], len(yv),
   len(g)); put("B випадкові 80% передтестового -> той самий test", nm, k, eB,
   bsAB[(f"B{nm}", k)], len(yv), len(g))
        d = bsAB[(f"B{nm}", k)] - bsAB[(f"A{nm}", k)]; lo, hi = ci(d)
        drows.append(dict(comparison="B - A (ті самі рядки test)", model=nm,
   metric=k, diff=eB - eA, ci_lo=lo, ci_hi=hi, p_boot=pboot(d), n=len(yv),
   n_blocks=len(g)))
# C* vs A*: випадкова модель на випадковому тесті, обмеженому годинами >=
   test_start, проти хронологічної на ТИХ САМИХ годинах
Cs = C[C.datetime_utc >= TEST_START]
AC = A.merge(Cs, on="datetime_utc", suffixes=("_A", "_C")); assert (AC.label_A ==
   AC.label_C).all()
dS = AC.rename(columns={"label_A": "label"}); yS = dS.label.values.astype(int);
   gS = week_groups(dS.datetime_utc)
scS = {**{f"A{nm}": dS[f"p_{nm}_A"].values for nm in MODELS}, **{f"C{nm}":
   dS[f"p_{nm}_C"].values for nm in MODELS}}
thS = {**{f"A{nm}": th2(nm) for nm in MODELS}, **{f"C{nm}": th2(nm) for nm in
   MODELS}}
bsS = boot_metrics(gS, yS, scS, thS, SEED)
for nm in MODELS:
    for k in ("pr_auc", "roc_auc", "f1", "f1_05"):
        eA, eC = all_metrics(yS, scS[f"A{nm}"], th2(nm))[k], all_metrics(yS,
   scS[f"C{nm}"], th2(nm))[k]
        put("A* хроно на тих самих годинах, що C*", nm, k, eA, bsS[(f"A{nm}",
   k)], len(yS), len(gS))
        put("C* випадковий поділ, тест лише >= test_start", nm, k, eC,
   bsS[(f"C{nm}", k)], len(yS), len(gS))
        d = bsS[(f"C{nm}", k)] - bsS[(f"A{nm}", k)]; lo, hi = ci(d)
        drows.append(dict(comparison="C* - A* (ті самі години)", model=nm,
   metric=k, diff=eC - eA, ci_lo=lo, ci_hi=hi, p_boot=pboot(d), n=len(yS),
   n_blocks=len(gS)))
# C: випадковий поділ усього періоду на власному тесті (інші рядки, ніж A) –
   незалежні бутстрепи
yC, scC, bsC, estC, nbC =
   mset(C.sort_values("datetime_utc").reset_index(drop=True), "p_", SEED + 1)
for nm in MODELS:
    for k in ("pr_auc", "roc_auc", "f1", "f1_05"):
        put("C випадковий поділ усього періоду -> власний випадковий test", nm,
```

```
   k, estC[nm][k], bsC[(nm, k)], len(yC), nbC)
        d = bsC[(nm, k)] - bs[(nm, k)]; lo, hi = ci(d); eA = est[nm][k] if k in
   est[nm] else all_metrics(y, score[nm], th2(nm))[k]
        drows.append(dict(comparison="C - A (різні рядки, незалежні бутстрепи)",
   model=nm, metric=k, diff=estC[nm][k] - eA, ci_lo=lo, ci_hi=hi, p_boot=pboot(d),
   n=len(yC), n_blocks=nbC))
rv = pd.DataFrame(rows); rv.to_csv(f"{RES}/pz5_random_vs_chrono_ci.csv",
   index=False)
rd = pd.DataFrame(drows); rd["ci_excludes_0"] = (rd.ci_lo > 0) | (rd.ci_hi < 0);
   rd.to_csv(f"{RES}/pz5_random_vs_chrono_diff.csv", index=False)
# «експозиція» витоку: яка частка випадкових тест-годин має обох сусідів (t-1,
   t+1) у випадковому train
allh = pd.read_csv(f"{RES}/pz5_target_series.csv",
   parse_dates=["datetime_utc"]).datetime_utc
test_set = set(C.datetime_utc); h = pd.Timedelta(hours=1)
nb_in_train = lambda t: ((t - h) in set_all and (t - h) not in test_set) and ((t
   + h) in set_all and (t + h) not in test_set)
set_all = set(allh)
expo = pd.DataFrame([("C_test_rows", len(C)), ("C_test_rows_>=test_start",
   len(Cs)),
                     ("share_C_test_with_both_neighbours_in_random_train",
   float(np.mean([nb_in_train(t) for t in C.datetime_utc]))),
                     ("share_C*_test_with_both_neighbours_in_random_train",
   float(np.mean([nb_in_train(t) for t in Cs.datetime_utc]))),
                     ("share_A_test_with_both_neighbours_in_train", 0.0)],
   columns=["parameter", "value"])
save(expo, "pz5_random_split_exposure")
with cap("14_random_same_hours", "випадковий проти хронологічного поділу на
   однакових годинах: PR-AUC, 95 % ДІ"):
    q = rv[rv.metric == "pr_auc"].copy(); q["variant"] = q.variant.str.split("
   ").str[0]
    q["PR-AUC [95 % ДІ]"] = q.apply(lambda r: f"{r.estimate:.3f} [{r.ci_lo:.3f};
   {r.ci_hi:.3f}]", axis=1)
    print(q[["variant", "model", "n", "PR-AUC [95 %
   ДІ]"]].to_string(index=False))
    print("\nРізниці PR-AUC (парні, ті самі години):")
    q = rd[(rd.metric == "pr_auc")].copy(); q["95% ДІ"] = q.apply(lambda r:
   f"[{r.ci_lo:+.3f}; {r.ci_hi:+.3f}]", axis=1)
    print(q[["comparison", "model", "n", "diff", "95%
   ДІ"]].round(3).to_string(index=False))

# ================ 3. Напрям ціни: біноміальний тест і правила знаку
   ================
def binom_two_sided(k, n):
    m = min(k, n - k); lp = [math.lgamma(n + 1) - math.lgamma(i + 1) -
   math.lgamma(n - i + 1) - n * math.log(2) for i in range(m + 1)]
    mx = max(lp); return min(1.0, 2 * math.exp(mx) * sum(math.exp(v - mx) for v
   in lp))
def wilson(k, n, z=1.96):
    p = k / n; den = 1 + z * z / n; c = (p + z * z / (2 * n)) / den; hw = z *
   math.sqrt(p * (1 - p) / n + z * z / (4 * n * n)) / den
    return c - hw, c + hw
D = pd.read_csv(f"{RES}/pz5_direction_pred_test.csv",
   parse_dates=["datetime_utc"]).sort_values("datetime_utc").reset_index(drop=True
   )
yd = D.label_dir.values.astype(int); pred = (D.p1.values >= 0.5).astype(int)
n_d = len(yd); k_d = int((pred == yd).sum()); acc_d = k_d / n_d
z_d = (k_d - n_d / 2) / math.sqrt(n_d / 4); p_d = binom_two_sided(k_d, n_d);
   lo_w, hi_w = wilson(k_d, n_d)
maj = max(yd.mean(), 1 - yd.mean())
gD = week_groups(D.datetime_utc); rng = np.random.default_rng(SEED); accs, aucs =
   [], []
for _ in range(NBOOT):
    idx = np.concatenate([gD[i] for i in rng.integers(0, len(gD), len(gD))])
    accs.append((pred[idx] == yd[idx]).mean()); aucs.append(roc_auc(yd[idx],
   D.p1.values[idx]))
auc_d = roc_auc(yd, D.p1.values)
dirt = pd.DataFrame([dict(test="LR: accuracy vs 0,5", n=n_d, k_correct=k_d,
   estimate=acc_d, ci_lo=ci(np.array(accs))[0], ci_hi=ci(np.array(accs))[1],
   z=z_d, p_binom_two_sided=p_d,
                          note=f"Wilson 95 %: [{lo_w:.4f}; {hi_w:.4f}];
```

```
    SE={math.sqrt(0.25 / n_d):.4f}; majority(test)={maj:.4f}"),
                      dict(test="LR: ROC-AUC", n=n_d, k_correct=np.nan,
    estimate=auc_d, ci_lo=ci(np.array(aucs))[0], ci_hi=ci(np.array(aucs))[1],
    z=np.nan, p_binom_two_sided=np.nan, note="блочний бутстреп")])
S = pd.read_csv(f"{RES}/pz5_target_series.csv", parse_dates=["datetime_utc"])
def sign_rule(df, name):
    v = df[(df.ret_1h != 0) & df.label_dir.notna()]
    same = ((v.ret_1h > 0).astype(int) == v.label_dir); n = len(v); k =
    int(same.sum())
    return dict(subset=name, n_hours=len(df), n_cur_zero_ret=int((df.ret_1h ==
    0).sum()), n_next_zero_ret=int((df.label_dir.isna()).sum()), n_used=n,
                same_sign_accuracy=k / n, opposite_sign_accuracy=1 - k / n,
    z_vs_0_5=(k - n / 2) / math.sqrt(n / 4), p_binom_two_sided=binom_two_sided(k,
    n),

    spearman_ret_t_ret_t1=float(v.ret_1h.rank().corr(v.next_ret.rank())),
    pearson_ret_t_ret_t1=float(v.ret_1h.corr(v.next_ret)))
sr = [sign_rule(S, "всі години"), sign_rule(S[S.split == "train"], "train"),
    sign_rule(S[S.split == "test"], "test")]
sr += [sign_rule(S[S.year == yv_], f"рік {yv_}") for yv_ in
    sorted(S.year.unique())]
srdf = pd.DataFrame(sr); save(srdf, "pz5_direction_sign_rules")
save(dirt, "pz5_direction_test")
with cap("15_direction_test", "напрям ціни: біноміальний тест LR і правила «той
    самий / протилежний знак»"):
    print(f"LR напрям, test: n={n_d}, правильних={k_d}, accuracy={acc_d:.4f}
    (мажоритарний {maj:.4f})")
    print(f"z={z_d:.2f} (SE={math.sqrt(0.25 / n_d):.4f}), p(двосторонній
    біном.)={p_d:.2e}, ROC-AUC={auc_d:.4f}")
    print(f"Wilson 95 %: [{lo_w:.4f}; {hi_w:.4f}];  бутстреп-ДІ accuracy:
    [{ci(np.array(accs))[0]:.4f}; {ci(np.array(accs))[1]:.4f}]")
    print("\nПравило знаку поточної години (години з ненульовою дохідністю):")
    q = srdf[["subset", "n_used", "same_sign_accuracy", "opposite_sign_accuracy",
    "z_vs_0_5"]].copy()
    print(q.round(4).to_string(index=False))
    print(f"\nSpearman(ret_t, ret_t+1), всі: {srdf.spearman_ret_t_ret_t1[0]:.4f};
    Pearson: {srdf.pearson_ret_t_ret_t1[0]:.4f}")

# =============== 4. Ембарго: ACF мітки ===============
lab_ = S.label.values.astype(float); lab_ = lab_ - lab_.mean(); n_l = len(lab_);
    bound = 1.96 / math.sqrt(n_l)
ac = {k: float((lab_[:-k] * lab_[k:]).sum() / (lab_ * lab_).sum()) for k in
    range(1, 721)}
emb = [dict(lag_h=k, acf_label=ac[k], conf95=bound) for k in (1, 2, 3, 6, 12, 24,
    48, 72, 168, 336, 720)]
emb_df = pd.DataFrame(emb); save(emb_df, "pz5_embargo_check")
extra = pd.DataFrame([("n_rows", n_l), ("lags_1_720_with_abs_acf_above_bound",
    int(sum(abs(v) > bound for v in ac.values()))),
                      ("label_horizon_h(min_embargo)", 1), ("embargo_used_h",
    24), ("train_labels_using_test_hours_if_no_embargo", 1)], columns=["parameter",
    "value"])
save(extra, "pz5_embargo_summary")
print("\nЕмбарго:", emb_df.round(4).to_string(index=False));
    print(extra.to_string(index=False))
rec = pd.DataFrame([("pz5_stats_seconds", round(time.perf_counter() - T0, 2),
    f"bootstrap {NBOOT}, block {BLOCK_H} h")], columns=["step", "seconds", "note"])
tm = pd.read_csv(f"{RES}/timings.csv"); tm = tm[tm.step != "pz5_stats_seconds"]
pd.concat([tm, rec]).to_csv(f"{RES}/timings.csv", index=False)
```

## A.6 Файл make_figures.py – аналіз помилок і побудова рисунків

```
# -*- coding: utf-8 -*-
"""ПЗ5: аналіз помилок (csv) та рисунки з results/*.csv. Друкований розмір 6,3 x
    3,4 / 4,7 дюйма,
шрифти >= 9 pt, dpi 200, українські підписи, десяткова кома."""
import os, sys, json
import numpy as np, pandas as pd
sys.path.insert(0, os.path.join(os.path.dirname(os.path.abspath(__file__)), "..",
    "..", "tools_report")); sys.path.insert(0,
    os.path.dirname(os.path.abspath(__file__)))
```

```
import plotstyle
from plotstyle import dec, comma_fmt, SINGLE, TWO_PANEL
import matplotlib.pyplot as plt
from matplotlib.ticker import FuncFormatter
from pz5_common import RES as R, FIG as FG

C = {"LR": "#1f77b4", "RF": "#2ca02c", "GBT": "#d62728", "persist": "#7f7f7f",
   "ratio": "#9467bd"}
def fig_save(name): plt.tight_layout(); plt.savefig(f"{FG}/{name}.png");
   plt.close()
def yc(ax): ax.yaxis.set_major_formatter(comma_fmt)
def xc(ax): ax.xaxis.set_major_formatter(comma_fmt)
thin = lambda v: f"{int(v):,}".replace(",", " ")     # тонкий пропуск між
   розрядами

FEAT_UA = {"log_rv_l0": "lg rv, ця година", "log_rv_l1": "lg rv, 1 год тому",
   "log_rv_l2": "lg rv, 2 год тому", "log_rv_l5": "lg rv, 5 год тому",
           "log_rv_l23": "lg rv, 23 год тому", "log_rv_m3": "ср. rv за 3 год",
   "log_rv_m6": "ср. rv за 6 год", "log_rv_m24": "ср. rv за 24 год",
           "log_rv_m168": "ср. rv за 168 год", "log_rv_over_thr": "lg(rv /
   поріг)", "ret_1h": "дохідність 1 год", "abs_ret_1h": "|дохідність| 1 год",
           "ret_6h": "дохідність 6 год", "log_rel_range": "lg відн. розмах",
   "log_volume": "lg обсяг", "vol_z168": "z-обсяг (168 год)",
           "flat_share": "частка пласких хв", "hour_sin": "година доби, sin",
   "hour_cos": "година доби, cos", "is_weekend": "вихідний день"}
def ua(f):
    if f.startswith("dow_ohe_"): return "день тижня, " + f.replace("dow_ohe_",
   "кат. ")
    return FEAT_UA.get(f, f)
GROUP = {**{k: "рівень rv (лаги, середні, відношення до порога)" for k in
   ("log_rv_l0", "log_rv_l1", "log_rv_l2", "log_rv_l5", "log_rv_l23", "log_rv_m3",
   "log_rv_m6", "log_rv_m24", "log_rv_m168", "log_rv_over_thr")},
         **{k: "дохідність" for k in ("ret_1h", "abs_ret_1h", "ret_6h")}, **{k:
   "розмах і обсяг" for k in ("log_rel_range", "log_volume", "vol_z168",
   "flat_share")},
         **{k: "календар" for k in ("hour_sin", "hour_cos", "is_weekend")}}
thr = json.load(open(f"{R}/pz5_chosen_thresholds.json"))
best =
   pd.read_csv(f"{R}/pz5_best_model.csv").set_index("parameter").value["best_model
   "]     # обрано за CV, не за test
M = pd.read_csv(f"{R}/pz5_metrics_test.csv")

# 1. Цільова змінна в часі
s = pd.read_csv(f"{R}/pz5_target_series.csv",
   parse_dates=["datetime_utc"]).set_index("datetime_utc")
fig, ax = plt.subplots(2, 1, figsize=TWO_PANEL, sharex=True)
d1 = s.resample("D").agg({"rv": "mean", "thr_rv": "mean", "label": "mean"})
ax[0].plot(d1.index, d1.rv, lw=.6, label="середня за добу погодинна rv");
   ax[0].plot(d1.index, d1.thr_rv, lw=1.2, color="C3", label="поріг (75-й
   перцентиль за 720 год)")
ax[0].set_yscale("log"); ax[0].set_ylabel("rv"); ax[0].legend(loc="upper right",
   fontsize=9); ax[0].set_title("Волатильність і ковзний поріг цільової змінної")
m30 = s.label.resample("30D").mean()
ax[1].plot(m30.index, m30.values, color="C1"); ax[1].axhline(s.label.mean(),
   ls="--", color="k", lw=.8, label=f"середнє {dec(s.label.mean(), 3)}")
ax[1].set_ylabel("Частка класу 1 (30 діб)"); ax[1].legend(loc="upper right",
   fontsize=9); ax[1].set_xlabel("Дата (UTC)"); yc(ax[1])
fig_save("fig01_target_over_time")

# 2. ACF
a = pd.read_csv(f"{R}/pz5_acf.csv"); lags = a.lag_h.values
fig, ax = plt.subplots(1, 2, figsize=SINGLE, sharey=True)
for x, col, t in ((ax[0], "acf_ret", "ACF дохідностей"), (ax[1], "acf_abs_ret",
   "ACF модуля |r|")):
    x.bar(lags, a[col], color="C0", width=.8); x.axhline(a.conf95[0], ls="--",
   color="r", lw=.8); x.axhline(-a.conf95[0], ls="--", color="r", lw=.8, label="95
   % межа")
    x.set_title(t); x.set_xlabel("Лаг, год"); yc(x)
ax[0].set_ylabel("Автокореляція"); ax[1].legend(loc="upper right", fontsize=9)
fig_save("fig02_acf_returns_vs_abs")
```

```
# Прогнози
P = pd.read_csv(f"{R}/pz5_predictions_test_full.csv",
   parse_dates=["datetime_utc"])
y = P.label.values
def roc_pr(score, y):
    o = np.argsort(-score, kind="mergesort"); ys = y[o]; sc = score[o]
    tp = np.cumsum(ys); fp = np.cumsum(1 - ys)
    keep = np.r_[np.where(np.diff(sc) != 0)[0], len(sc) - 1]
    tp, fp = tp[keep], fp[keep]
    tpr = np.r_[0, tp / y.sum()]; fpr = np.r_[0, fp / (1 - y).sum()]; prec =
   np.r_[1, tp / (tp + fp)]
    return fpr, tpr, tpr, prec
scores = {"Персист.": P.persist.values, "LR": P.p_LR.values, "RF": P.p_RF.values,
   "GBT": P.p_GBT.values}
cols = {"Персист.": C["persist"], "LR": C["LR"], "RF": C["RF"], "GBT": C["GBT"]}
MROW = {"Персист.": "Персистентність (rv_t > порогу)", "LR": "LR (поріг 0,5)",
   "RF": "RF (поріг 0,5)", "GBT": "GBT (поріг 0,5)"}
fig, ax = plt.subplots(1, 2, figsize=SINGLE)
for k, sc in scores.items():
    fpr, tpr, rc, pr = roc_pr(sc, y)
    row = M[M.model == MROW[k]].iloc[0]; auc, ap = float(row.roc_auc),
   float(row.pr_auc)
    assert abs(auc - float(np.trapezoid(tpr, fpr))) < 5e-3, (k, auc)      #
   звірка кривої зі значенням Spark
    ax[0].plot(fpr, tpr, color=cols[k], label=f"{k} {dec(auc, 3)}");
   ax[1].plot(rc, pr, color=cols[k], label=f"{k} {dec(ap, 3)}")
ax[0].plot([0, 1], [0, 1], "k--", lw=.8); ax[0].set_xlabel("FPR");
   ax[0].set_ylabel("TPR"); ax[0].set_title("ROC (test)"); ax[0].legend(loc="lower
   right", fontsize=9)
ax[1].axhline(y.mean(), ls="--", color="k", lw=.8); ax[1].set_xlabel("Recall");
   ax[1].set_ylabel("Precision"); ax[1].set_title("PR (test)");
   ax[1].legend(loc="lower left", fontsize=9)
for x in ax: xc(x); yc(x)
fig_save("fig03_roc_pr")

# 4. Матриці помилок (поріг з валідації)
fig, ax = plt.subplots(1, 3, figsize=SINGLE)
for x, nm in zip(ax, ("LR", "RF", "GBT")):
    r = M[M.model == f"{nm} (поріг {thr[nm]:.2f}, з валідації)"].iloc[0]
    cm = np.array([[r.tn, r.fp], [r.fn, r.tp]])
    x.imshow(cm, cmap="Blues"); x.grid(False)
    for i in range(2):
        for j in range(2): x.text(j, i, thin(cm[i, j]), ha="center", va="center",
   fontsize=9, color="white" if cm[i, j] > cm.max() / 2 else "black")
    x.set_xticks([0, 1], ["0", "1"]); x.set_yticks([0, 1], ["0", "1"]);
   x.set_xlabel("прогноз"); x.set_title(f"{nm}, {dec(thr[nm], 2)}")
ax[0].set_ylabel("факт")
fig_save("fig04_confusion_matrices")

# 5. Важливість ознак (імпурітна для RF і GBT, стандартизовані коефіцієнти LR) +
   групові суми
I = pd.read_csv(f"{R}/pz5_feature_importance.csv")
I["group"] = I.feature.map(GROUP).fillna("календар (день тижня)")
g = I.groupby("group")[["RF_importance", "GBT_importance"]].sum().reset_index();
   g["LR_sum_abs_coef"] = I.groupby("group").LR_abs_coef.sum().values
g.to_csv(f"{R}/pz5_feature_importance_groups.csv", index=False)
fig, ax = plt.subplots(2, 1, figsize=TWO_PANEL)
q = I.assign(mean_imp=(I.RF_importance + I.GBT_importance) /
   2).sort_values("mean_imp").tail(8)
yy = np.arange(len(q)); ax[0].barh(yy + .2, q.RF_importance, .4, color=C["RF"],
   label="RF"); ax[0].barh(yy - .2, q.GBT_importance, .4, color=C["GBT"],
   label="GBT")
ax[0].set_yticks(yy, [ua(f) for f in q.feature]); ax[0].set_xlabel("Важливість
   ознаки (імпурітна)"); ax[0].legend(loc="lower right", fontsize=9); xc(ax[0])
q = I.reindex(I.LR_coef_standardized.abs().sort_values().index).tail(8)
ax[1].barh([ua(f) for f in q.feature], q.LR_coef_standardized, color=C["LR"]);
   ax[1].set_xlabel("LR: стандартизований коефіцієнт"); ax[1].axvline(0,
   color="k", lw=.6); xc(ax[1])
fig_save("fig05_feature_importance")

# Аналіз помилок (модель, обрана за CV, з порогом із валідації)
```

```
P["yhat"] = (P[f"p_{best}"] >= thr[best]).astype(int); P["err"] = (P.yhat !=
   P.label).astype(int)
P["fn"] = ((P.yhat == 0) & (P.label == 1)).astype(int); P["fp"] = ((P.yhat == 1)
   & (P.label == 0)).astype(int)
P["cur_high"] = P.persist.astype(int)
def grp(k):
    gg = P.groupby(k).agg(n=("err", "size"), pos_share=("label", "mean"),
   error_rate=("err", "mean"), fn_rate=("fn", "sum"), fp=("fp", "sum"))
    gg["recall"] = P[P.label == 1].groupby(k).yhat.mean(); gg["precision"] =
   P[P.yhat == 1].groupby(k).label.mean()
    gg["fn_rate"] = gg.fn_rate / (gg.n * gg.pos_share); return gg.reset_index()
ey, eh, er = grp("year"), grp("hour"), grp("cur_high")
tr = P.assign(transition=np.select([(P.cur_high == 0) & (P.label == 1),
   (P.cur_high == 1) & (P.label == 0), P.cur_high == P.label], ["onset (0->1)",
   "decay (1->0)", "persist"], "other"))
et = tr.groupby("transition").agg(n=("err", "size"), error_rate=("err",
   "mean")).reset_index()
for df_, nm in ((ey, "year"), (eh, "hour"), (er, "current_regime"), (et,
   "transition")):
    df_.assign(model=best,
   threshold=thr[best]).to_csv(f"{R}/pz5_errors_by_{nm}.csv", index=False)
fig, ax = plt.subplots(2, 1, figsize=TWO_PANEL)
ax[0].bar(ey.year.astype(str), ey.error_rate, color="C0");
   ax[0].set_title(f"Частка помилок за роками (test, {best})");
   ax[0].set_ylabel("Частка помилок"); yc(ax[0])
for i, e in enumerate(ey.error_rate): ax[0].text(i, e, dec(e, 3), ha="center",
   va="bottom", fontsize=9)
ax[0].set_ylim(0, ey.error_rate.max() * 1.18)
ax[1].bar(eh.hour, eh.error_rate, color="C1", label="частка помилок");
   ax[1].plot(eh.hour, eh.pos_share, "k.-", lw=.8, label="частка класу 1");
   ax[1].legend(loc="upper left", fontsize=9, ncol=2)
ax[1].set_title("За годиною доби (UTC)"); ax[1].set_xlabel("Година");
   ax[1].set_xticks(range(0, 24, 3)); yc(ax[1]); ax[1].set_ylim(0,
   max(eh.error_rate.max(), eh.pos_share.max()) * 1.25)
fig_save("fig06_errors_year_hour")

# 7. Випадковий і хронологічний поділ на однакових годинах (ДІ: блочний бутстреп)
rv = pd.read_csv(f"{R}/pz5_random_vs_chrono_ci.csv")
VAR = [("A хроно -> хроно test", "A: хроно → test"), ("B випадкові 80%
   передтестового -> той самий test", "B: випадк. 80 % передтесту\n→ той самий
   test"),
       ("A* хроно на тих самих годинах, що C*", "A*: хроно, години C*"), ("C*
   випадковий поділ, тест лише >= test_start", "C*: випадк. поділ,\nлише години
   test"),
       ("C випадковий поділ усього періоду -> власний випадковий test", "C:
   випадк. поділ,\nвесь період")]
fig, ax = plt.subplots(1, 2, figsize=TWO_PANEL, sharey=True)
for x, met, t in zip(ax, ("pr_auc", "roc_auc"), ("PR-AUC", "ROC-AUC")):
    for j, (v, lab_) in enumerate(VAR):
        for k, nm in enumerate(("LR", "RF", "GBT")):
            r = rv[(rv.variant == v) & (rv.model == nm) & (rv.metric ==
   met)].iloc[0]
            yp = -j + (1 - k) * .22
            x.errorbar(r.estimate, yp, xerr=[[r.estimate - r.ci_lo], [r.ci_hi -
   r.estimate]], fmt="o", ms=4, color=C[nm], capsize=2, lw=1.2, label=nm if j == 0
   else None)
    x.set_xlabel(t); xc(x); x.set_title(t)
ax[0].set_yticks([-j for j in range(len(VAR))], [f"{l}\nn={thin(rv[(rv.variant ==
   v)].n.iloc[0])}" for v, l in VAR]); ax[1].legend(loc="lower right", fontsize=9)
fig_save("fig07_random_vs_chrono")

# 8. Порівняння моделей: оцінки з 95 % ДІ + час виконання
ci = pd.read_csv(f"{R}/pz5_bootstrap_ci.csv"); tm =
   pd.read_csv(f"{R}/pz5_model_runtimes.csv")
names = [("Персистентність", "Персист."), ("log(rv/поріг)", "log(rv/пор.)"),
   ("LR", "LR"), ("RF", "RF"), ("GBT", "GBT")]
fig, ax = plt.subplots(2, 1, figsize=TWO_PANEL, gridspec_kw={"height_ratios":
   [2.2, 1]})
for k, (met, ln, col) in enumerate((("pr_auc", "PR-AUC", "C3"), ("roc_auc", "ROC-
   AUC", "C2"), ("f1", "F1", "C0"))):
    for i, (nm, lab_) in enumerate(names):
```

```
        r = ci[(ci.model == nm) & (ci.metric == met)].iloc[0]
        ax[0].errorbar(i + (k - 1) * .22, r.estimate, yerr=[[r.estimate -
   r.ci_lo], [r.ci_hi - r.estimate]], fmt="o", ms=4, color=col, capsize=2,
   label=ln if i == 0 else None)
ax[0].set_xticks(range(len(names)), [l for _, l in names]);
   ax[0].set_ylabel("Значення (95 % ДІ)"); ax[0].legend(loc="lower right",
   fontsize=9, ncol=3); yc(ax[0]); ax[0].set_title("Метрики на test з 95 % ДІ
   (блочний бутстреп)")
ax[1].bar(tm.model, tm.fit_seconds, color="C0", label="навчання");
   ax[1].bar(tm.model, tm.inference_seconds_test, bottom=tm.fit_seconds,
   color="C1", label="інференс (test)")
ax[1].set_ylabel("Час, с"); ax[1].legend(loc="upper left", fontsize=9)
fig_save("fig08_model_comparison")

# 9. Налаштування гіперпараметрів
T = pd.read_csv(f"{R}/pz5_tuning.csv")
fig, ax = plt.subplots(figsize=SINGLE)
for nm in ("LR", "RF", "GBT"):
    qq = T[T.model == nm].sort_values("cv_pr_auc",
   ascending=False).reset_index(drop=True)
    ax.errorbar(qq.index + 1, qq.cv_pr_auc, yerr=qq.cv_pr_auc_std, fmt="o-",
   ms=4, lw=1, capsize=2, color=C[nm], label=nm, alpha=.9)
ax.set_xlabel("Ранг конфігурації"); ax.set_ylabel("Середній PR-AUC (3 фолди)");
   ax.legend(loc="lower left", fontsize=9, ncol=3); yc(ax); ax.set_title("Часова
   CV: сітка гіперпараметрів (± σ між фолдами)")
fig_save("fig09_tuning")

# 10. Вибір порогу (середній F1 за 3 фолдами)
V = pd.read_csv(f"{R}/pz5_threshold_validation.csv")
fig, ax = plt.subplots(figsize=SINGLE)
for nm in ("LR", "RF", "GBT"):
    qq = V[V.model == nm]; ax.plot(qq.threshold, qq.val_f1, color=C[nm],
   label=f"{nm}, макс. при {dec(thr[nm], 2)}"); ax.axvline(thr[nm], color=C[nm],
   ls=":", lw=.8)
ax.set_xlabel("Поріг ймовірності"); ax.set_ylabel("Середній F1 (3 фолди)");
   ax.legend(loc="lower center", fontsize=9); xc(ax); yc(ax); ax.set_title("Вибір
   порогу рішення")
fig_save("fig10_threshold")

# 11. Різниці GBT − інші моделі з 95 % ДІ
dd = pd.read_csv(f"{R}/pz5_bootstrap_diff.csv"); dd =
   dd[dd.comparison.str.startswith("GBT -")]
fig, ax = plt.subplots(figsize=SINGLE)
rows_ = [(c, m_) for c in ("GBT - LR", "GBT - RF", "GBT - Персистентність") for
   m_ in ("pr_auc", "roc_auc", "f1")]
lab_m = {"pr_auc": "PR-AUC", "roc_auc": "ROC-AUC", "f1": "F1"}; lab_c = {"GBT -
   LR": "GBT − LR", "GBT - RF": "GBT − RF", "GBT - Персистентність": "GBT −
   персист."}
for i, (c_, m_) in enumerate(rows_):
    r = dd[(dd.comparison == c_) & (dd.metric == m_)].iloc[0]
    ax.errorbar(r["diff"], -i, xerr=[[r["diff"] - r.ci_lo], [r.ci_hi -
   r["diff"]]], fmt="o", ms=4, capsize=2, color={"pr_auc": "C3", "roc_auc": "C2",
   "f1": "C0"}[m_])
ax.axvline(0, color="k", lw=.8); ax.set_yticks([-i for i in range(len(rows_))],
   [f"{lab_c[c_]}, {lab_m[m_]}" for c_, m_ in rows_]); ax.set_xlabel("Різниця
   метрики (95 % ДІ)"); xc(ax)
fig_save("fig11_differences")
print("ok; best (CV) =", best)
```