Міністерство освіти і науки України
Харківський національний університет радіоелектроніки

Кафедра штучного інтелекту

Дисципліна «Аналітика великих даних»

Практичне заняття №5

«Інтелектуальний аналіз великих даних засобами Apache Spark MLlib»

Виконав:
ст. гр. ДМм-26-1
Зелінський В.С.

Прийняв:
Золотухін О.В.

Харків – 2026

Інтелектуальний аналіз великих даних засобами Apache Spark MLlib

Мета роботи

Мета роботи: ознайомитися з можливостями Apache Spark MLlib для інтелектуального аналізу великих даних; отримати практичні навички підготовки даних до машинного навчання, формування ознак, побудови та оцінювання моделей класифікації засобами PySpark на прикладі погодинних свічок BTC/USD (Bitcoin Historical Data), отриманих у П32 агрегацією 7 816 537 хвилинних записів, з прогнозом режиму волатильності наступної години.

Короткі теоретичні відомості

Модель у Spark MLlib – `Pipeline` з етапів двох типів: трансформатор (`transform()`) перетворює DataFrame, оцінювач (`fit()`) навчається і повертає модель. `Pipeline.fit()` навчає всі етапи лише на переданій вибірці, тому статистики `Imputer`, `StringIndexer`, `OneHotEncoder` і `StandardScaler` беруться тільки з train, а `VectorAssembler` збирає ознаки у вектор `features`.

Порівнюються три класифікатори: логістична регресія (LR) – лінійна модель ймовірності класу; випадковий ліс (RF) – усереднення дерев, навчених на бутстреп-підвибірках; градієнтний бустинг дерев (GBT) – послідовні неглибокі дерева, кожне з яких виправляє помилки попередніх.

При частці класу 1 близько 25 % константа має accuracy 75 %, тому основними метриками обрано PR-AUC і F1. Сусідні години мають схожу волатильність, тому поділ хронологічний з ембарго, гіперпараметри підбираються крос-валідацією з розширюваним вікном, а невизначеність метрик оцінюється блочним бутстрепом.

Результати виконання практичного заняття

1 Визначення задачі

Вхідні дані – погодинна таблиця ПЗ2 (`pz2_hourly_features.parquet`, 130 276 рядків): OHLC, обсяг, кількість flat-хвилин і реалізована волатильність `rv` (корінь із суми квадратів хвилинних лог-дохідностей). Передбачуваність двох кандидатів на ціль – напряму ціни і волатильності наступної години – оцінено автокореляціями дохідностей `r` і їх модуля `|r|` (рисунок 1) та контрольною LR на мітці «дохідність наступної години > 0» (таблиця 1).

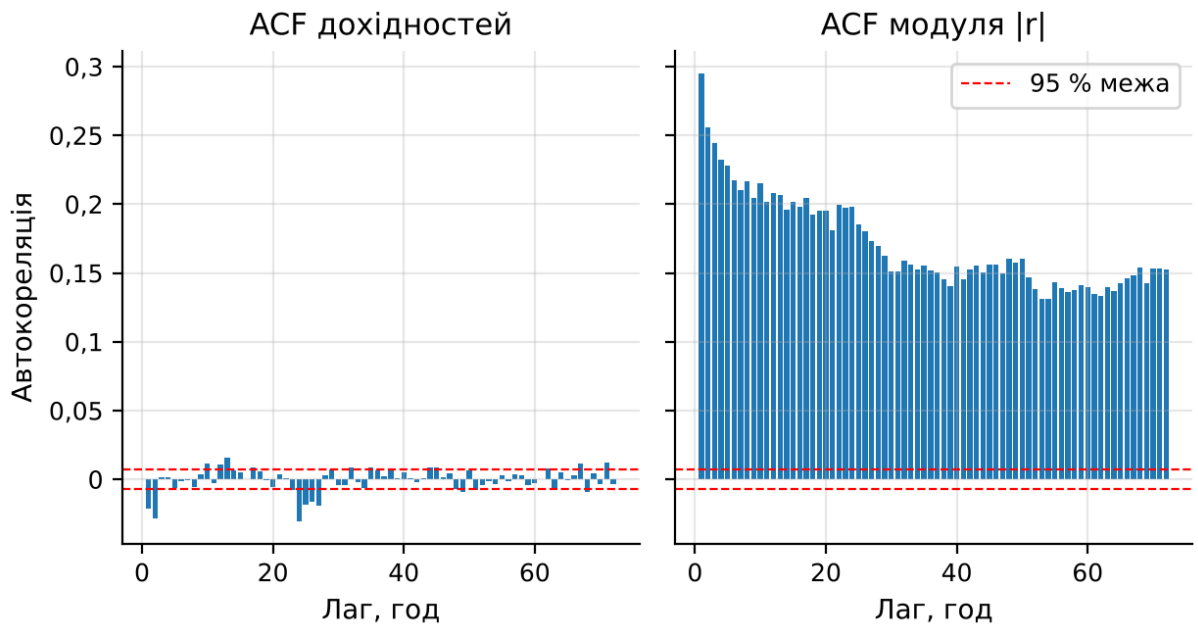


Рисунок 1 – Автокореляційні функції годинних дохідностей і їх модуля, 2018–2026 роки

Таблиця 1 – Передбачуваність напряму ціни і волатильності (2018–2026 роки, 77 666 годин)

Показник	Значення
ACF дохідності, лаг 1 / лаг 2 / лаг 24	−0,0213 / −0,0288 / −0,0304
ACF модуля дохідності, лаг 1 / лаг 24 / лаг 168	0,2951 / 0,1982 / 0,1445
95 % межа незначущої автокореляції	±0,0070
Частка годин зі зростанням ціни	0,5066
Правило «той самий знак»: усі години / train / test	0,4644 / 0,4593 / 0,4847
Правило «протилежний знак»: усі години / train / test	0,5356 / 0,5407 / 0,5153
Кореляція Спірмена r_t і r_t+1	−0,0677
LR для напряму на тесті: ROC-AUC / accuracy	0,5266 / 0,5132
Мажоритарний клас для напряму на тесті: accuracy	0,5000

LR вгадала напрям у 7 961 з 15 511 тестових годин з ненульовою дохідністю наступної години (з 15 534): accuracy 0,5132, біноміальний тест z = 3,30, p = 0,001. Це статистично краще за 0,5, але перевага в 1,3 відсоткового пункта економічно мізерна. Перевага правила «протилежний знак» (0,5356) відображає слабке повернення до середнього (Спірмен −0,0677), яке слабшає з часом (train 0,5407, test 0,5153). Волатильність має значно сильніший сигнал (ACF модуля 0,2951 на лагу 1), тому обрано бінарну класифікацію: чи буде наступна година високоволатильною.

2 Підготовка даних

2.1 Період моделювання

У ПЗ2 встановлено, що flat-хвилини – заповнення сітки, і при великій їх частці `rv` відображає неліквідність (доба 27.01.2012 з 98,1 % flat-хвилин потрапила до топ-10 за `rv`). Частку flat-хвилин за роками разом із часткою позитивного класу наведено в таблиці 2.

Таблиця 2 – Частка flat-хвилин, медіана rv і частка класу 1 за роками

Показник	2017	2018	2019	2020	2021	2022	2023	2024	2025	2026
Flat, %	8,04	3,77	3,28	1,55	0,70	2,66	3,95	3,33	1,13	0,34
Медіана rv	0,01010	0,00720	0,00579	0,00579	0,00735	0,00502	0,00294	0,00412	0,00324	0,00318
Клас 1, ковзний поріг	–	0,2185	0,2408	0,2665	0,2483	0,2305	0,2669	0,2617	0,2503	0,2482
Клас 1, глоб. поріг	–	0,4400	0,2597	0,2469	0,4352	0,2029	0,0581	0,1185	0,0711	0,0671

З 2018 року частка flat-хвилин не перевищує 3,95 %, а у 2017 році вона ще 8,04 %, тому моделювання почато з 01.01.2018. Відкинуто неповні години (`n_minutes < 60`) і години з неповною наступною: остання година 11.11.2026 03:00 має 38 хвилин, тому рядок 02:00 мітки не отримує. Залишилося 77 666 годин до 11.11.2026 01:00 UTC. Решту flat-хвилин не видалено, щоб не ламати годинну сітку, а їх частку `flat_share` передано моделі як ознаку.

2.2 Цільова змінна

Мітка години t дорівнює 1, якщо `rv` години t+1 перевищує 75-й перцентиль `rv` за останні 720 годин, включно з годиною t, і година t+1 повна:

```
d = (d.withColumn("thr_rv", F.expr(f"percentile_approx(rv, {PCT},
   10000)").over(roll(HI_WIN)))
        .withColumn("next_rv", F.lead("rv", 1).over(w_all))
        .withColumn("next_nmin", F.lead("n_minutes", 1).over(w_all))
        .withColumn("label", F.when(F.col("next_nmin") == 60,
                                    (F.col("next_rv") >
   F.col("thr_rv")).cast("int"))))
```

Поріг відомий у момент прогнозу, перцентиль 75 % дає клас 1 близько чверті годин. Вікно 720 год (30 діб) встигає за зміною режиму: медіана `rv` впала з 0,00720 у 2018 році до 0,00318 у 2026 році (таблиця 2). Глобальний поріг 0,00793 (75-й перцентиль навчальної вибірки) дав би частку класу 1 від 0,0581 (2023) до 0,4400 (2018), тобто модель вчилася б

розрізняти епохи, а не години. Ковзний поріг утримує частку в межах 0,2185–0,2669, що видно на рисунку 2.

2.3 Ознаки, пропуски та категоріальні змінні

Ознаки побудовано віконними функціями Spark (`lag`, `rowsBetween`) лише з годин до t включно. Волатильність прологарифмовано з доданком 10^{-5} через важкий правий хвіст (надлишковий ексцес годинних дохідностей у ПЗ2 – 118,11) і години з `rv = 0`. Склад ознак наведено в таблиці 3.

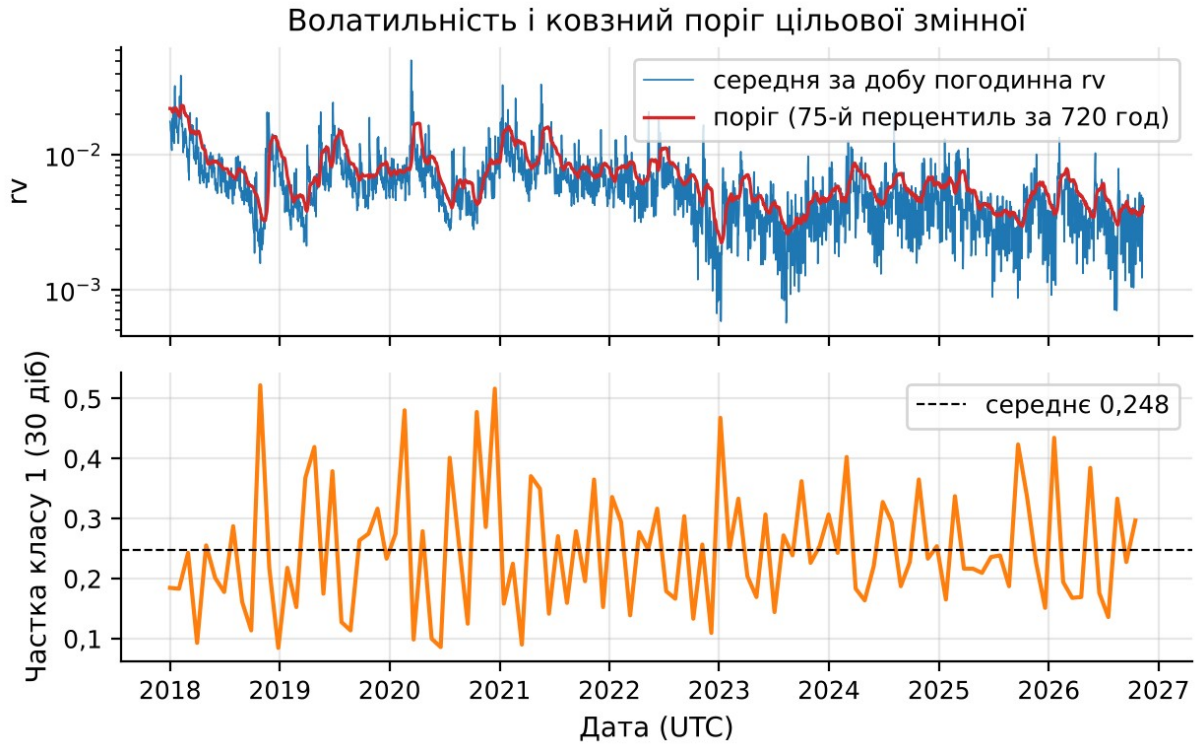


Рисунок 2 – Середня за добу погодинна rv, ковзний поріг і частка класу 1 у 30-добових вікнах

Частка класу 1 коливається навколо 0,248 без тренду, тож мітка не дрейфує.

Таблиця 3 – Ознаки моделі та кількість пропусків (уся історія / рядки моделі)

Група	Ознаки	Зміст	Пропуски
Рівень rv	log_rv_l0, _l1, _l2, _l5, _l23	log rv години t і лагів	0, 1, 2, 5, 23 / 0
Ковзні середні rv	log_rv_m3, _m6, _m24, _m168	log середньої rv за 3–168 год	0 / 0
Відносний рівень	log_rv_over_thr	log(rv_t / поріг_t)	0 / 0
Дохідність	ret_1h, abs_ret_1h, ret_6h	дохідність за 1 і 6 год, модуль	1, 1, 6 / 0
Діапазон і обсяг	log_rel_range, log_volume, vol_z168, flat_share	розмах, обсяг, z-оцінка обсягу, частка flat-хвилин	0, 0, 1, 0 / 0
Календар	hour_sin, hour_cos, is_weekend, dow	година (sin/cos), вихідний, день тижня (OneHot)	0 / 0

Пропуски є лише на початку історії 2012 року (до 23 значень для `log_rv_l23`), тому в рядках з 2018 року їх немає; `Imputer` (медіана train) залишено в конвеєрі для нових рядків. Годину закодовано через sin/cos, щоб 23:00 і 00:00 були поруч, день тижня – `StringIndexer` і `OneHotEncoder` (`dropLast=False`). Вектор ознак має 29 позицій разом з індикаторами невідомої категорії (`handleInvalid="keep"`). Ознаки відібрано за змістом; розділ 8.1 показує, що день тижня можна відкинути.

3 Формування вибірок

Ряд упорядковано за часом і поділено 80/20 за номером рядка: перші 80 % – навчальна вибірка, останні 20 % – тестова. Останні 24 години навчальної частини вилучено як ембарго:

```
n_train = int(N * 0.8)
train = m.filter(F.col("rn") <= n_train - EMB).cache()   # ембарго EMB = 24 год
test = m.filter(F.col("rn") > n_train).cache()
```

Навчальна вибірка охоплює 62 108 годин (01.01.2018 00:00 – 31.01.2025 19:00), тестова – 15 534 години (01.02.2025 20:00 – 11.11.2026 01:00), частка класу 1 майже однакова (0,2478 і 0,2489), як видно на рисунку 3.

Мінімально необхідне ембарго – 1 год, бо мітка години t обчислюється з години t+1; 24 години взято із запасом. Проте ACF самої мітки становить 0,5165 на лагу 1, 0,2908 на лагу 24 і 0,0331 на лагу 720 і перевищує межу ±0,0070 для 675 з 720 лагів, тож ембарго усуває перекриття міток, але не залежність між навчальними і тестовими годинами.

```
$ python code/pz5_spark.py
# фрагмент виводу: хронологічний поділ 80/20 з ембарго, розміри вибірок і частка класу 1
                  rows_model_total               77666
                        train_rows               62108
                    embargo_rows                  24
                       test_rows               15534
                   train_share_pct                80.0
                       train_start 2018-01-01 00:00:00
                         train_end 2025-01-31 19:00:00
embargo_end_nominal_train_boundary 2025-02-01 19:00:00
                       test_start 2025-02-01 20:00:00
                         test_end 2026-11-11 01:00:00
                    raw_last_hour 2026-11-11 03:00:00
           raw_last_hour_n_minutes                  38
                    raw_hourly_rows              130276

Частка класу 1: train=0.2478  test=0.2489
Глобальний поріг rv (75-й перцентиль train) = 0.00793
 year  hours  pos_share_rolling_thr  pos_share_global_thr  up_share_next_hour
 2018   8760                0.2185                0.4400              0.4982
 2019   8760                0.2408                0.2597              0.5111
 2020   8784                0.2665                0.2469              0.5159
 2021   8760                0.2483                0.4352              0.5070
 2022   8760                0.2305                0.2029              0.4982
 2023   8760                0.2669                0.0581              0.5142
 2024   8784                0.2617                0.1185              0.5129
 2025   8760                0.2503                0.0711              0.5046
 2026   7538                0.2482                0.0671              0.4953
```

Рисунок 3 – Хронологічний поділ 80/20 з ембарго: межі, розміри вибірок і частка класу 1

4 Побудова моделей

4.1 Моделі та гіперпараметри

Першою моделлю побудовано інтерпретовану LR, другою – деревні ансамблі RF і GBT, що вловлюють нелінійності й взаємодії. Гіперпараметри підібрано на навчальній вибірці крос-валідацією з розширюваним вікном: валідаційні блоки – 50–66,7 %, 66,7–83,3 % і 83,3–

100 % навчальної частини, кожен навчається на всіх минулих годинах мінус 24 години ембарго. Критерій – середній PR-AUC, чутливий до рідшого класу 1; за ним же обирається модель, тест у виборі не бере участі. Сітки і результати наведено в таблиці 4.

Таблиця 4 – Сітки гіперпараметрів і найкращі конфігурації (часова крос-валідація, 3 блоки)

Модель	Сітка (8 конфігурацій)	Найкраща конфігурація	CV ROC-AUC	CV PR-AUC за блоками	CV PR-AUC ± σ
LR	regParam × elasticNetParam	0,001; 0	0,8625	0,7001 / 0,7557 / 0,7810	0,7456 ± 0,0338
RF	numTrees × maxDepth × minInstancesPerNode	100; 8; 20	0,8536	0,6753 / 0,7289 / 0,7683	0,7241 ± 0,0381
GBT	maxIter × maxDepth × stepSize	100; 3; 0,1	0,8680	0,7025 / 0,7438 / 0,7938	0,7467 ± 0,0373

За середнім CV PR-AUC обрано GBT (0,7467), але LR відстає лише на 0,0011 при розкиді між блоками 0,034–0,038, а в другому блоці краща (0,7557 проти 0,7438), тож CV їх практично не розрізняє; RF нижчий в усіх блоках. Сильна регуляризація LR (regParam 0,1) знижує PR-AUC до 0,7193, для RF глибина 8 краща за 4 (0,7241 проти 0,6980). Повна сітка (24 конфігурації × 3 блоки) тривала 1038,573 с.

4.2 Поріг рішення

Поріг 0,5 не оптимальний для F1 при частці класу 1 близько 0,25, тому поріг обрано за максимумом середнього F1 трьох валідаційних блоків (перебір 0,05–0,95 з кроком 0,01), без доступу до тесту: LR 0,33 (F1 0,6585), RF 0,26 (0,6439), GBT 0,33 (0,6664). Класові ваги (`weightCol`) не застосовано: ранжувальні метрики від них не залежать, а для F1 достатньо порогу.

5 ML Pipeline

У конвеєрі Data → Preprocessing → Feature Engineering → Model → Prediction → Evaluation (скрипт `pz5_spark.py`) читання Parquet і віконні

ознаки виконуються до `Pipeline`, бо потребують упорядкування всього ряду, а етапи підготовки (`SQLTransformer`, `Imputer`, `StringIndexer`, `OneHotEncoder`, `VectorAssembler`, масштабування) і класифікатор зібрано в `Pipeline` (рисунок 4).

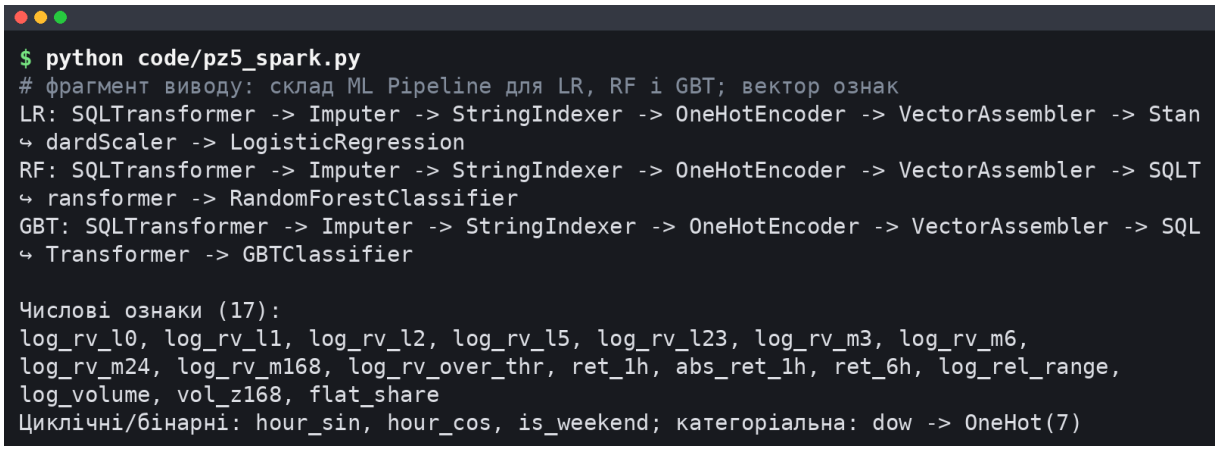


Рисунок 4 – Етапи ML Pipeline для LR, RF і GBT та склад вектора ознак

Стандартизація потрібна лише LR, у деревах замість `StandardScaler` стоїть тотожний `SQLTransformer`. Prediction – `PipelineModel.transform(test)`, Evaluation – `BinaryClassificationEvaluator` і матриця помилок. Обрану за CV модель (GBT) збережено `write().save()` у `results/model/best_pipeline_GBT` за 1,912 с і завантажено `PipelineModel.load()` за 2,338 с. Увесь сценарій на 4 ядрах Intel Xeon 2,10 ГГц тривав 1429,708 с, з них 41,642 с – віконні ознаки.

6 Оцінювання

Метрики методички (accuracy, precision, recall, F1 для класу 1, ROC-AUC) доповнено PR-AUC і коефіцієнтом Метьюза (MCC), коректними при нерівних класах. Базові лінії – мажоритарний клас, персистентність (клас 1, якщо `rv` поточної години вже вища за поріг) і ранжування за ознакою `log(rv_t/поріг_t)`. `areaUnderPR` у Spark інтерполює криву лінійно, що

для бінарної оцінки завищує площу: average precision персистентності 0,5441 проти PR-AUC 0,6135.

7 Порівняння моделей

7.1 Моделі та базові лінії

Метрики на тестовій вибірці показано на рисунку 5 і зведено в таблицю 5.

```
$ python code/pz5_spark.py
# фрагмент виводу: метрики на тесті: базові лінії та моделі (поріг 0,5 і поріг з валідації
↪ )
Частка класу 1 у test: 0.2489; n=15534
Пороги з валідації: LR 0.33, RF 0.26, GBT 0.33
         модель  thr   acc  prec   rec    f1   mcc   ROC    PR
   Мажоритарний 0.50 0.751 0.000 0.000 0.000 0.000 0.500 0.249
Персистентність 0.50 0.842 0.683 0.680 0.682 0.576 0.788 0.614
   log(rv/порir 0.00 0.842 0.682 0.683 0.683 0.577 0.877 0.761
        LR @0.5 0.50 0.855 0.790 0.567 0.660 0.584 0.888 0.782
       LR @0.33 0.33 0.833 0.645 0.727 0.684 0.573 0.888 0.782
        RF @0.5 0.50 0.854 0.852 0.501 0.631 0.578 0.891 0.783
       RF @0.26 0.26 0.842 0.665 0.736 0.699 0.593 0.891 0.783
       GBT @0.5 0.50 0.864 0.816 0.588 0.683 0.613 0.901 0.802
      GBT @0.33 0.33 0.852 0.692 0.731 0.711 0.611 0.901 0.802

Час, с:
model  fit_seconds  inference_seconds_test  inference_rows_per_sec
   LR         4.08                    0.69                22410.55
   RF        23.45                    1.23                12652.42
  GBT        23.60                    0.57                27159.17
```

Рисунок 5 – Метрики моделей і базових ліній на тесті та час навчання й прогнозу

Таблиця 5 – Порівняння моделей і базових ліній на тестовій вибірці (15 534 год, частка класу 1 0,2489)

Модель (поріг)	Accuracy	Precision	Recall	F1	ROC-AUC	PR-AUC	MCC
Мажоритарний	0,7511	0,0000	0,0000	0,0000	0,5000	0,2489	0,0000
Персистентність	0,8418	0,6829	0,6801	0,6815	0,7877	0,6135	0,5763
log(rv/поріг) (0)	0,8419	0,6821	0,6835	0,6828	0,8773	0,7608	0,5775
LR (0,5)	0,8548	0,7905	0,5668	0,6602	0,8875	0,7820	0,5838
LR (0,33)	0,8327	0,6455	0,7274	0,6840	0,8875	0,7820	0,5727
RF (0,5)	0,8541	0,8519	0,5012	0,6311	0,8907	0,7827	0,5776
RF (0,26)	0,8419	0,6649	0,7357	0,6985	0,8907	0,7827	0,5931
GBT (0,5)	0,8644	0,8162	0,5878	0,6834	0,9010	0,8024	0,6131
GBT (0,33)	0,8518	0,6916	0,7305	0,7105	0,9010	0,8024	0,6114

Поріг з валідації підвищив F1 усіх моделей за рахунок recall ціною precision: у RF F1 зріс з 0,6311 до 0,6985, recall – з 0,5012 до 0,7357, а precision впала з 0,8519 до 0,6649. Навчання тривало 23,448 с (RF), 23,602 с (GBT) і 4,080 с (LR).

Для довірчих інтервалів тест поділено на 93 тижневі блоки, виконано 1000 повторів блочного бутстрепу (seed 42, скрипт `pz5_stats.py`) з парними різницями на тих самих блоках (таблиця 6).

Таблиця 6 – Тестові метрики та різниці з 95 % довірчими інтервалами (блочний бутстреп)

Модель / порівняння	PR-AUC	ДІ	ROC-AUC	ДІ	F1	ДІ
LR	0,7820	[0,739; 0,821]	0,8875	[0,874; 0,900]	0,6840	[0,648; 0,717]
RF	0,7827	[0,740; 0,820]	0,8907	[0,879; 0,902]	0,6985	[0,665; 0,728]
GBT	0,8024	[0,763; 0,836]	0,9010	[0,890; 0,911]	0,7105	[0,680; 0,739]
Персистентність	0,6135	[0,573; 0,653]	0,7877	[0,771; 0,803]	0,6815	[0,647; 0,715]
log(rv/поріг)	0,7608	[0,713; 0,802]	0,8773	[0,863; 0,890]	0,6828	[0,648; 0,716]
GBT − LR	+0,0203	[+0,014; +0,028]	+0,0134	[+0,010; +0,017]	+0,0265	[+0,017; +0,036]
GBT − RF	+0,0197	[+0,014; +0,026]	+0,0103	[+0,008; +0,012]	+0,0120	[+0,007; +0,017]
GBT − персистентність	+0,1888	[+0,178; +0,199]	+0,1132	[+0,106; +0,121]	+0,0290	[+0,021; +0,037]
GBT − log(rv/поріг)	+0,0415	[+0,033; +0,051]	+0,0236	[+0,021; +0,028]	+0,0277	[+0,020; +0,036]

Інтервали окремих моделей широкі (для PR-AUC близько ±0,04) і перекриваються, парні різниці вужчі, бо спільні важкі тижні компенсуються. Перевага GBT над LR мала (+0,0203 PR-AUC, +0,0134 ROC-AUC), але її інтервал не містить 0, як і перевага над RF. Над персистентністю виграш великий у PR-AUC (+0,1888), але в F1 лише +0,0290.

7.2 Хронологічний і випадковий поділ

Вплив поділу перевірено на однакових годинах тесту з тими самими гіперпараметрами (таблиця 7, рисунок 6). A – хронологічна модель, B навчено на випадкових 80 % передтестового періоду; C – `randomSplit([0.8, 0.2], seed=42)` усіх 77 666 годин; C* – тестові години C у періоді хронологічного тесту, A* – хронологічна модель на тих самих 3180 годинах.

Таблиця 7 – PR-AUC при хронологічному і випадковому поділі на однакових годинах

Варіант	Train	Test	LR	RF	GBT
A: хронологічний	62 108	15 534	0,7820	0,7827	0,8024
B: випадкові 80 % до тесту	49 550	15 534	0,7819	0,7846	0,8019
B − A (95 % ДІ)	–	15 534	−0,000 [−0,000; +0,000]	+0,002 [+0,000; +0,004]	−0,001 [−0,003; +0,002]
A*: хронологічний на годинах C*	62 108	3 180	0,7743	0,7744	0,7946
C*: випадковий 80/20, години тесту	61 920	3 180	0,7795	0,7864	0,8077
C* − A* (95 % ДІ)	–	3 180	+0,005 [+0,003; +0,008]	+0,012 [+0,007; +0,020]	+0,013 [+0,006; +0,021]
C: випадковий 80/20, свій тест	61 920	15 746	0,7441	0,7200	0,7520

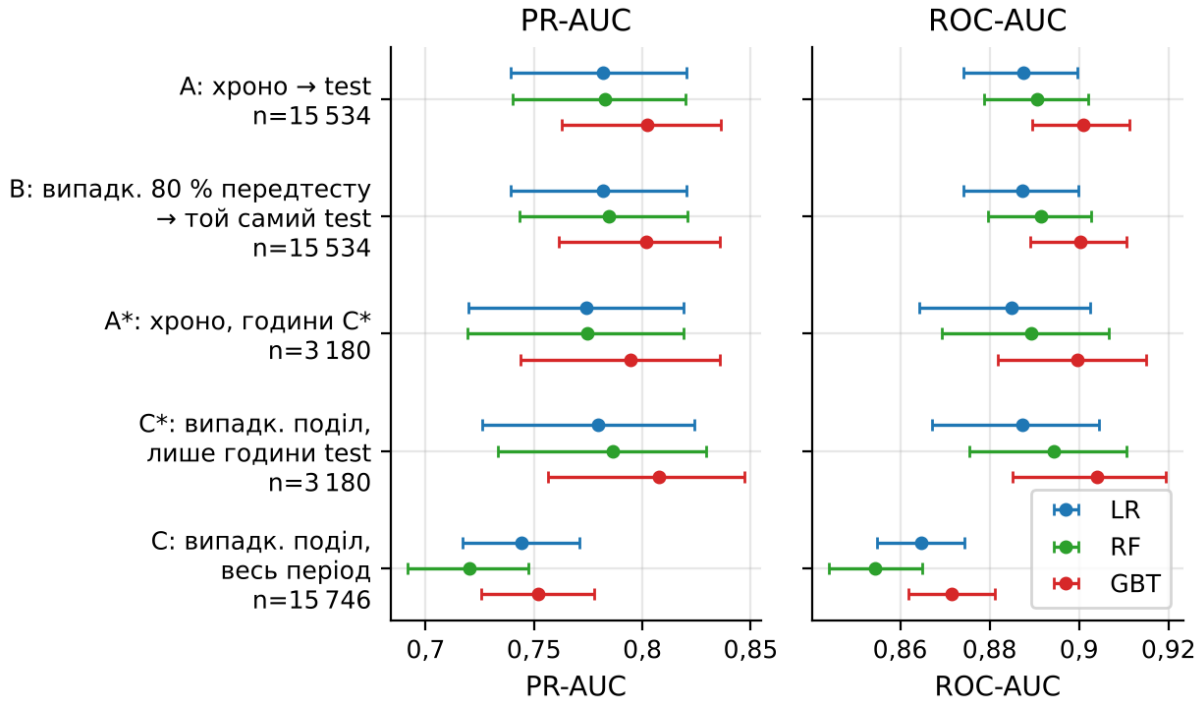


Рисунок 6 – PR-AUC і ROC-AUC з 95 % ДІ при хронологічному і випадковому поділі

Коли обидві моделі навчаються на періоді до тесту (B і A), перемішування train змінює PR-AUC не більше ніж на 0,002 (для RF B − A = +0,0019, ДІ [+0,0003; +0,0038] не містить 0). Коли ж випадковий train містить сусідні години тестового періоду (C* і A*), PR-AUC вищий на 0,005–0,013 і інтервали не містять 0: 0,6399 тестових годин C* мають обох сусідів у train (у хронологічному поділі – жодна), а сусідні години мають майже однакові повільні ознаки і корельовані мітки (ACF 0,5165 на лагу 1).

Дерева інтерполюють між такими сусідами, тому приріст RF і GBT (+0,012–0,013) більший, ніж LR (+0,005). Нижчий на 0,04–0,06 PR-AUC на власному тесті C відображає інший склад тесту (рядки 2018–2026 років). Для оцінки використано хронологічний поділ.

8 Аналіз результатів

8.1 Інформативність ознак

Важливості ознак RF і GBT та коефіцієнти LR показано на рисунку 7.

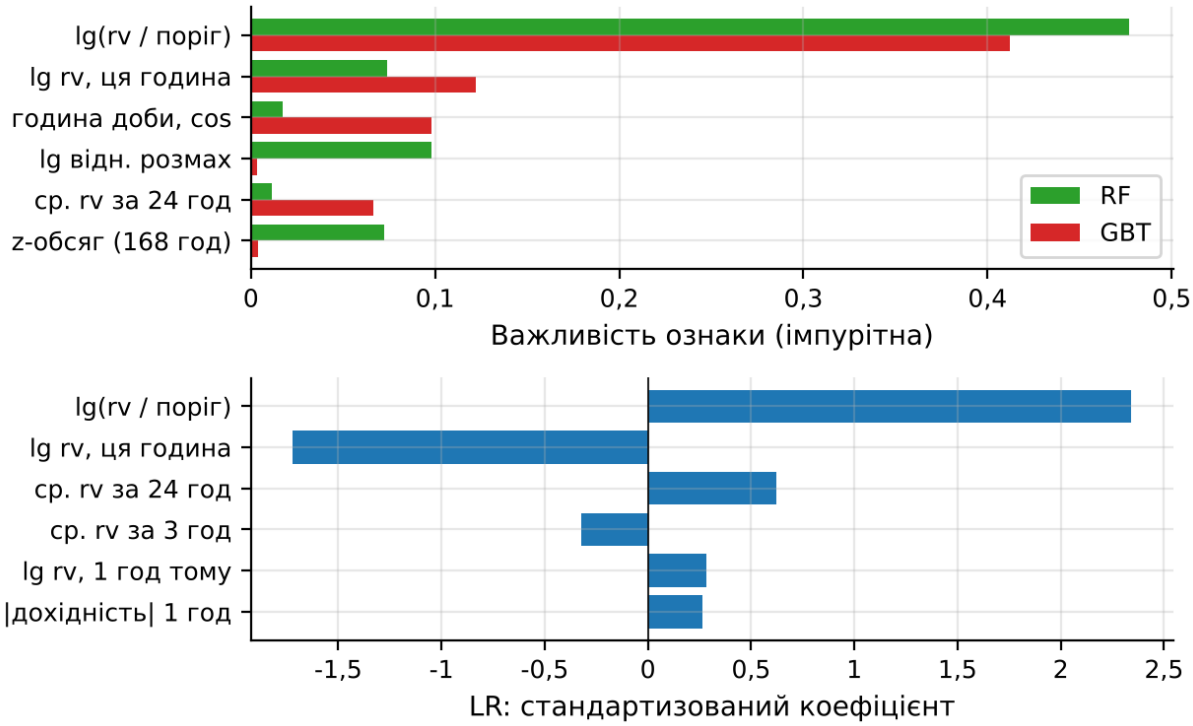


Рисунок 7 – Важливість ознак RF і GBT та стандартизовані коефіцієнти LR (6 найбільших)

Найінформативніша ознака в усіх трьох моделях – `log_rv_over_thr`: 0,4770 важливості в RF, 0,4121 у GBT і коефіцієнт 2,3413 у LR, що узгоджується з ROC-AUC 0,8773 цієї ознаки окремо. Далі в RF ідуть `log_rel_range` (0,0981), `log_rv_l0` (0,0741) і `vol_z168` (0,0722). GBT другою ставить `log_rv_l0` (0,1223), третьою – `hour_cos` (0,0978), а разом з `hour_sin` (0,0426) година доби набирає 0,1404 (внутрішньодобова

сезонність, у П32 максимум обсягу о 14:00 UTC). Дохідності разом мають 0,0539 у RF і 0,0770 у GBT; день тижня (0,0027 у RF) і частка flat-хвилин (0,0054) майже не використовуються. Імпурітні важливості зміщені на користь неперервних і корельованих ознак, тож це лише порядок величини.

8.2 Помилки моделей

З порогами з валідації GBT робить 2302 помилки з 15 534 (1260 хибно позитивних, 1042 хибно негативних), RF – 2456, LR – 2599. Помилки GBT за групами зведено в таблицю 8.

Таблиця 8 – Помилки GBT (поріг 0,33) за групами тестових годин

Група	n	Частка класу 1	Частка помилок	Recall	Precision
Поточна година нижче порогу	11 683	0,1059	0,1064	0,2369	0,4949
Поточна година вище порогу	3 851	0,6829	0,2750	0,9627	0,7249
Режим зберігається	13 076	–	0,0304	–	–
Початок сплеску (0 → 1)	1 237	–	0,7631	–	–
Завершення сплеску (1 → 0)	1 221	–	0,7871	–	–
2025 рік	7 996	0,2496	0,1471	0,7405	0,6919
2026 рік	7 538	0,2482	0,1494	0,7199	0,6911

Основне джерело помилок – зміна режиму: коли режим зберігається, частка помилок 0,0304, а на початку сплеску – 0,7631. Recall у спокійних годинах 0,2369, тобто сплеск передбачається переважно тоді, коли він уже триває. Модель так само запізнюється із завершенням сплеску (0,7871): 961 з 1260 хибних тривог припадає на години, коли поточна `rv` вища за поріг, а наступна вже спадає. Частка помилок 0,1471 у 2025 році і 0,1494 у 2026 році, тож деградації за 21 місяць немає. Розподіл за годиною доби показано на рисунку 8 (рядок години t прогнозує годину t+1).

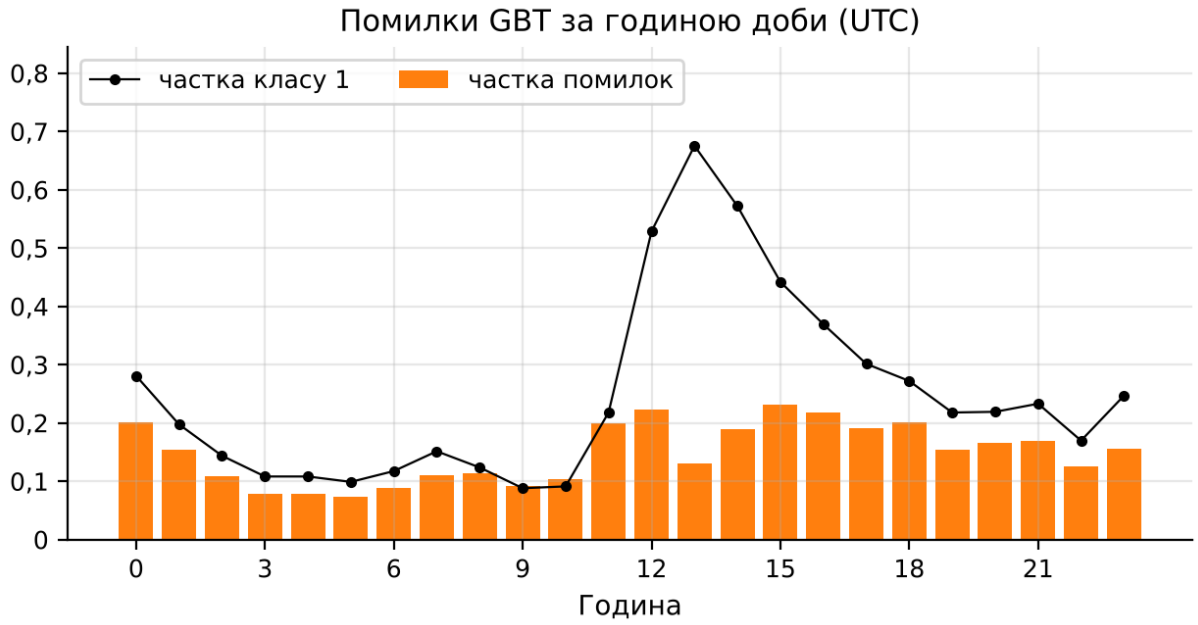


Рисунок 8 – Частка помилок GBT і частка класу 1 за годиною доби (UTC)

Помилок найменше вночі (0,0742 у рядках 05:00) і найбільше вдень: 0,2226 у рядку 12:00 і 0,2318 у рядку 15:00. У рядку 12:00 частка класу 1 становить 0,5286, а recall лише 0,6959: сплеск на початку американської сесії модель передбачає лише частково; за періодами літнього і зимового часу цю гіпотезу не перевіряли.

8.3 Шляхи вдосконалення

Резерв – у передбаченні початку і завершення сплесків: можна додати ознаки всередині години з хвилинних даних (`rv` останніх 15 хв, кількість стрибків, нахил обсягу) і календар подій (сесії США, макростатистика).

Висновки

1. Обрано задачу «чи буде наступна година високоволатильною»: напрям ціни передбачуваний статистично (accuracy 0,5132, p = 0,001), але економічно мізерно.

2. Дані: 77 666 годин 2018–2026 років; ціль – перевищення `rv` над 75-м перцентилем за 720 годин, ознаки – 17 числових з минулого, година і день тижня.
3. Поділ хронологічний 80/20 з ембарго 24 год (62 108 і 15 534 годин).
4. Побудовано LR, RF і GBT; за часовою CV (PR-AUC) GBT (0,7467) і LR (0,7456) практично рівноцінні.
5. Реалізовано повний ML Pipeline MLlib зі збереженням моделі; метрики – accuracy, precision, recall, F1, ROC-AUC, PR-AUC, MCC з 95 % ДІ блочного бутстрепу.
6. Найкращі значення має GBT з порогом 0,33: F1 0,7105, ROC-AUC 0,9010, PR-AUC 0,8024 [0,7630; 0,8363]. Перевага над LR мала (+0,0203 PR-AUC), але її інтервал [+0,0144; +0,0280] не містить 0. Випадковий поділ завищує PR-AUC на 0,005–0,013, лише коли train містить сусідні години тесту.
7. Найінформативніша ознака – відношення `rv` до порогу; основні помилки – пропуск початку сплеску (0,7631) і запізнення з його завершенням (0,7871), резерв – внутрішньогодинні ознаки.